Глубокое обучение в компьютерном зрении

Занятие 7
Архитектуры CNN

Дмитрий Яшунин, к.ф.-м.н
IntelliVision

e-mail: yashuninda@yandex.ru

Классификация изображений

Ключевая задача компьютерного зрения

К какому классу принадлежит изображение?
классы: человек, животное, автомобиль …

кот

Large Scale Visual Recognition Challenge (ILSVRC)

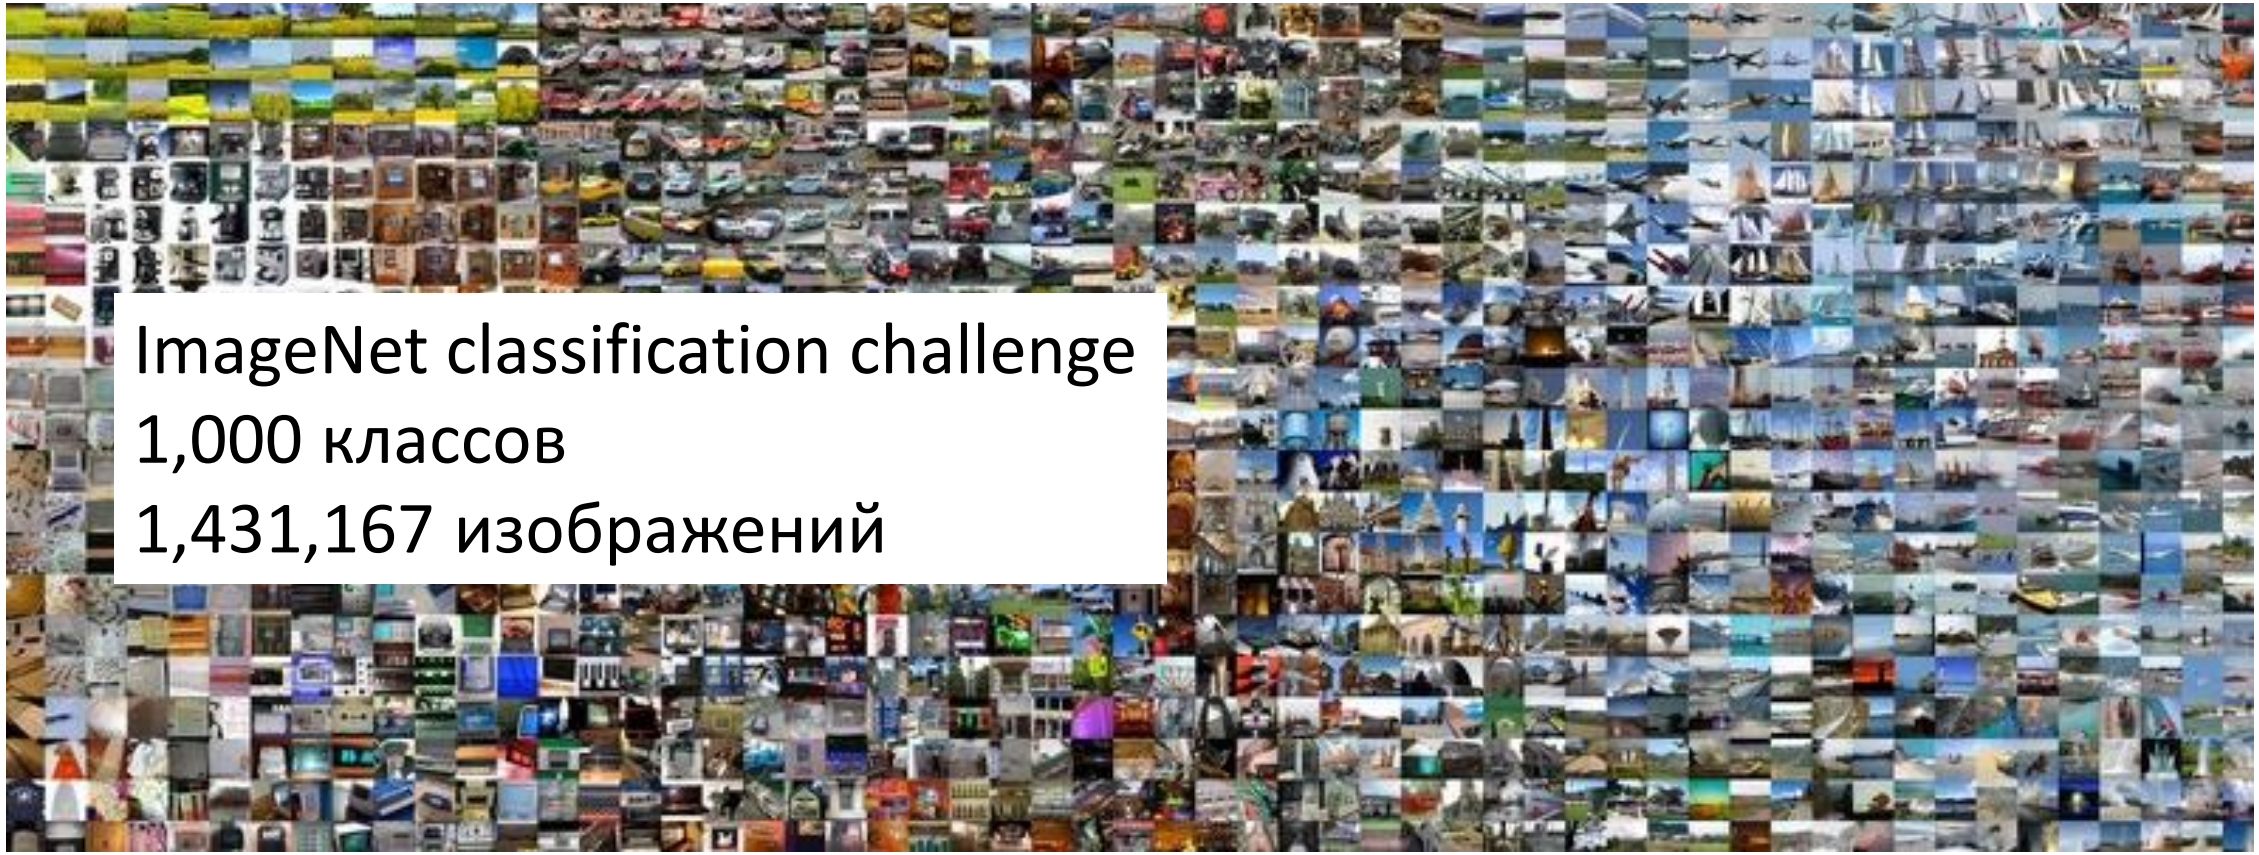

http://image-net.org/

IMAGENET Large Scale Visual Recognition Challenge (ILSVRC)

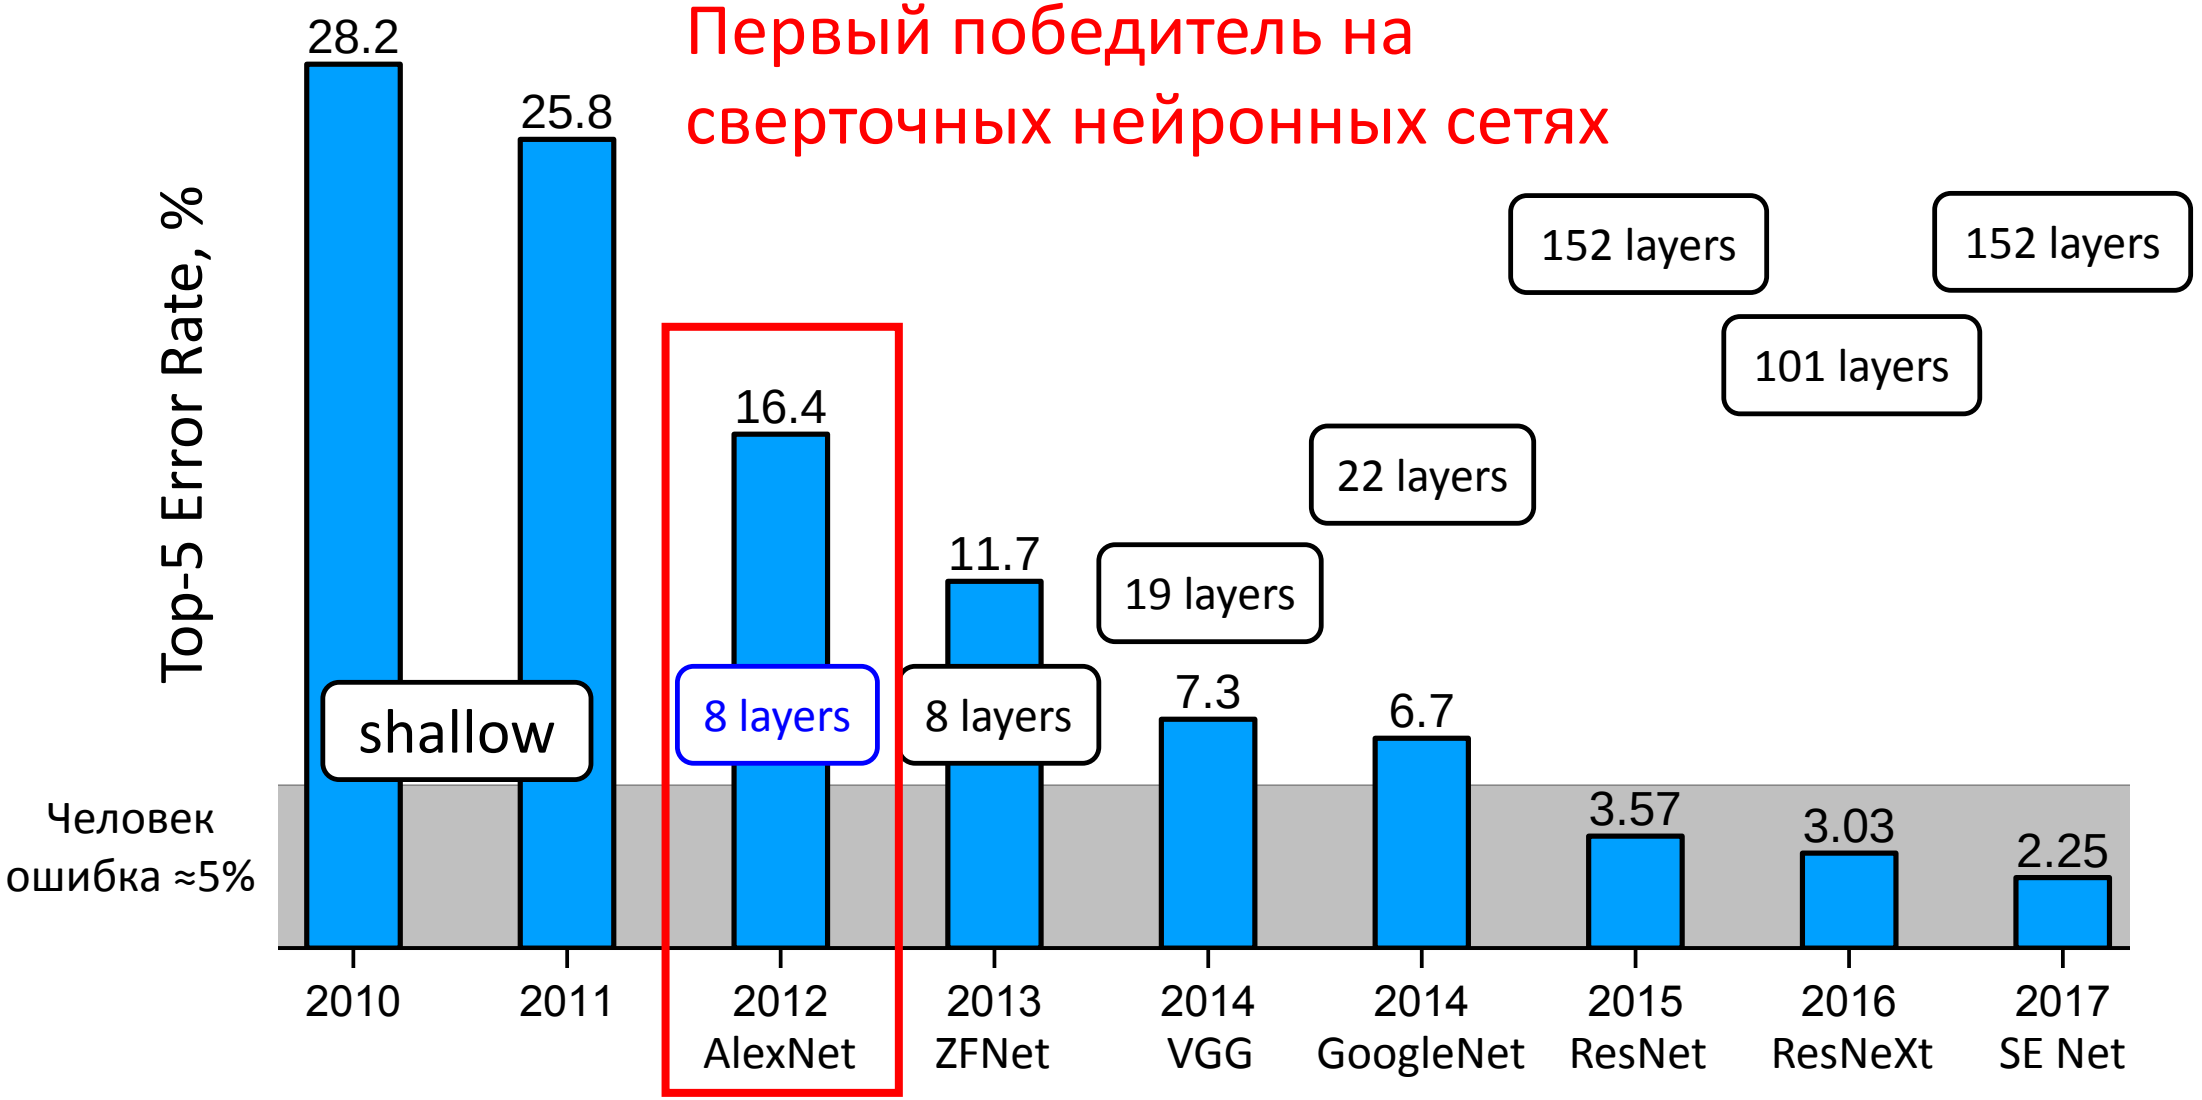

AlexNet

(Krizhevsky et al. 2012)

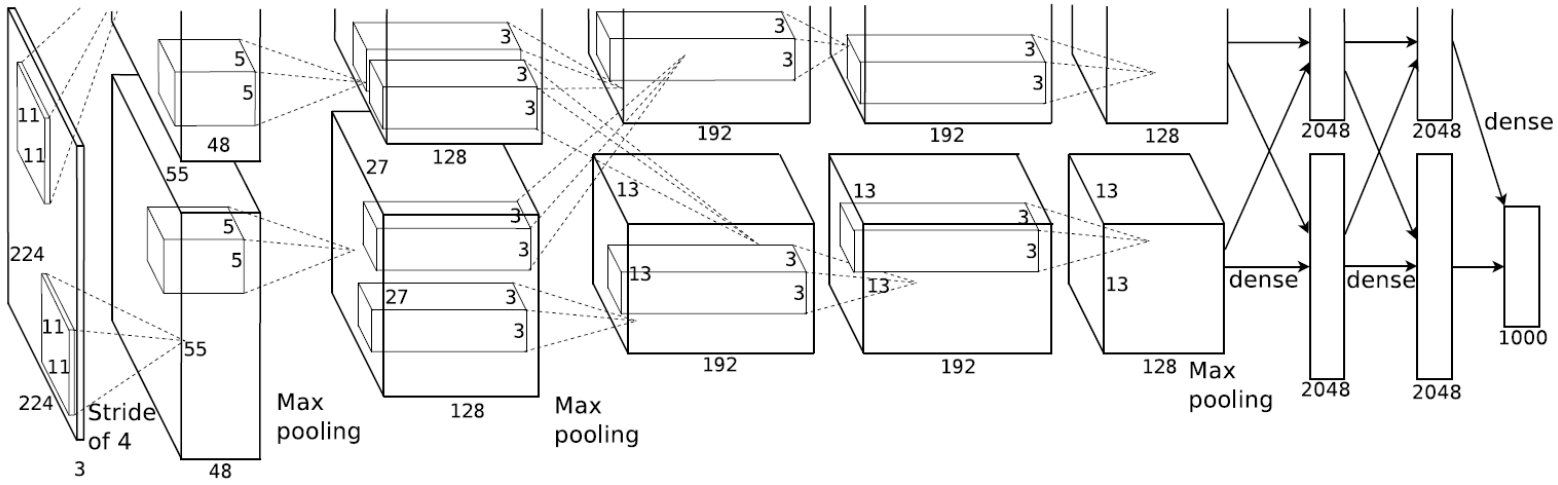

Архитектура:

CONV1

MAX POOL1

LRN1

CONV2

MAX POOL2

LRN2

CONV3

CONV4

CONV5

Max POOL3

FC6

FC7

FC8

ImageNet top 5 error: 25.8% -> 16.4%

AlexNet

(Krizhevsky et al. 2012)

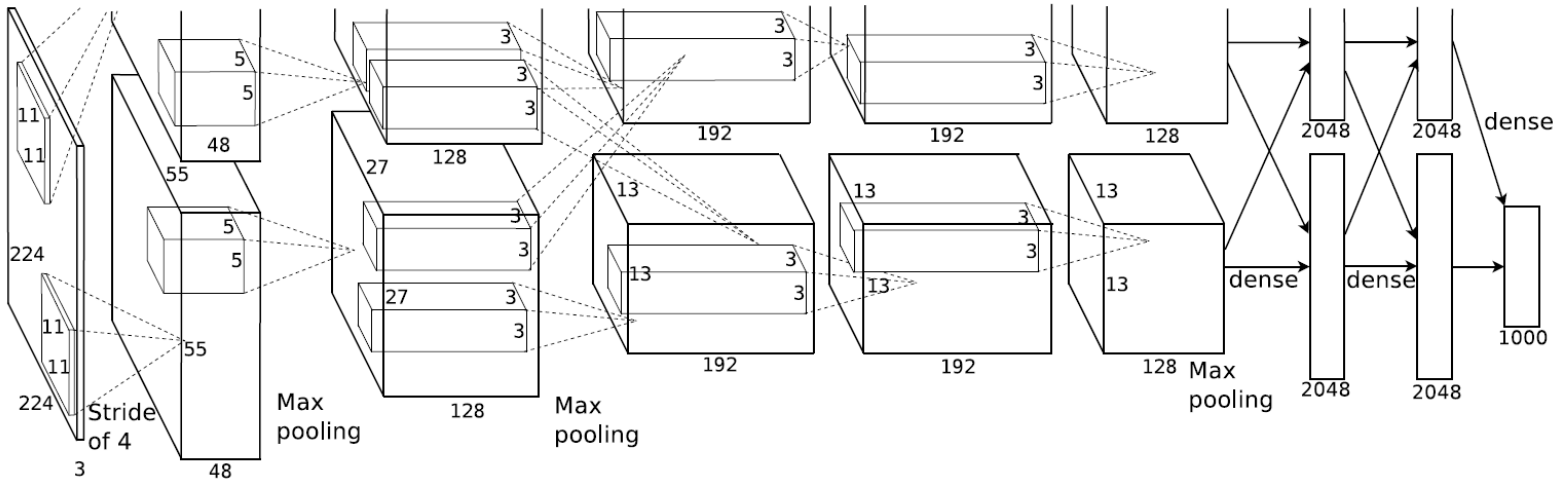

Размер входного изображения: 227x227x3

Первый слой (CONV1): 96 11x11 фильтров (filters) с шагом (stride) 4 отступом (padding) 0

Вопрос: какой размер карты активаций на выходе? Подсказка: (227-11)/4+1 = 55

AlexNet

(Krizhevsky et al. 2012)

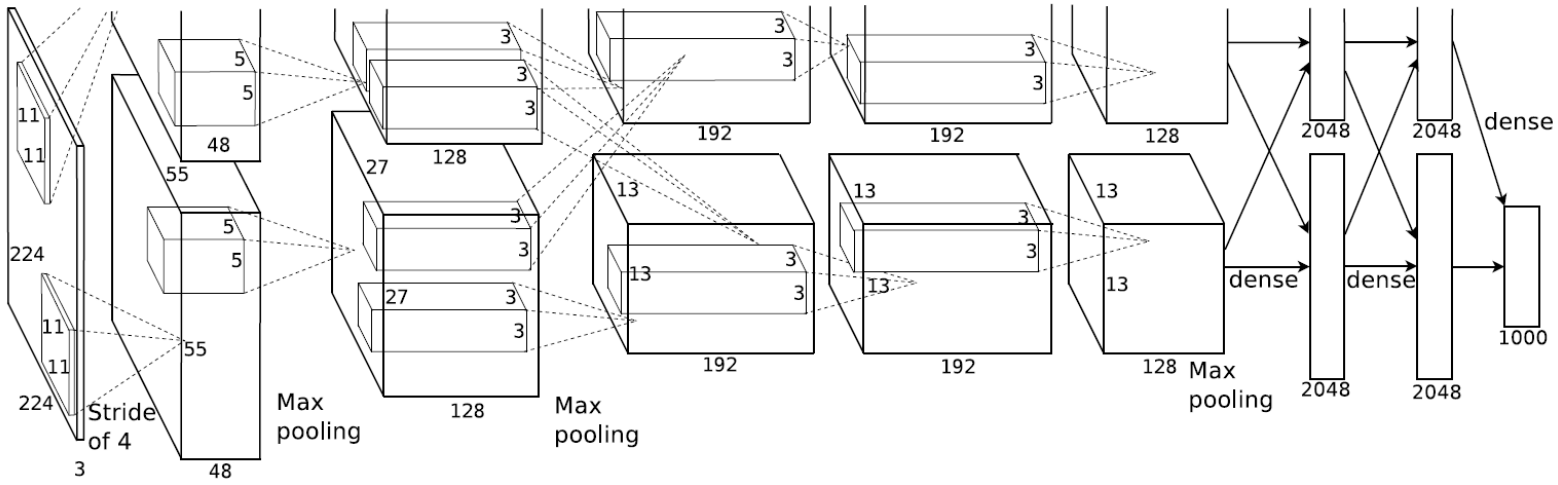

Размер входного изображения: 227x227x3

Первый слой (CONV1): 96 11x11 фильтров (filters) с шагом (stride) 4
Размер карты активаций **55x55x96**

Вопрос: какое число параметров в слое?

AlexNet

(Krizhevsky et al. 2012)

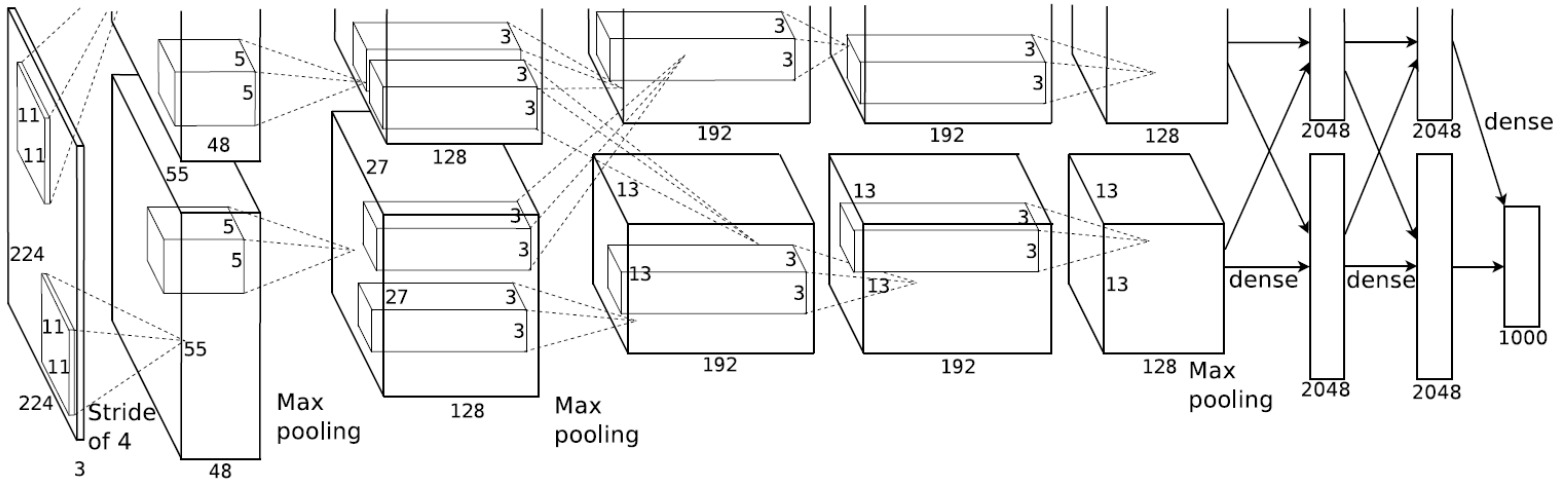

Размер входного изображения: 227x227x3

Первый слой (CONV1): 96 11x11 фильтров (filters) с шагом (stride) 4
Размер карты активаций **55x55x96**
Число параметров: (11*11*3)*96 = **35K**

AlexNet

(Krizhevsky et al. 2012)

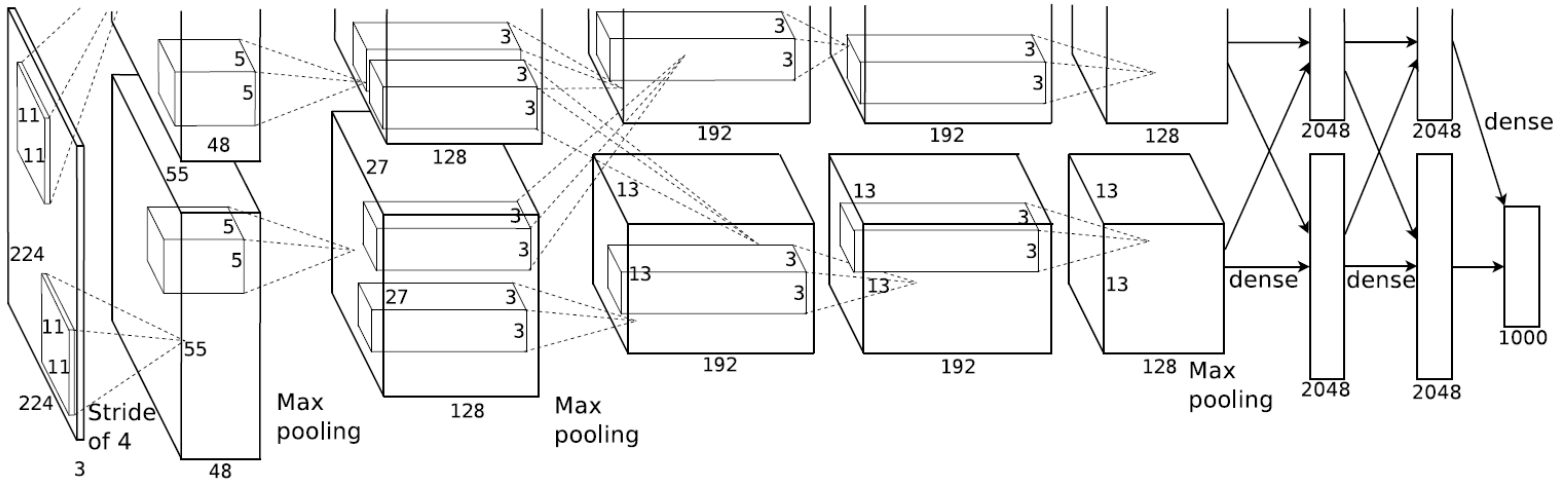

Размер входного изображения: 227x227x3
после CONV1: 55x55x96

Второй слой (MAX POOL1): фильтры 3x3 с шагом (stride) 2

Вопрос: какой размер на выходе? Подсказка: (55-3)/2+1 = 27

AlexNet

(Krizhevsky et al. 2012)

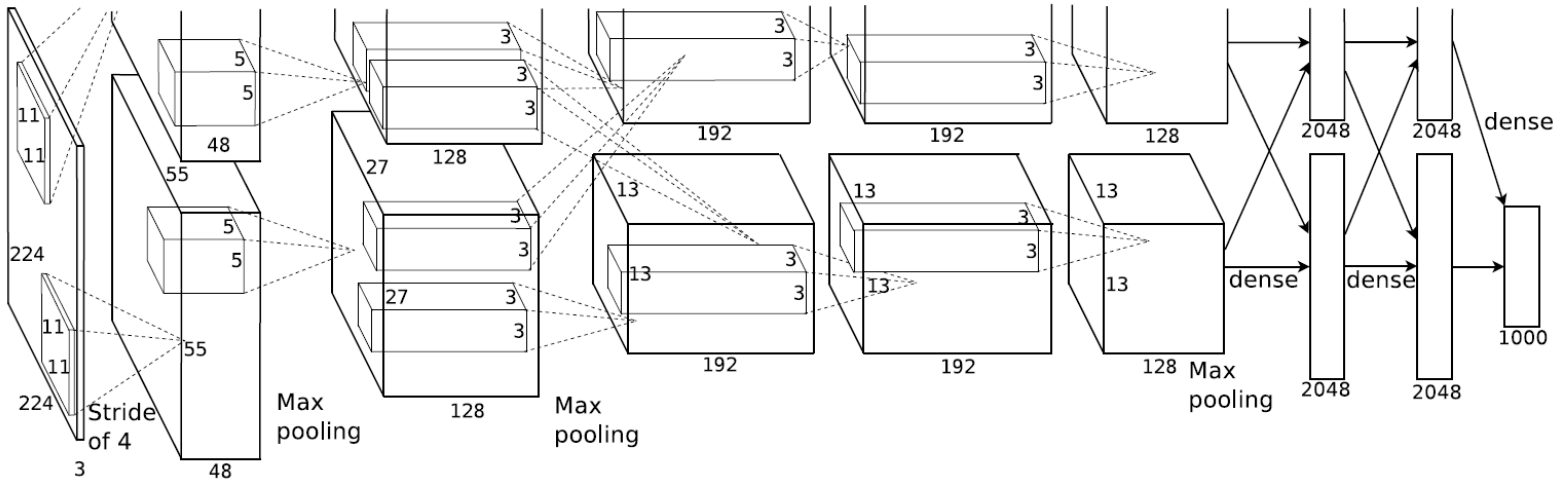

Размер входного изображения: 227x227x3
после CONV1: 55x55x96

Второй слой (MAX POOL1): фильтры 3x3 с шагом (stride) 2
Размер на выходе: **27x27x96**

Вопрос: какое число параметров в слое?

AlexNet

(Krizhevsky et al. 2012)

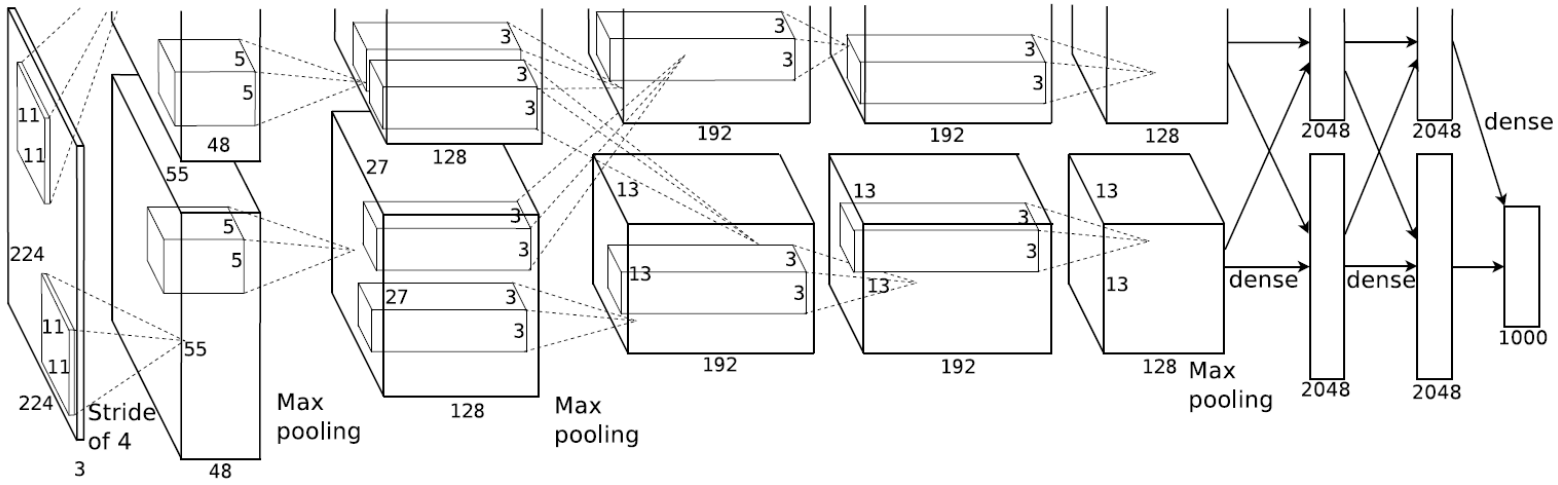

Размер входного изображения: 227x227x3
после CONV1: 55x55x96

Второй слой (MAX POOL1): фильтры 3x3 с шагом (stride) 2
Размер на выходе: **27x27x96**
Число параметров: **0**

AlexNet

(Krizhevsky et al. 2012)

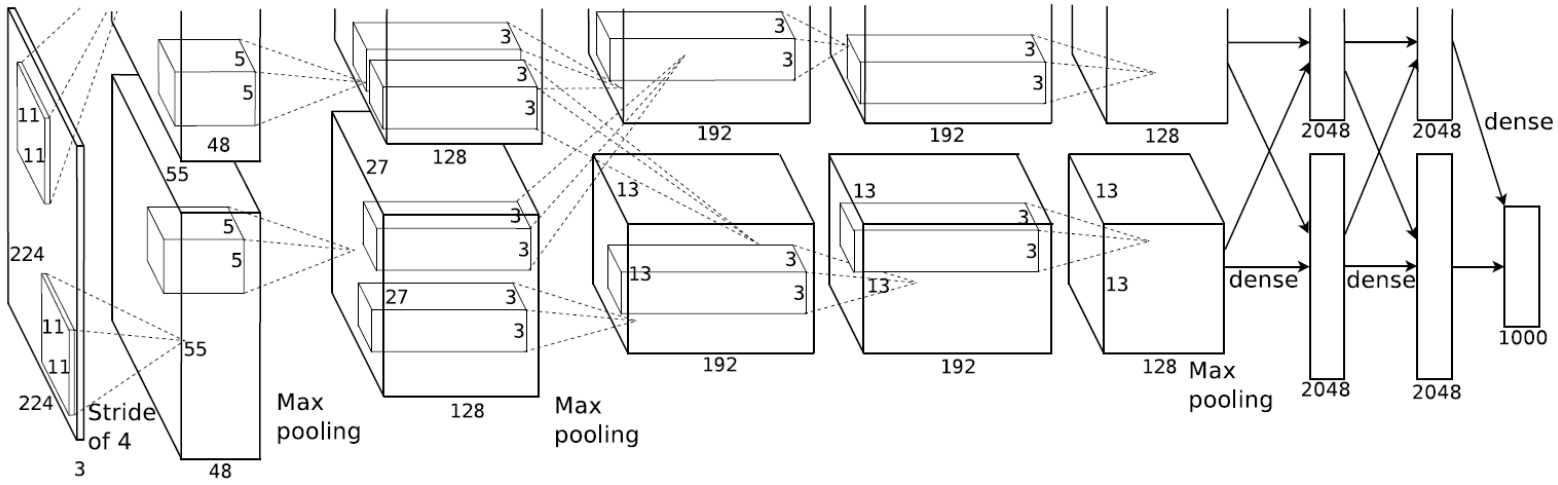

Размер входного изображения: 227x227x3
после CONV1: 55x55x96
после POOL1: 27x27x96
…

AlexNet

(Krizhevsky et al. 2012)

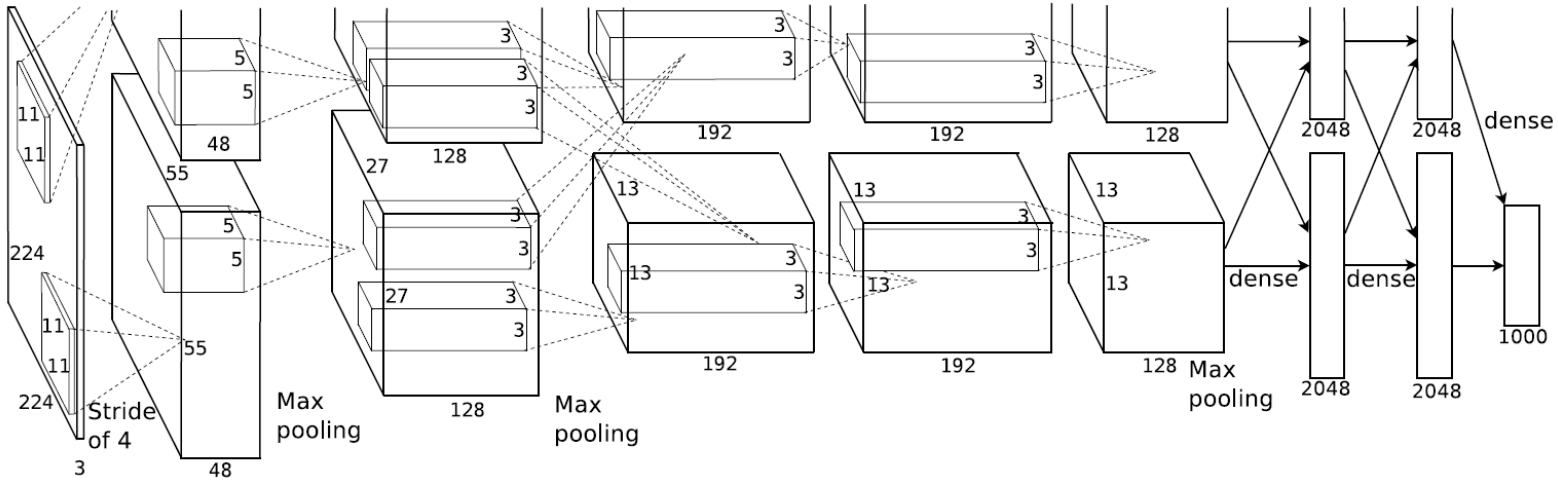

Архитектура AlexNet:

[227x227x3] INPUT
[55x55x96] CONV1: 96 11x11 filters at stride 4, pad 0
[27x27x96] MAX POOL1: 3x3 filters at stride 2
[27x27x96] LRN1: Normalization layer
[27x27x256] CONV2: 256 5x5 filters at stride 1, pad 2
[13x13x256] MAX POOL2: 3x3 filters at stride 2
[13x13x256] LRN2: Normalization layer
[13x13x384] CONV3: 384 3x3 filters at stride 1, pad 1
[13x13x384] CONV4: 384 3x3 filters at stride 1, pad 1
[13x13x256] CONV5: 256 3x3 filters at stride 1, pad 1
[6x6x256] MAX POOL3: 3x3 filters at stride 2
[4096] FC6: 4096 neurons
[4096] FC7: 4096 neurons
[1000] FC8: 1000 neurons (class scores)

AlexNet

(Krizhevsky et al. 2012)

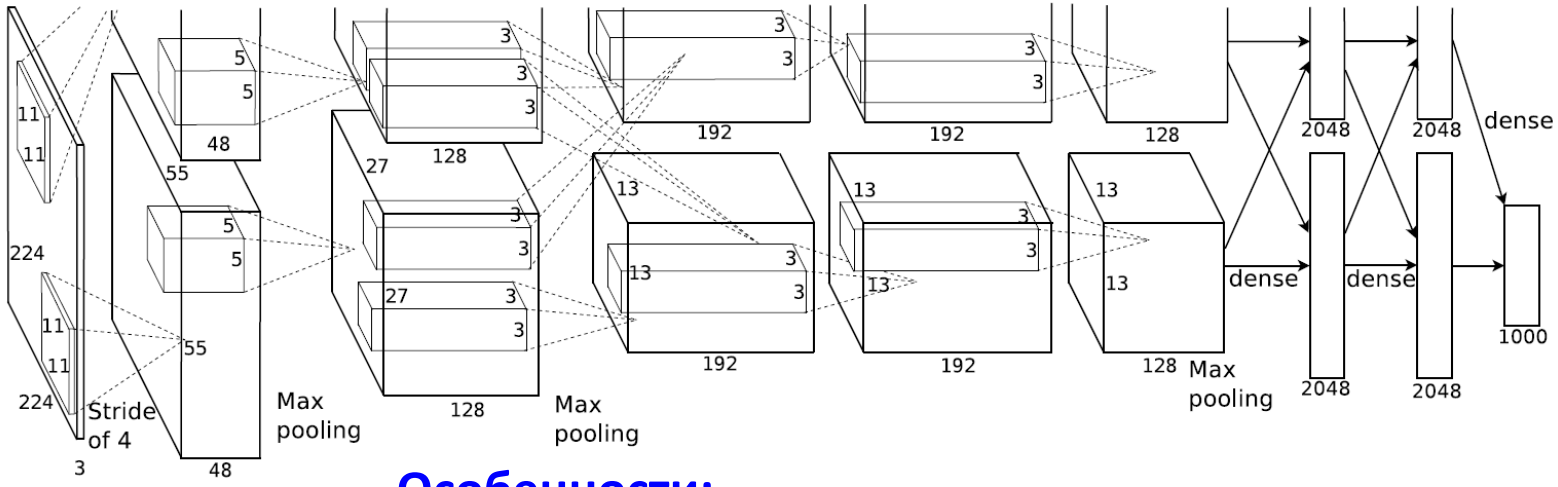

Архитектура AlexNet:

[227x227x3] INPUT
[55x55x96] CONV1: 96 11x11 filters at stride 4, pad 0
[27x27x96] MAX POOL1: 3x3 filters at stride 2
[27x27x96] LRN1: Normalization layer
[27x27x256] CONV2: 256 5x5 filters at stride 1, pad 2
[13x13x256] MAX POOL2: 3x3 filters at stride 2
[13x13x256] LRN2: Normalization layer
[13x13x384] CONV3: 384 3x3 filters at stride 1, pad 1
[13x13x384] CONV4: 384 3x3 filters at stride 1, pad 1
[13x13x256] CONV5: 256 3x3 filters at stride 1, pad 1
[6x6x256] MAX POOL3: 3x3 filters at stride 2
[4096] FC6: 4096 neurons
[4096] FC7: 4096 neurons
[1000] FC8: 1000 neurons (class scores)

Особенности:

- впервые применили ReLU
- использовали Local Response Normalization слои (теперь не применяются)
- сильная аугментация данных
- dropout 0.5
- batch size 128, SGD Momentum 0.9
- learning rate 1e-2, когда точность на валидационном наборе переставала расти уменьшали в 10 раз
- L2 weight decay (регуляризация) 5e-4
- 7 CNN ансамбль моделей (ensemble): 18.2% -> 15.4% (на валидации)
- ≈ 60 млн. параметров, ≈ 230 Мбайт caffemodel

AlexNet

(Krizhevsky et al. 2012)

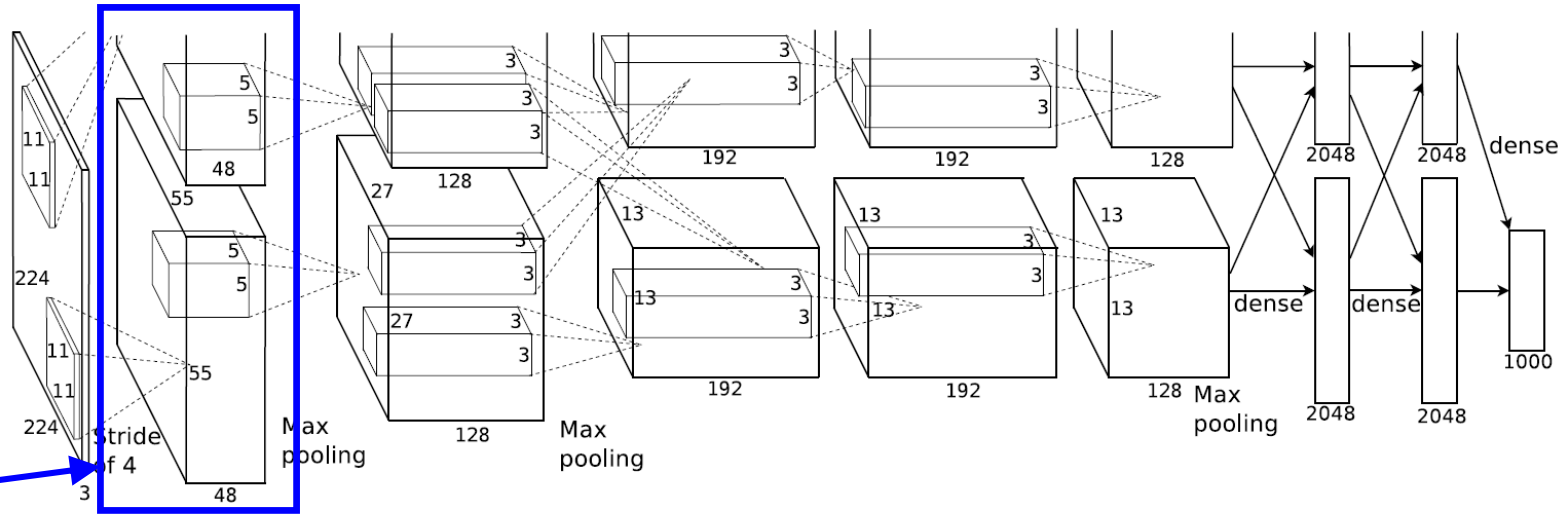

Архитектура AlexNet:

[227x227x3] INPUT
[55x55x96] CONV1: 96 11x11 filters at stride 4, pad 0
[27x27x96] MAX POOL1: 3x3 filters at stride 2
[27x27x96] LRN1: Normalization layer
[27x27x256] CONV2: 256 5x5 filters at stride 1, pad 2
[13x13x256] MAX POOL2: 3x3 filters at stride 2
[13x13x256] LRN2: Normalization layer
[13x13x384] CONV3: 384 3x3 filters at stride 1, pad 1
[13x13x384] CONV4: 384 3x3 filters at stride 1, pad 1
[13x13x256] CONV5: 256 3x3 filters at stride 1, pad 1
[6x6x256] MAX POOL3: 3x3 filters at stride 2
[4096] FC6: 4096 neurons
[4096] FC7: 4096 neurons
[1000] FC8: 1000 neurons (class scores)

[55x55x48]x2

Сеть тренировали на двух GTX 580 3GB GPUs.
Сеть делилась между двумя видеокартами. Половина карт активации на одной GPU, половина на другой.

AlexNet

(Krizhevsky et al. 2012)

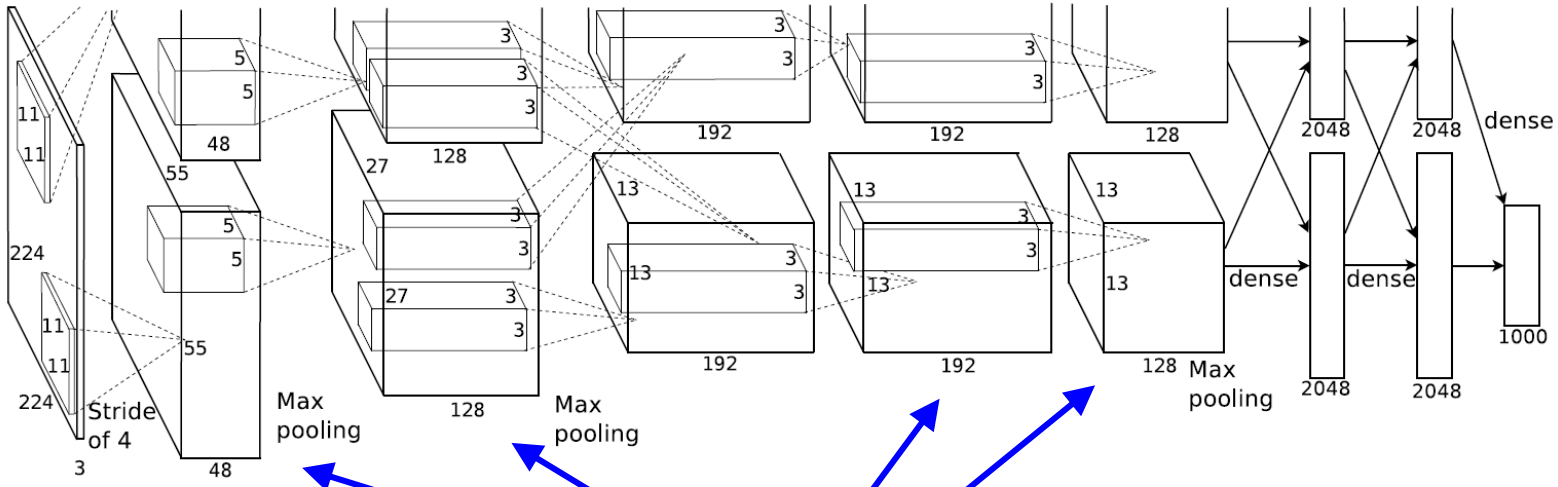

Архитектура AlexNet:

[227x227x3] INPUT
[55x55x96] CONV1: 96 11x11 filters at stride 4, pad 0
[27x27x96] MAX POOL1: 3x3 filters at stride 2
[27x27x96] LRN1: Normalization layer
[27x27x256] CONV2: 256 5x5 filters at stride 1, pad 2
[13x13x256] MAX POOL2: 3x3 filters at stride 2
[13x13x256] LRN2: Normalization layer
[13x13x384] CONV3: 384 3x3 filters at stride 1, pad 1
[13x13x384] CONV4: 384 3x3 filters at stride 1, pad 1
[13x13x256] CONV5: 256 3x3 filters at stride 1, pad 1
[6x6x256] MAX POOL3: 3x3 filters at stride 2
[4096] FC6: 4096 neurons
[4096] FC7: 4096 neurons
[1000] FC8: 1000 neurons (class scores)

CONV1, CONV2, CONV4, CONV5:
Connections only with feature maps on same GPU

AlexNet

(Krizhevsky et al. 2012)

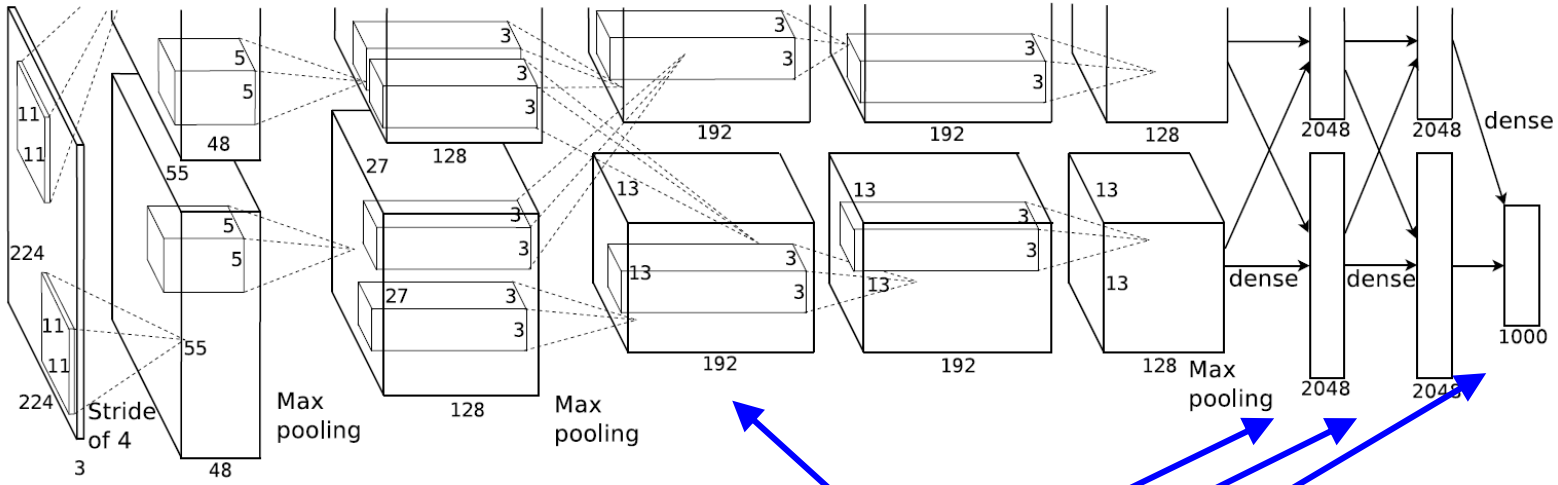

Архитектура AlexNet:

[227x227x3] INPUT
[55x55x96] CONV1: 96 11x11 filters at stride 4, pad 0
[27x27x96] MAX POOL1: 3x3 filters at stride 2
[27x27x96] LRN1: Normalization layer
[27x27x256] CONV2: 256 5x5 filters at stride 1, pad 2
[13x13x256] MAX POOL2: 3x3 filters at stride 2
[13x13x256] LRN2: Normalization layer
[13x13x384] CONV3: 384 3x3 filters at stride 1, pad 1
[13x13x384] CONV4: 384 3x3 filters at stride 1, pad 1
[13x13x256] CONV5: 256 3x3 filters at stride 1, pad 1
[6x6x256] MAX POOL3: 3x3 filters at stride 2
[4096] FC6: 4096 neurons
[4096] FC7: 4096 neurons
[1000] FC8: 1000 neurons (class scores)

CONV3, FC6, FC7, FC8:
Connections with all feature maps in preceding layer, communication across GPUs

Large Scale Visual Recognition Challenge (ILSVRC)

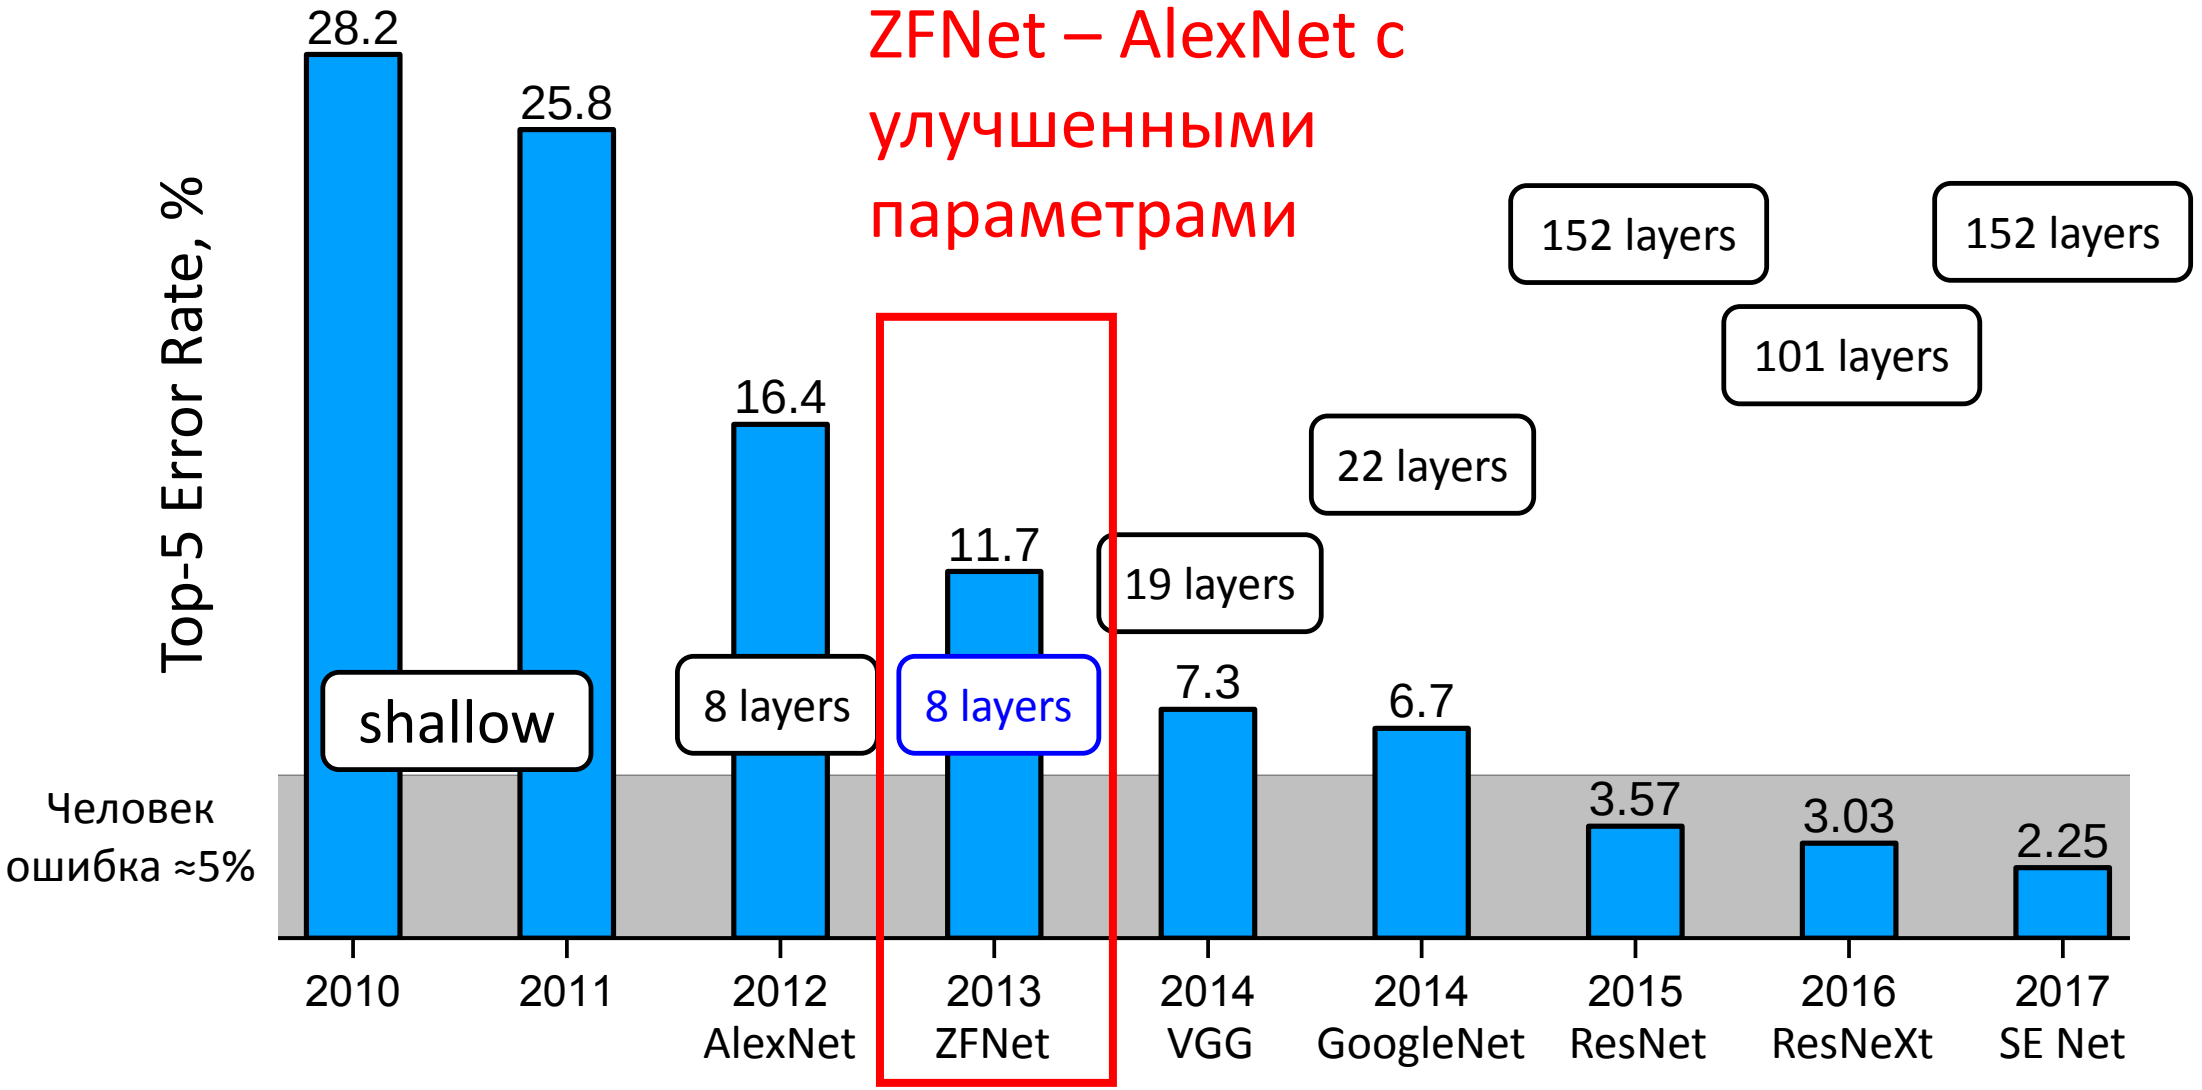

ZFNet

(Zeiler and Fergus, 2013)

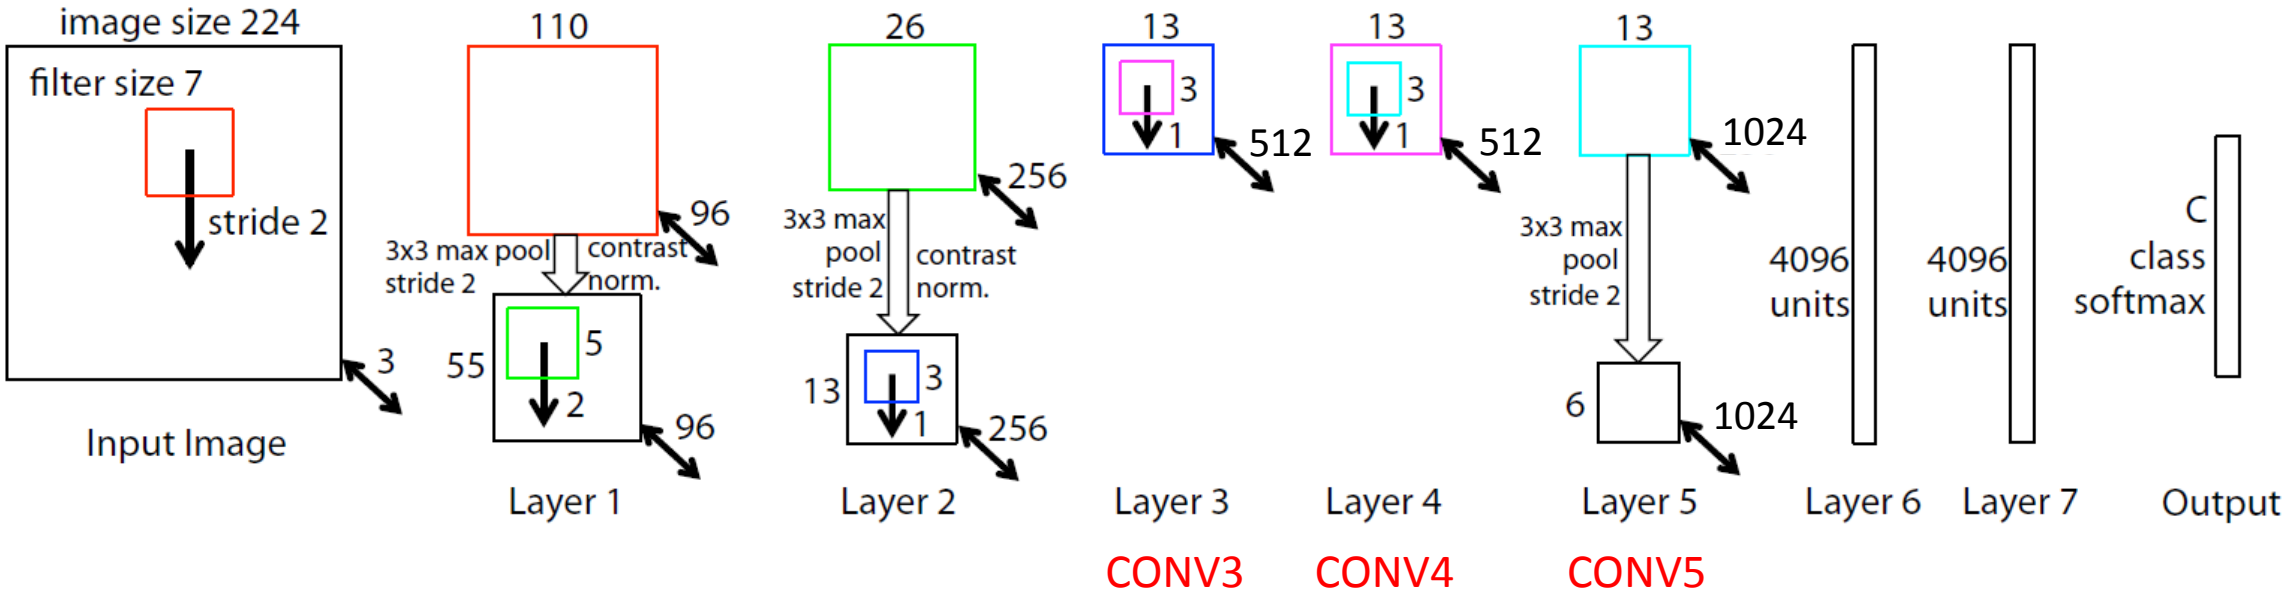

Архитектура ZFNet почти такая же как у AlexNet:

CONV1: (11x11 stride 4) -> (7x7 stride 2)

CONV3,4,5: 384, 384, 256 filters -> 512, 1024, 512 filters

ImageNet top 5 error: 16.4% (AlexNet) -> 11.7%

Large Scale Visual Recognition Challenge (ILSVRC)

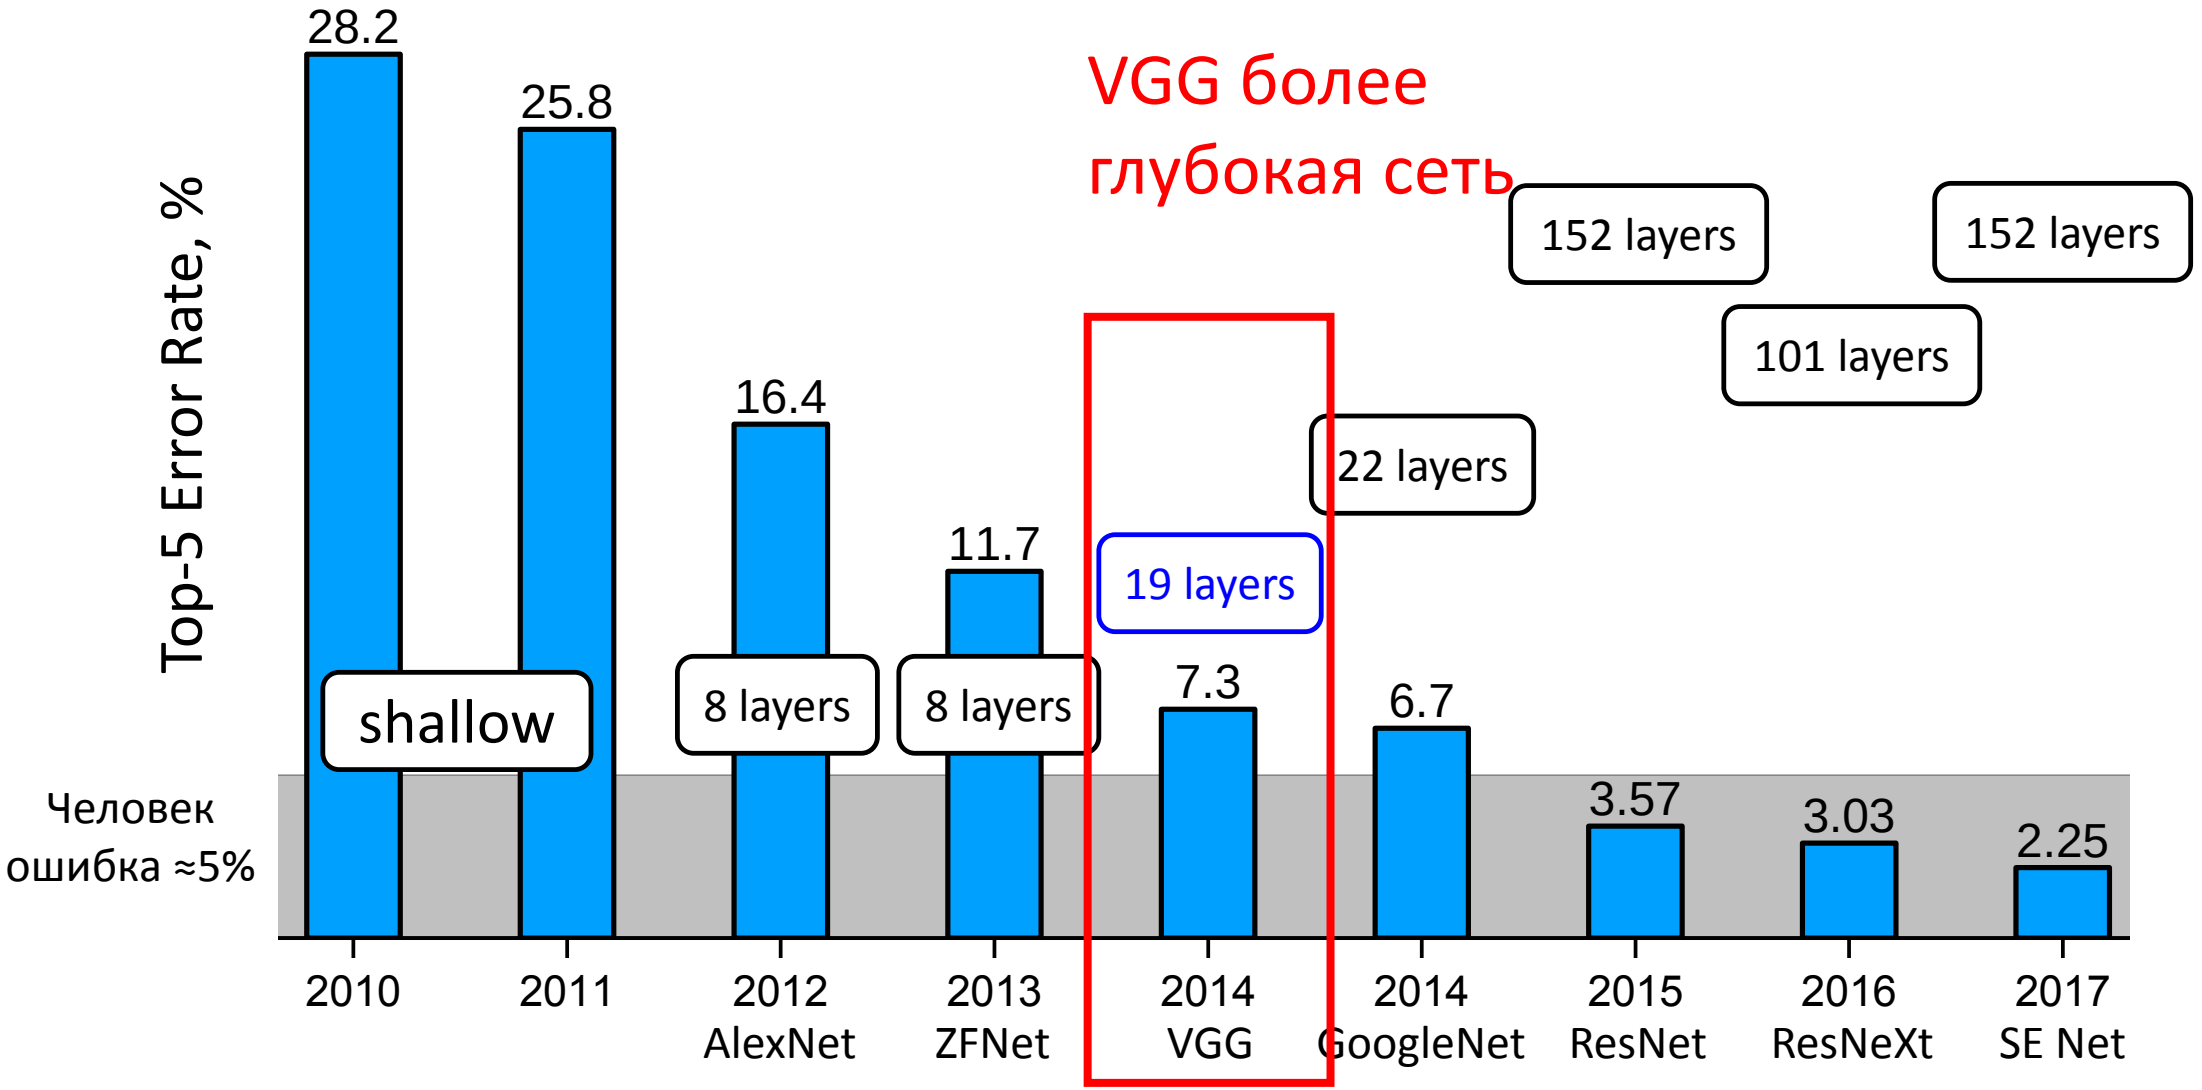

VGG

(Simonyan and Zisserman, 2014)

Глубже сеть, меньше свертки (3x3)

AlexNet 8 слоев -> VGG 16 - 19 слоев

Свертки только 3x3 stride 1, pad 1
и MAX POOL 2x2 stride 2

ImageNet top 5 error: 11.7% (ZFNet) -> 7.3%

AlexNet

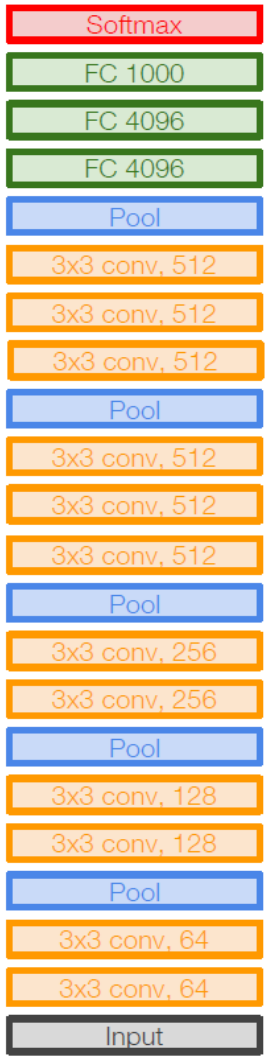

VGG16

VGG19

VGG

(Simonyan and Zisserman, 2014)

Вопрос: почему авторы используют небольшие свертки (3x3)?

Преимущества маленьких сверток

Пусть мы применяем последовательно две свертки 3x3 stride 1
Каждый нейрон видит область 3x3 на предыдущей карте активаций

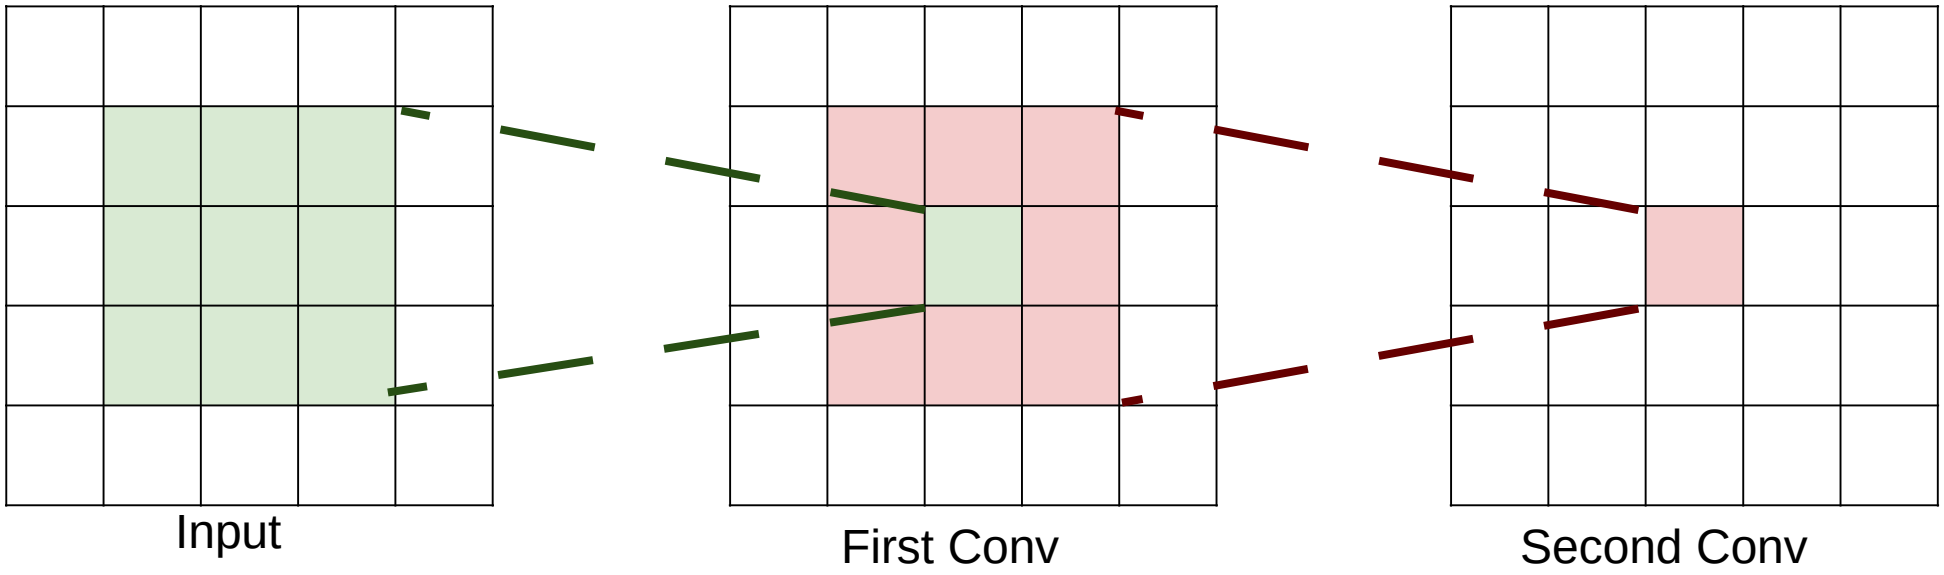

Преимущества маленьких сверток

Вопрос: какую область входа видит нейрон во втором сверточном слое?

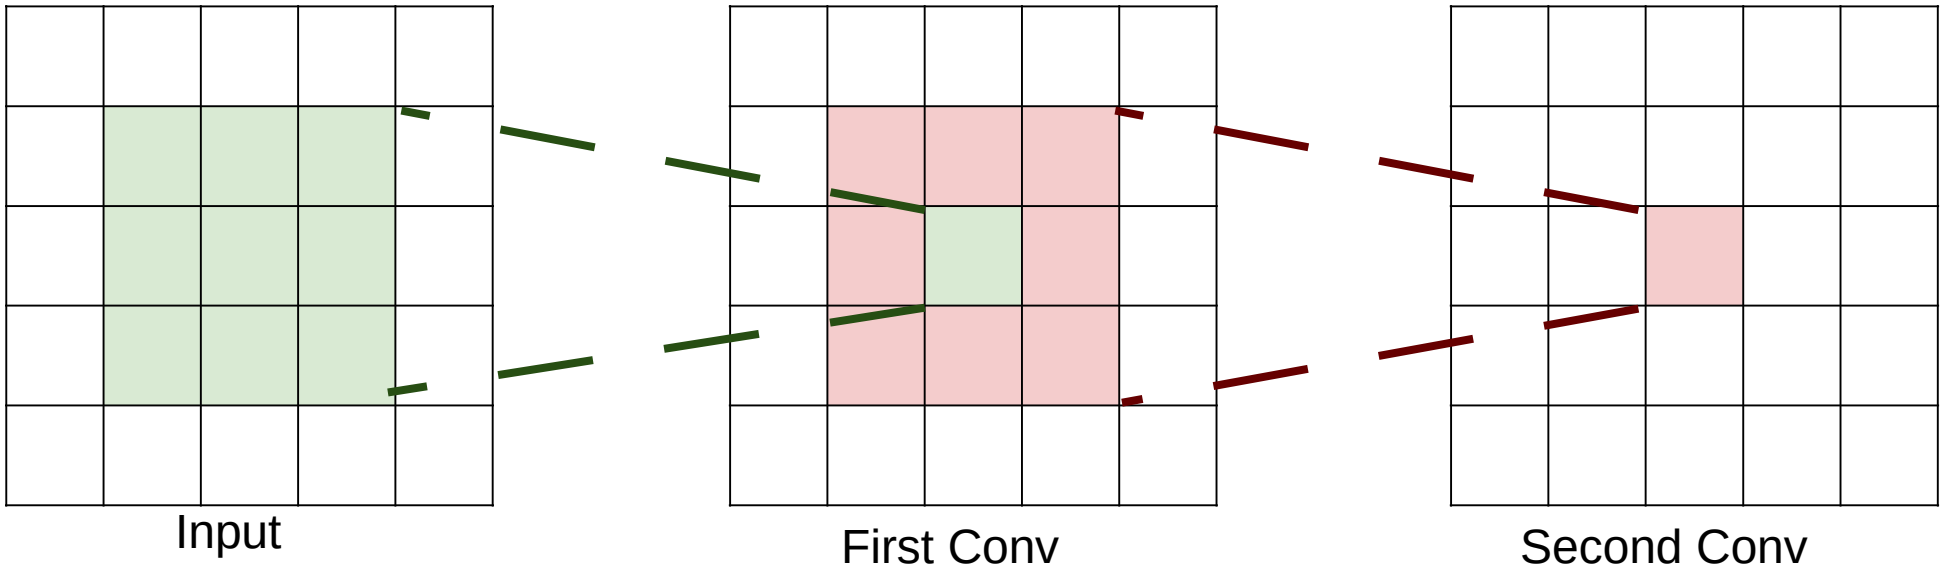

Преимущества маленьких сверток

Вопрос: какую область входа видит нейрон во втором сверточном слое?

Ответ: 5x5

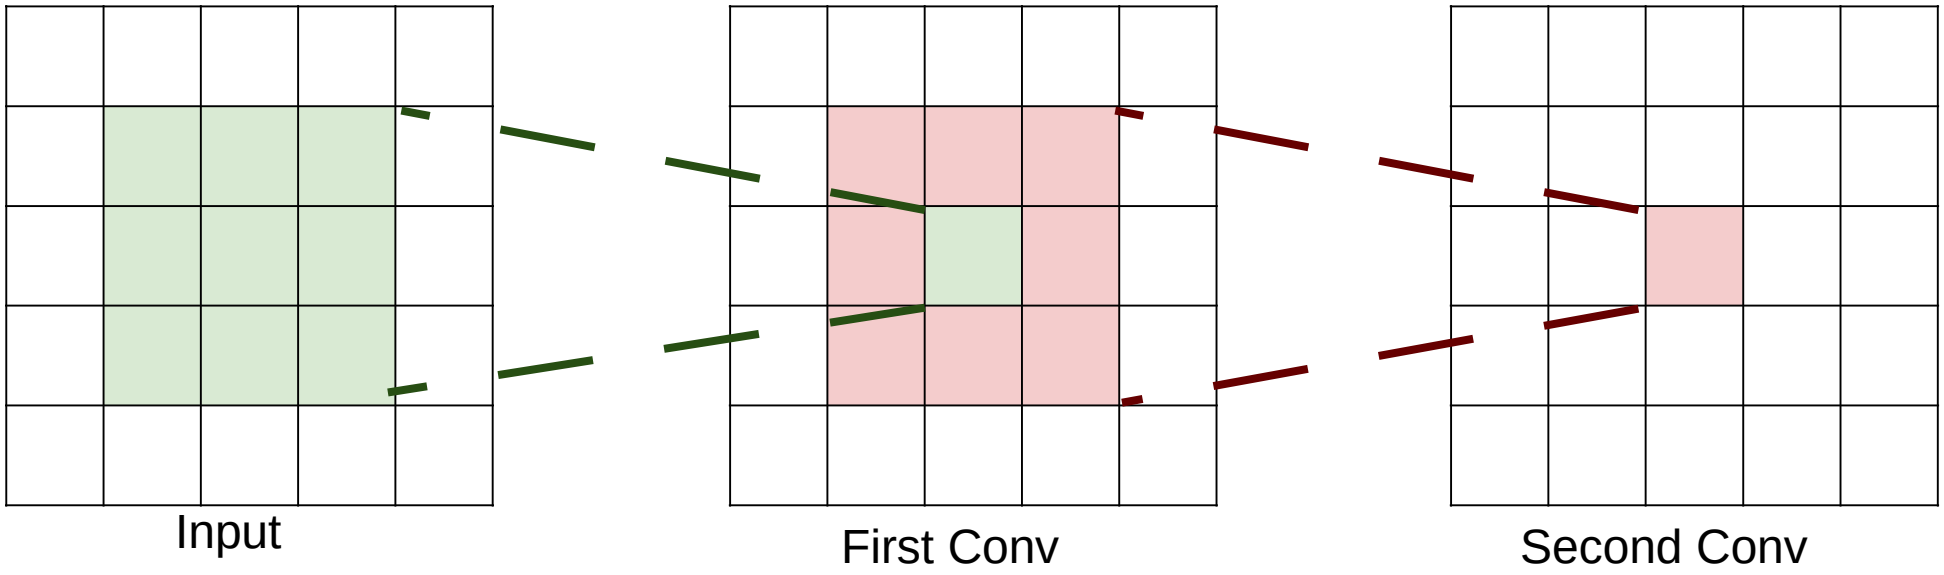

Преимущества маленьких сверток

Вопрос: если бы мы применили **три** свертки 3x3 stride 1, то какую бы область входа видел нейрон из последнего сверточного слоя?

Преимущества маленьких сверток

Вопрос: если бы мы применили **три** свертки 3x3 stride 1, то какую бы область входа видел нейрон из третьего сверточного слоя?

Ответ: 7x7

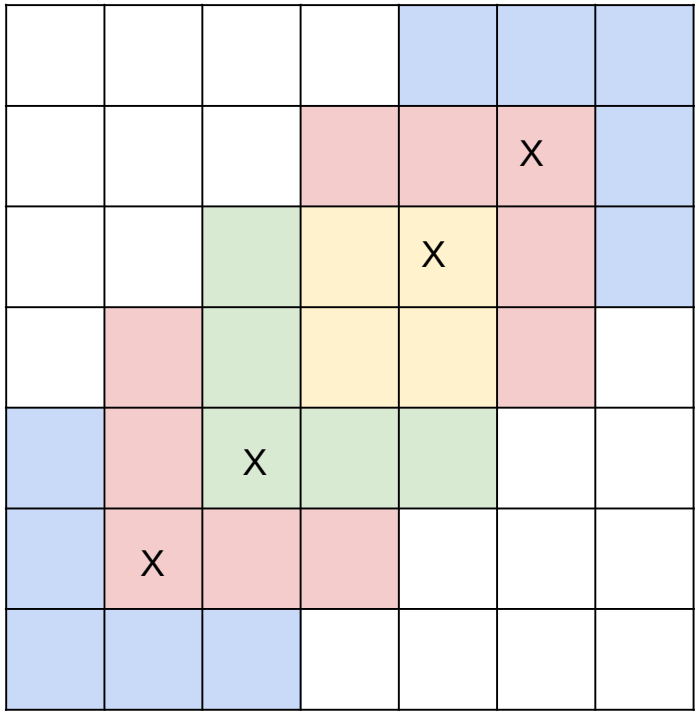

Три свертки 3x3 аналогичны свертке 7x7

Преимущества маленьких сверток

Пусть размер входа H x W x C и мы применяем C сверток для сохранения глубины (stride 1, padding такой, чтобы сохранить размеры H, W)

1 CONV with 7 x 7 filters

3 CONV with 3 x 3 filters

Преимущества маленьких сверток

Пусть размер входа H x W x C и мы применяем C сверток для сохранения глубины (stride 1, padding такой, чтобы сохранить размеры H, W)

1 CONV with 7 x 7 filters

Число параметров:

= C x (7 x 7 x C) = **49 C^2**

3 CONV with 3 x 3 filters

Число параметров:

= 3 x C x (3 x 3 x C) = **27 C^2**

Преимущества маленьких сверток

Пусть размер входа H x W x C и мы применяем C сверток для сохранения глубины (stride 1, padding такой, чтобы сохранить размеры H, W)

1 CONV with 7 x 7 filters

Число параметров:

= C x (7 x 7 x C) = **49 C^2**

3 CONV with 3 x 3 filters

Число параметров:

= 3 x C x (3 x 3 x C) = **27 C^2**

Меньше параметров, выше нелинейность!

Преимущества маленьких сверток

Пусть размер входа H x W x C и мы применяем C сверток для сохранения глубины (stride 1, padding такой, чтобы сохранить размеры H, W)

1 CONV with 7 x 7 filters

Число параметров:

$= C \times (7 \times 7 \times C) = 49\ C^2$

Число умножений и сложений:

3 CONV with 3 x 3 filters

Число параметров:

$= 3 \times C \times (3 \times 3 \times C) = 27\ C^2$

Число сложений и умножений:

Преимущества маленьких сверток

Пусть размер входа H x W x C и мы применяем C сверток для сохранения глубины (stride 1, padding такой, чтобы сохранить размеры H, W)

1 CONV with 7 x 7 filters

Число параметров:

= C x (7 x 7 x C) = 49 C^2

Число умножений и сложений:

= (H x W x C) x (7 x 7 x C)

= **49 HWC^2**

3 CONV with 3 x 3 filters

Число параметров:

= 3 x C x (3 x 3 x C) = 27 C^2

Число сложений и умножений:

= 3 x (H x W x C) x (3 x 3 x C)

= **27 HWC^2**

Преимущества маленьких сверток

Пусть размер входа H x W x C и мы применяем C сверток для сохранения глубины (stride 1, padding такой, чтобы сохранить размеры H, W)

1 CONV with 7 x 7 filters

Число параметров :

= C x (7 x 7 x C) = 49 C^2

Число умножений и сложений:

= (H x W x C) x (7 x 7 x C)

= **49 HWC^2**

3 CONV with 3 x 3 filters

Число параметров :

= 3 x C x (3 x 3 x C) = 27 C^2

Число сложений и умножений:

= 3 x (H x W x C) x (3 x 3 x C)

= **27 HWC^2**

Меньше вычислений, выше нелинейность!

Преимущества маленьких сверток

Как использовать свертки 1x1?

Преимущества маленьких сверток

Как использовать свертки 1x1?

H x W x C

CONV 1x1, C/2 filters

H x W x C/2

1. уменьшаем число каналов с помощью “bottleneck” 1 x 1 conv

Преимущества маленьких сверток

Как использовать свертки 1x1?

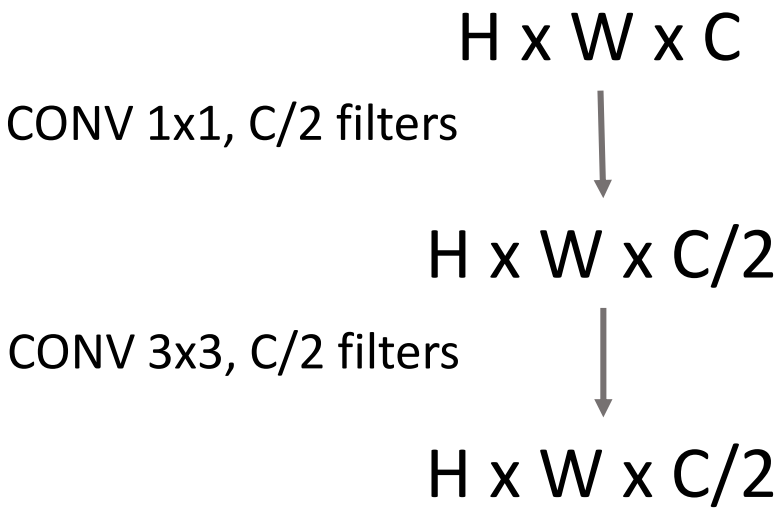

1. уменьшаем число каналов с помощью “bottleneck” 1 x 1 conv

2. применяем 3 x 3 conv

Преимущества маленьких сверток

Как использовать свертки 1x1?

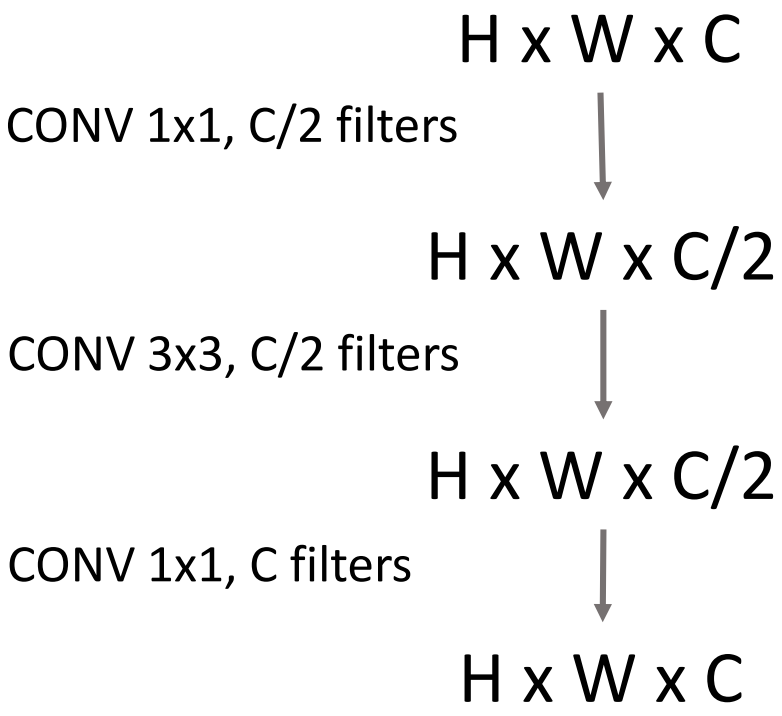

1. уменьшаем число каналов с помощью “bottleneck” 1 x 1 conv

2. применяем 3 x 3 conv

3. восстанавливаем число каналов с помощью 1 x 1 conv

Подобный подход использовался в GoogleNet, ResNet и подобным им сетям, например, DenseNet

Преимущества маленьких сверток

Как использовать свертки 1x1?

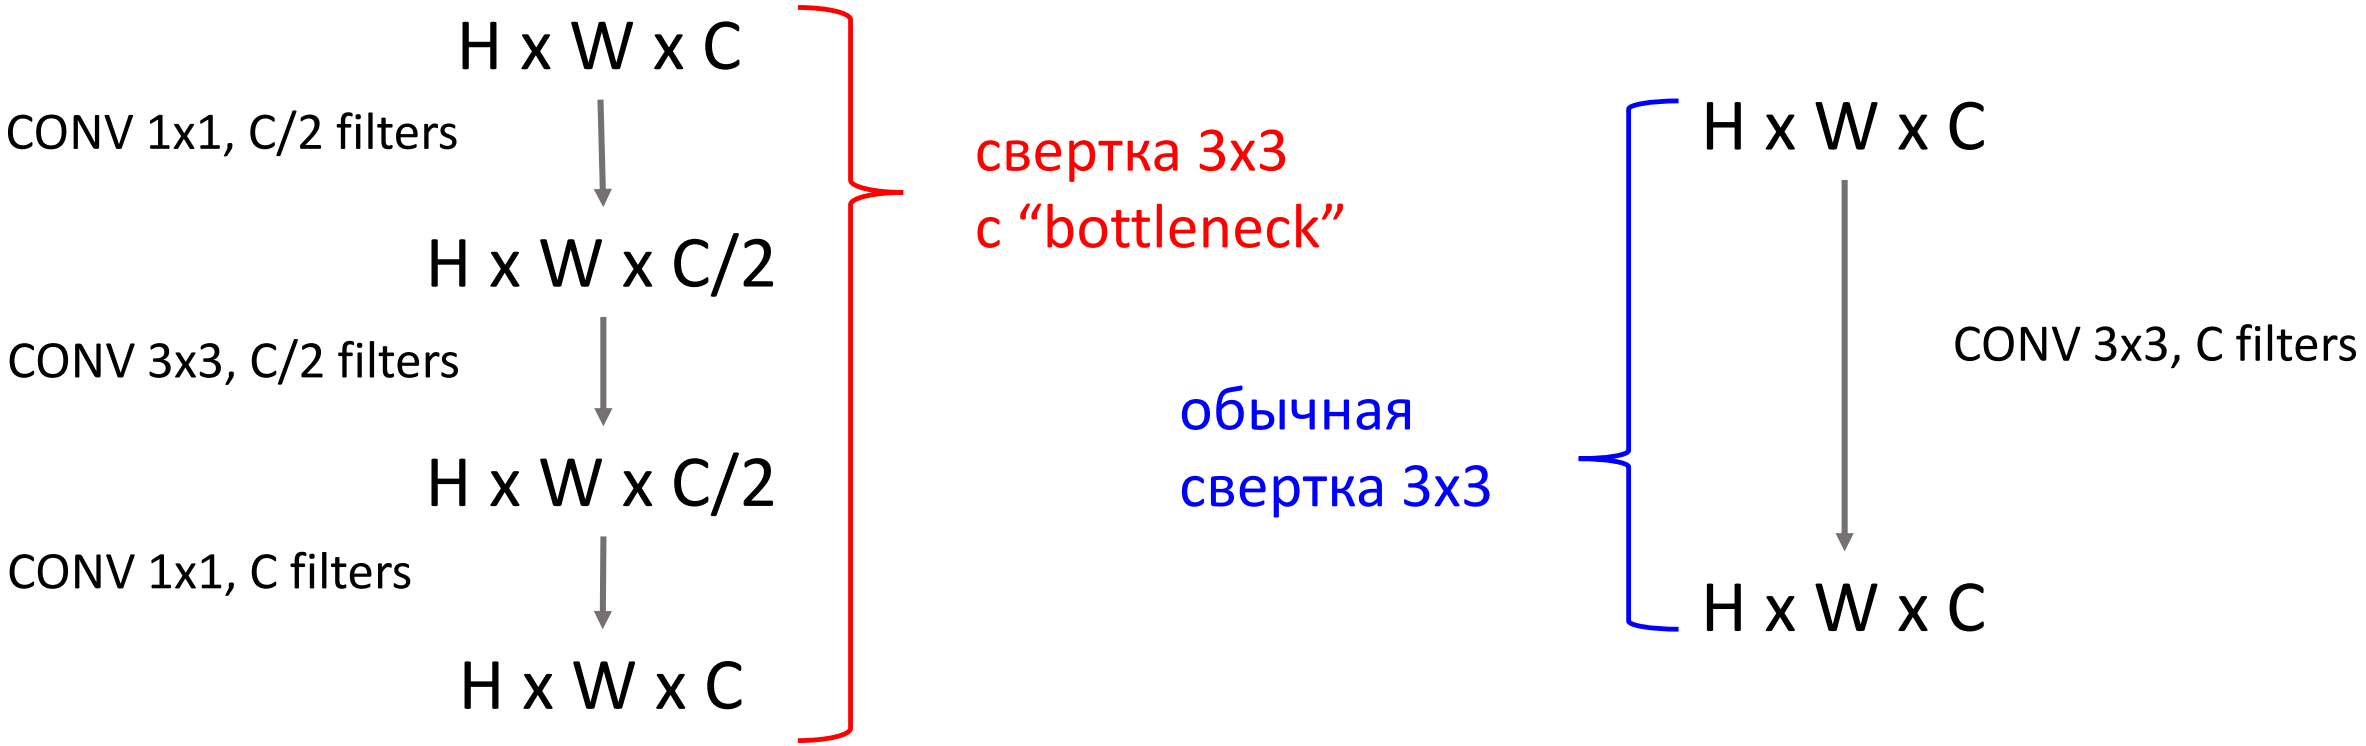

Преимущества маленьких сверток

Как использовать свертки 1x1?

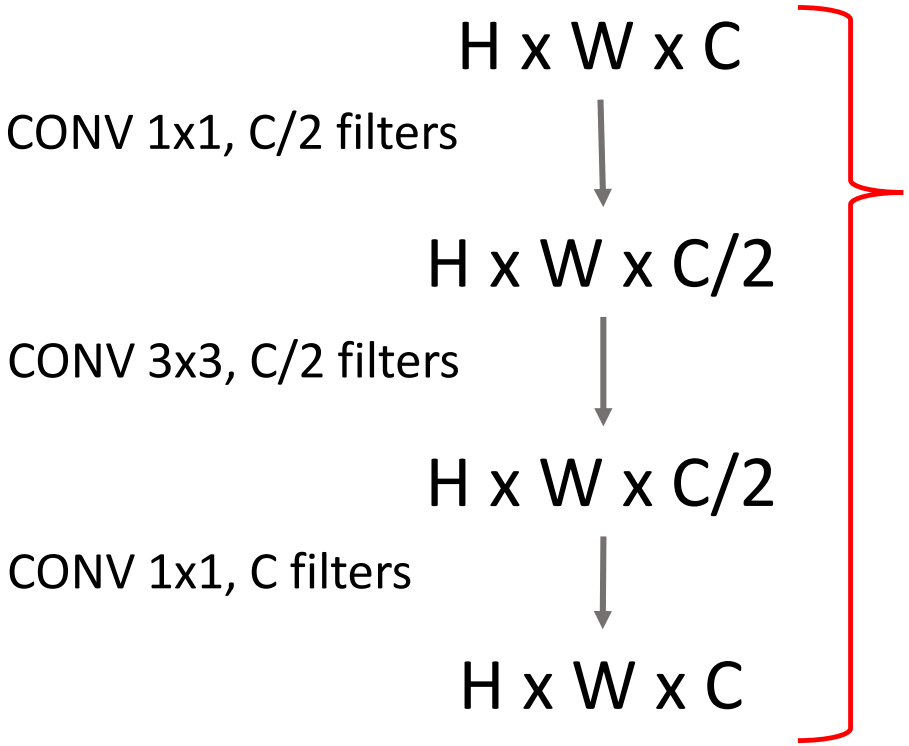

$3.25C^2$
параметров

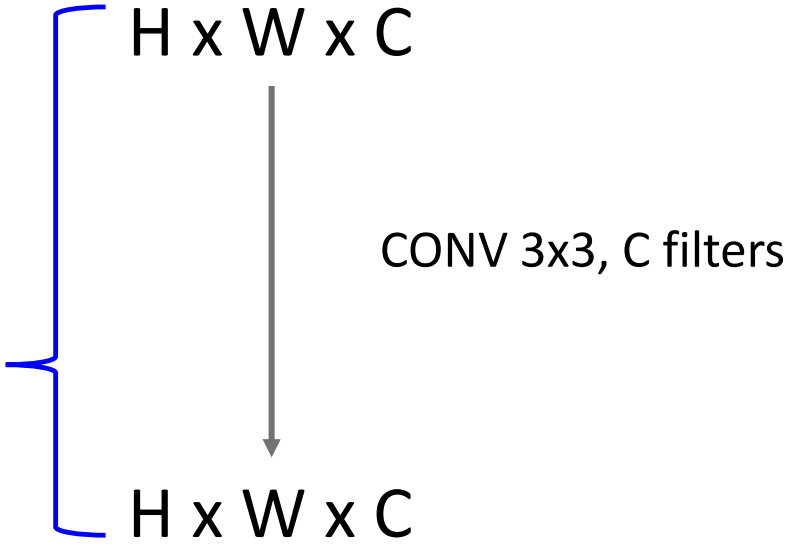

$9C^2$
параметров

Меньше параметров, меньше вычислений, выше нелинейность!

Преимущества маленьких сверток

Совсем избавиться от сверток 3x3 мы не можем.
Можем ли мы их упростить?

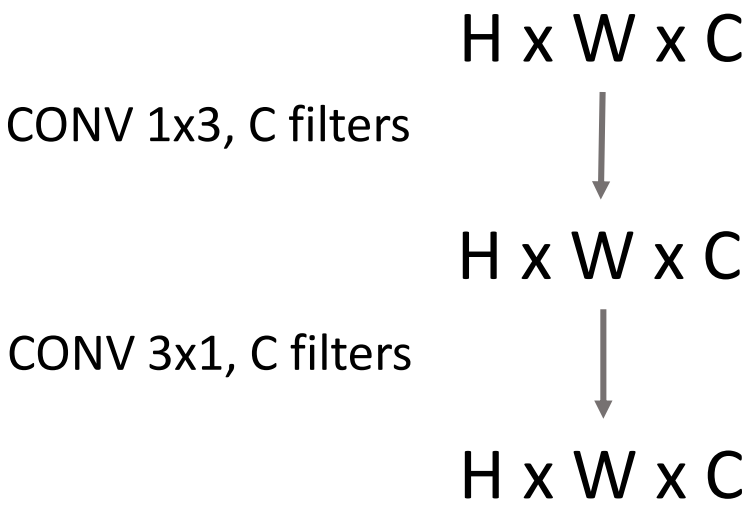

Преимущества маленьких сверток

Совсем избавиться от сверток 3x3 мы не можем.
Можем ли мы их упростить?

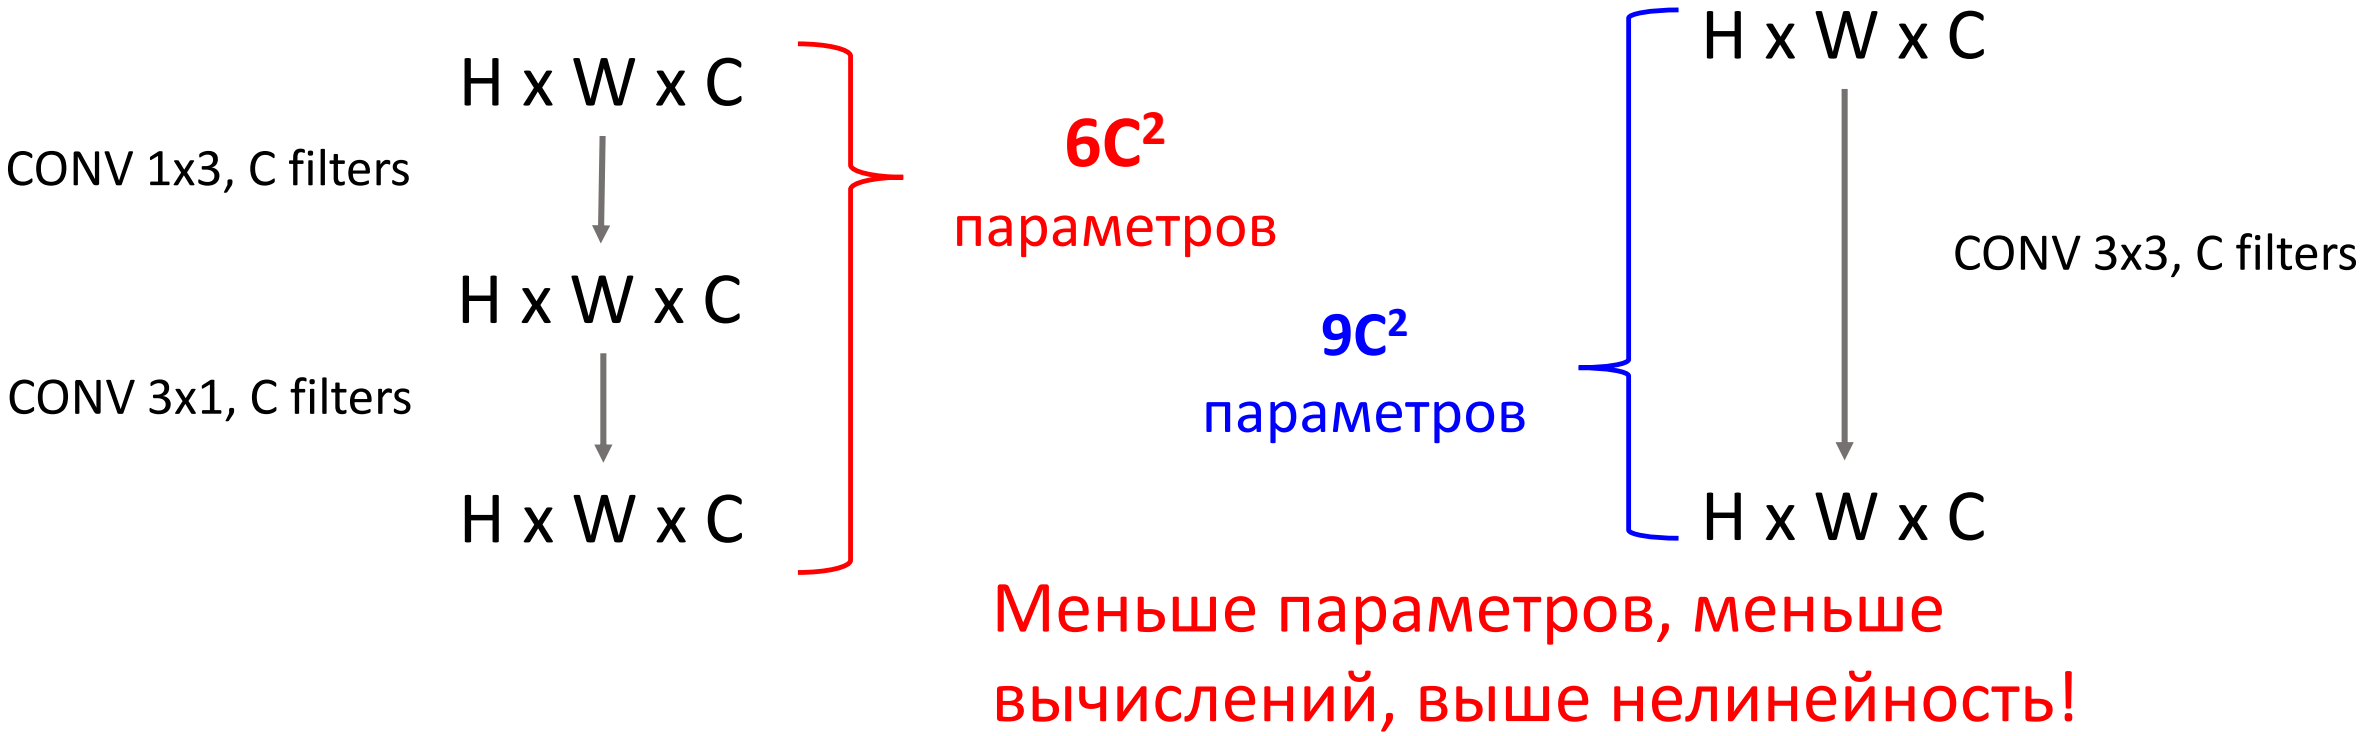

Меньше параметров, меньше вычислений, выше нелинейность!

Преимущества маленьких сверток

Inception v1
(GoogleNet)

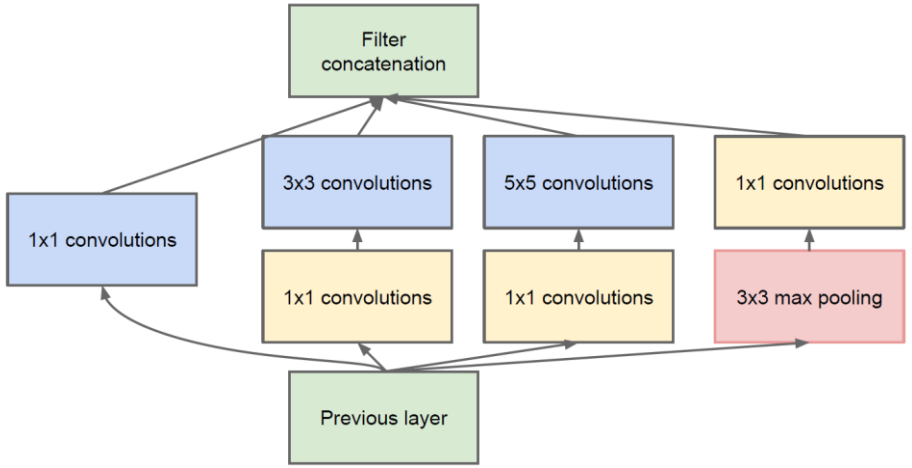

Inception v3

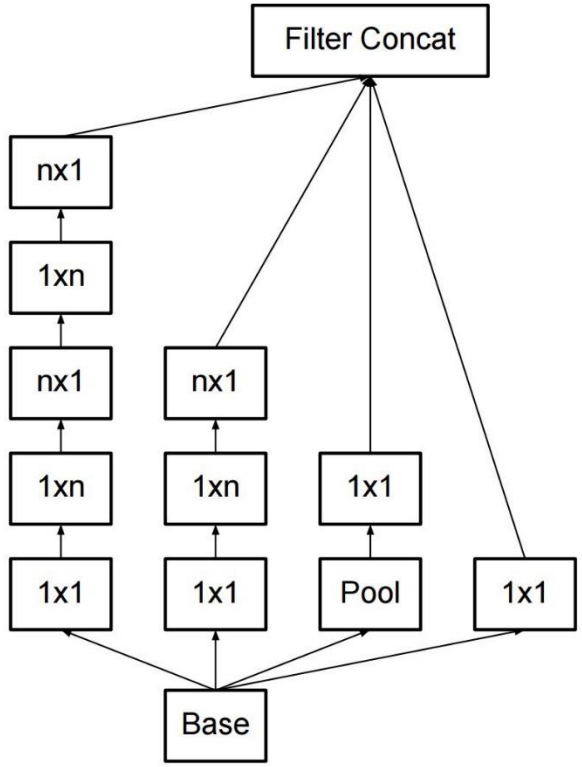

ResNet

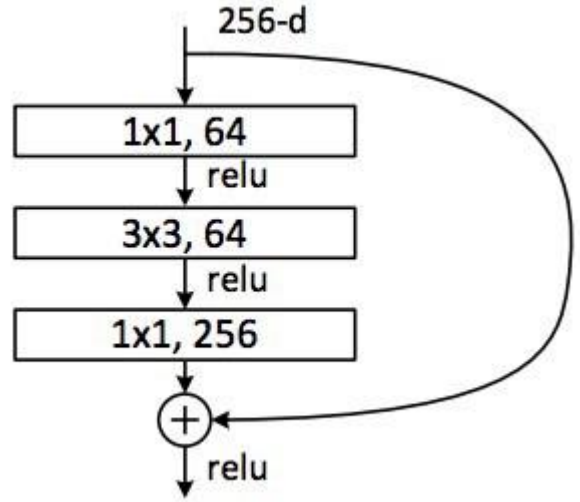

VGG

(Simonyan and Zisserman, 2014)

INPUT: [224x224x3] memory: 224*224*3=150K params: 0
CONV3-64: [224x224x64] memory: 224*224*64=3.2M params: (3*3*3)*64 = 1,728
CONV3-64: [224x224x64] memory: 224*224*64=3.2M params: (3*3*64)*64 = 36,864
POOL2: [112x112x64] memory: 112*112*64=800K params: 0
CONV3-128: [112x112x128] memory: 112*112*128=1.6M params: (3*3*64)*128 = 73,728
CONV3-128: [112x112x128] memory: 112*112*128=1.6M params: (3*3*128)*128 = 147,456
POOL2: [56x56x128] memory: 56*56*128=400K params: 0
…
…
CONV3-512: [14x14x512] memory: 14*14*512=100K params: (3*3*512)*512 = 2,359,296
CONV3-512: [14x14x512] memory: 14*14*512=100K params: (3*3*512)*512 = 2,359,296
CONV3-512: [14x14x512] memory: 14*14*512=100K params: (3*3*512)*512 = 2,359,296
POOL2: [7x7x512] memory: 7*7*512=25K params: 0
FC: [1x1x4096] memory: 4096 params: 7*7*512*4096 = 102,760,448
FC: [1x1x4096] memory: 4096 params: 4096*4096 = 16,777,216
FC: [1x1x1000] memory: 1000 params: 4096*1000 = 4,096,000

TOTAL memory: 24M * 4 bytes ≈ 96MB / image (only forward! ≈x2 for backward)
TOTAL params: 138M parameters

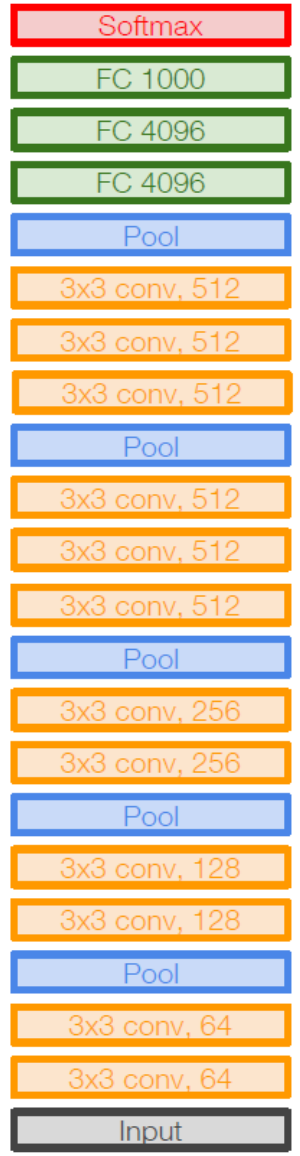

VGG16

VGG

(Simonyan and Zisserman, 2014)

INPUT: [224x224x3] memory: 224*224*3=150K params: 0
CONV3-64: [224x224x64] memory: **224*224*64=3.2M** params: (3*3*3)*64 = 1,728
CONV3-64: [224x224x64] memory: **224*224*64=3.2M** params: (3*3*64)*64 = 36,864
POOL2: [112x112x64] memory: 112*112*64=800K params: 0
CONV3-128: [112x112x128] memory: 112*112*128=1.6M params: (3*3*64)*128 = 73,728
CONV3-128: [112x112x128] memory: 112*112*128=1.6M params: (3*3*128)*128 = 147,456
POOL2: [56x56x128] memory: 56*56*128=400K params: 0
…
…
CONV3-512: [14x14x512] memory: 14*14*512=100K params: (3*3*512)*512 = 2,359,296
CONV3-512: [14x14x512] memory: 14*14*512=100K params: (3*3*512)*512 = 2,359,296
CONV3-512: [14x14x512] memory: 14*14*512=100K params: (3*3*512)*512 = 2,359,296
POOL2: [7x7x512] memory: 7*7*512=25K params: 0
FC: [1x1x4096] memory: 4096 params: 7*7*512*4096 = **102,760,448**
FC: [1x1x4096] memory: 4096 params: 4096*4096 = 16,777,216
FC: [1x1x1000] memory: 1000 params: 4096*1000 = 4,096,000

TOTAL memory: 24M * 4 bytes ≈ 96MB / image (only forward! ≈x2 for backward)
TOTAL params: 138M parameters

Самые большие расходы памяти в первых сверточных слоях

Больше всего параметров в выходных полно-связанных слоях

VGG

(Simonyan and Zisserman, 2014)

Особенности:

- ImageNet’14 в классификации 2-е место, в локализации 1-е
- процедура тренировки аналогична AlexNet
- признаки из fc7 слоя хорошо подходят для решения задач компьютерного зрения
- VGG16, ≈ 140 млн. параметров, ≈ 530 Мбайт caffemodel

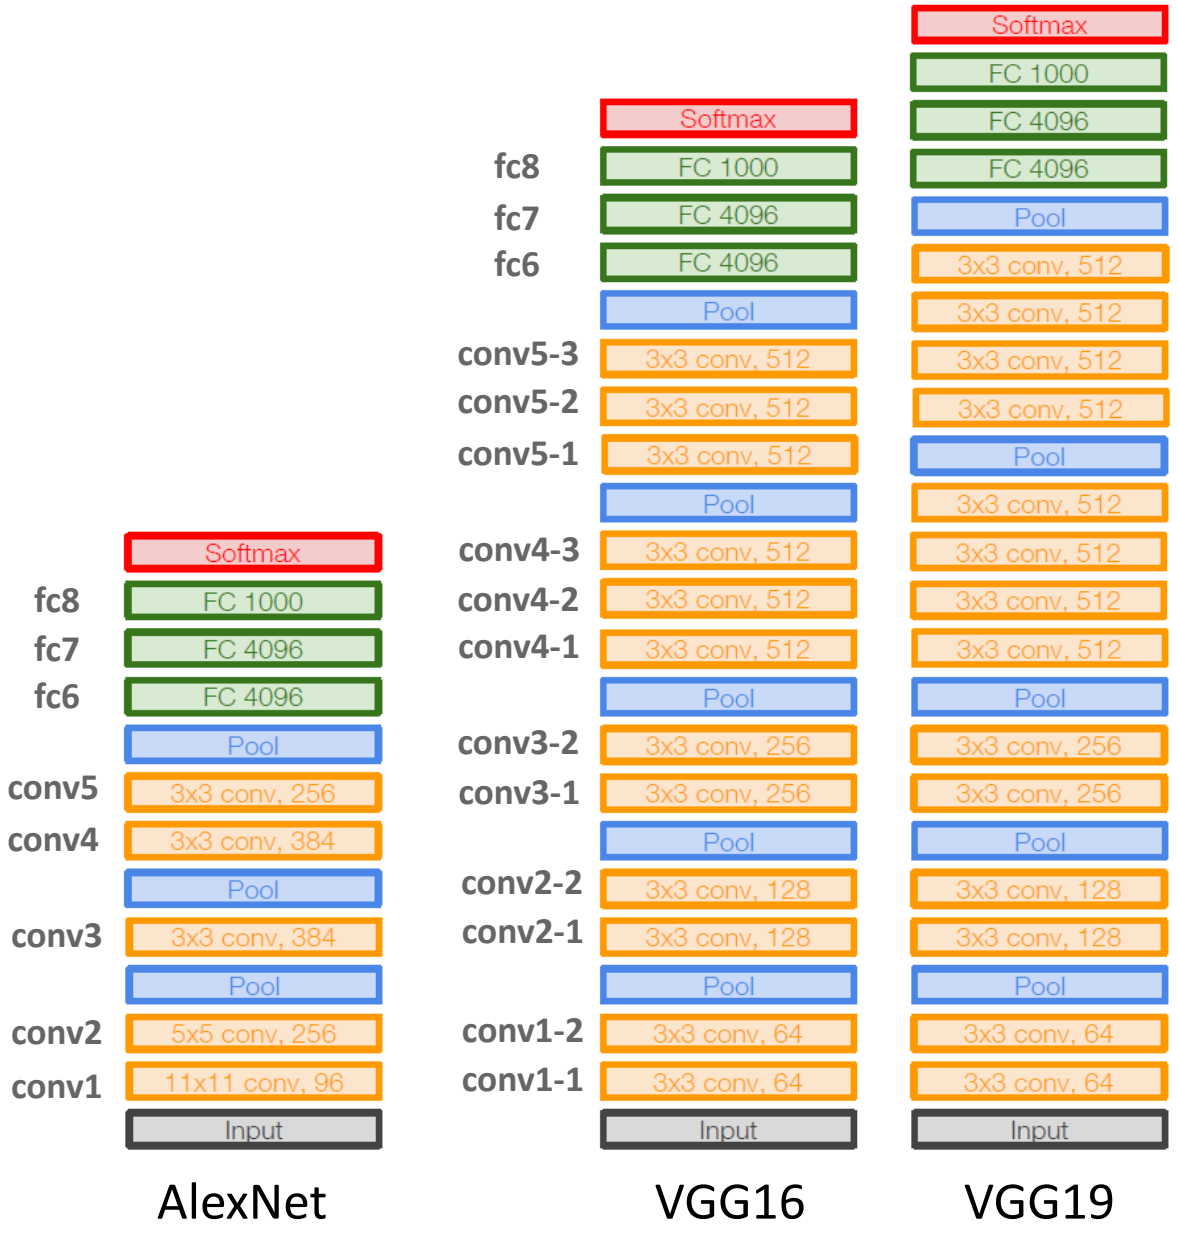

IMAGENET Large Scale Visual Recognition Challenge (ILSVRC)

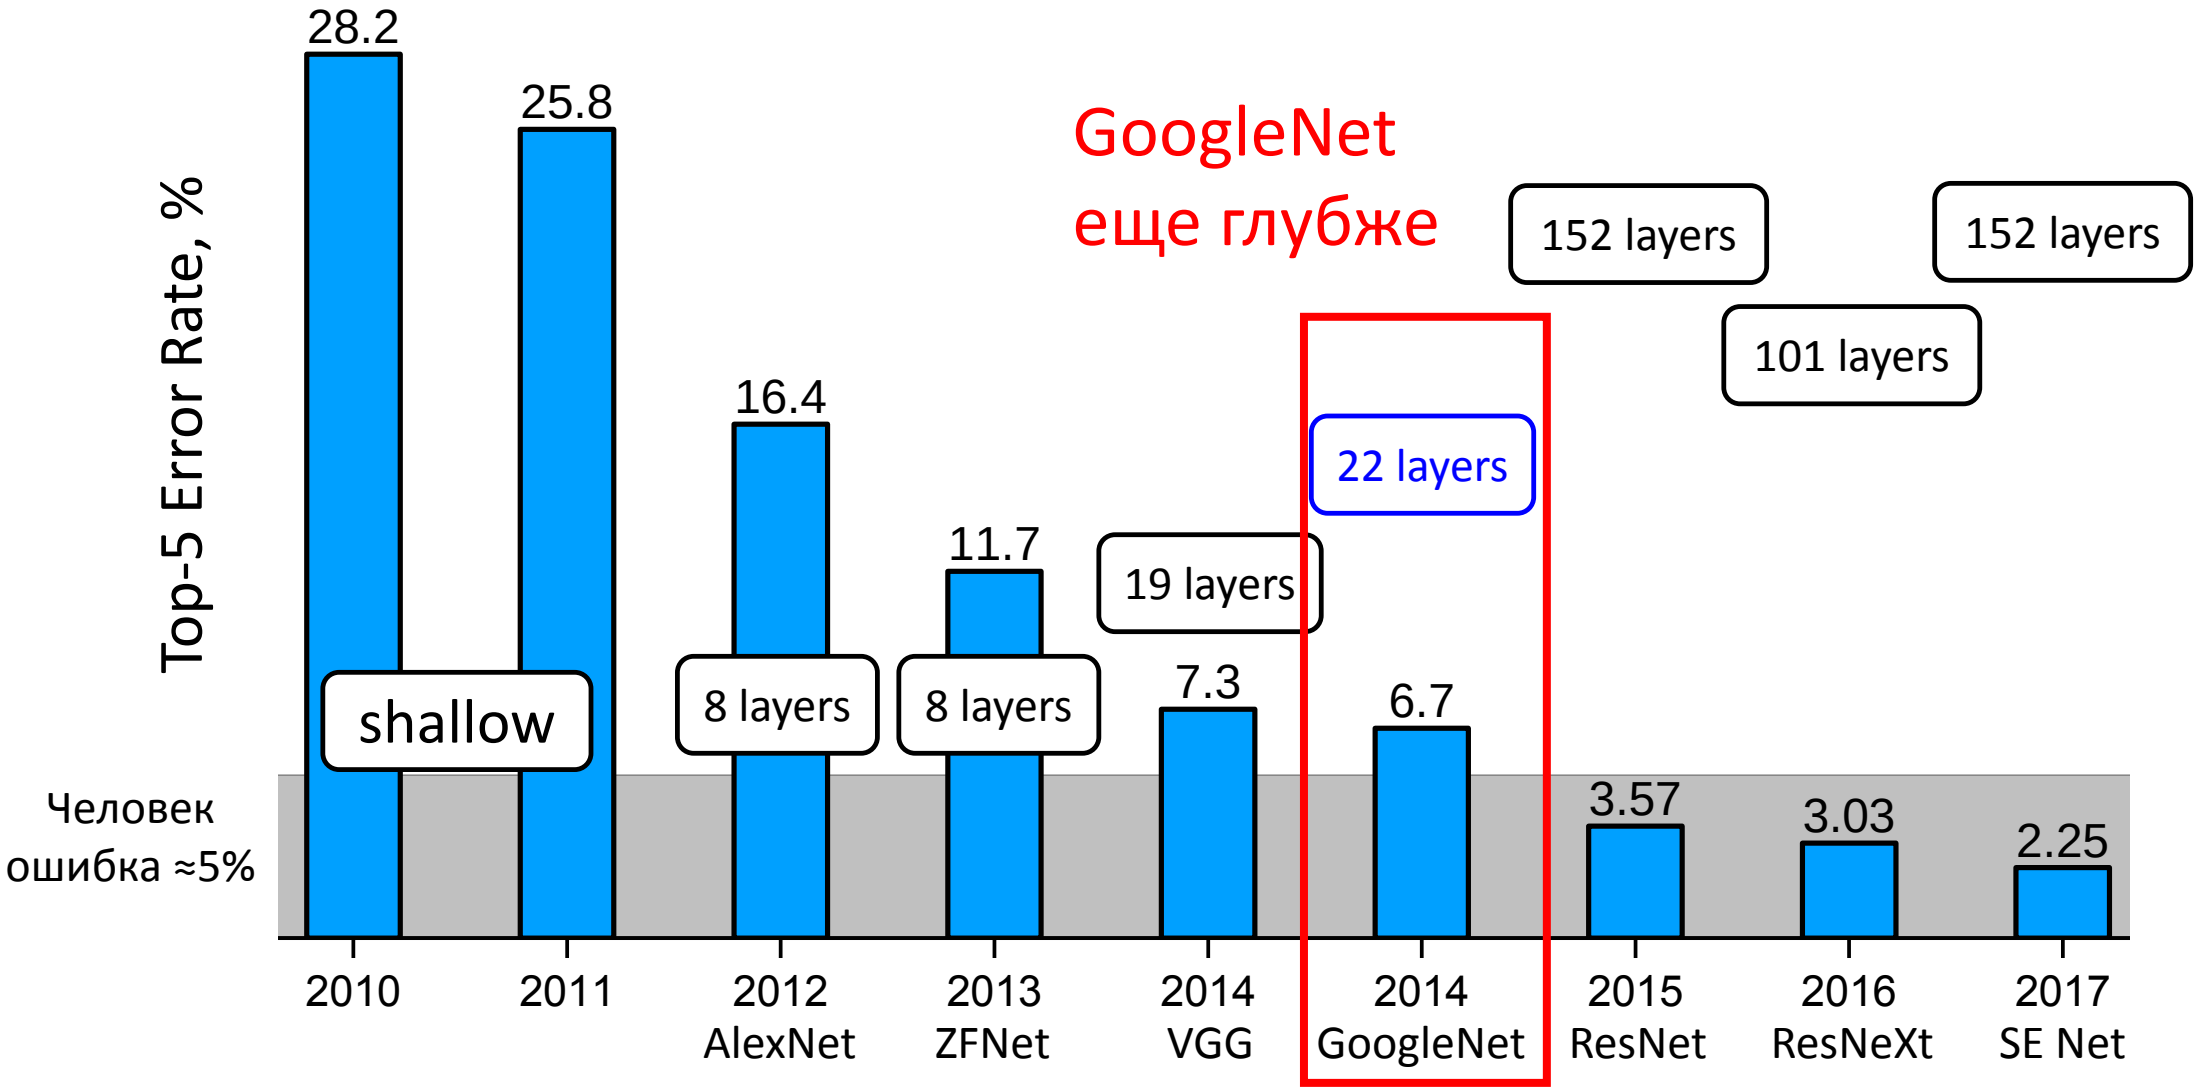

GoogleNet

(Szegedy et al., 2014)

Еще глубже, оптимизированная архитектура для высокой скорости вычислений

Особенности:

- победитель ImageNet’14 в классификации
- 22 слоя
- 9 Inception модулей
- нет полно-связанных слоев (AVE POOL)
- ≈ 5 млн. параметров, в 12 раз меньше, чем в AlexNet и в 2 раза меньше вычислений!
  ≈ 50 Мбайт caffemodel

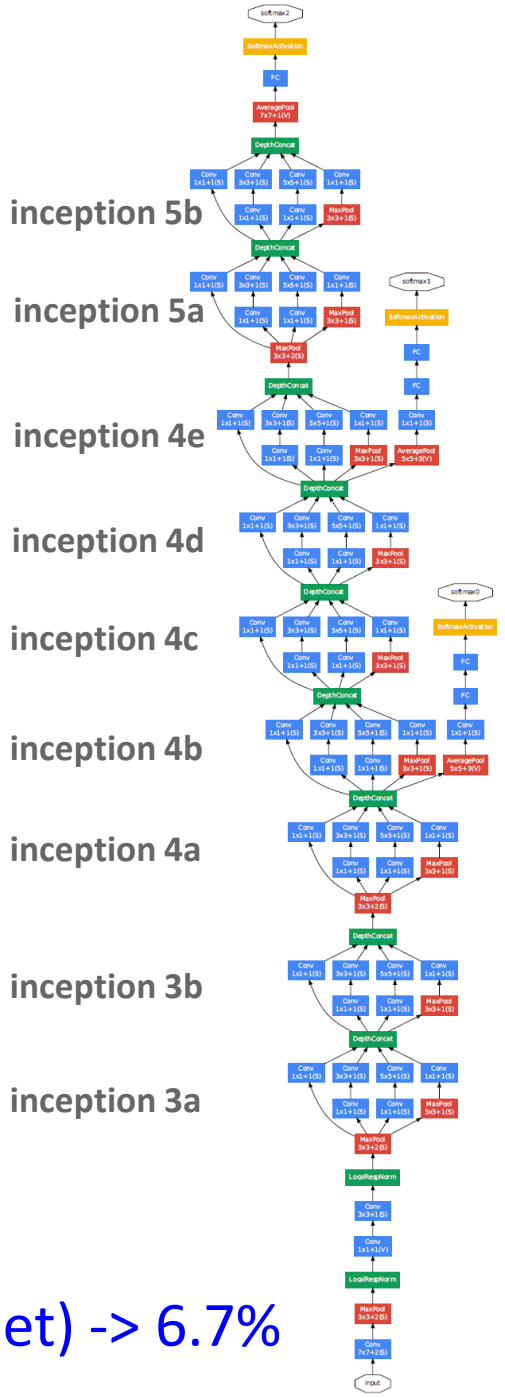

ImageNet top 5 error: 11.7% (ZFNet) -> 6.7%

GoogleNet

(Szegedy et al., 2014)

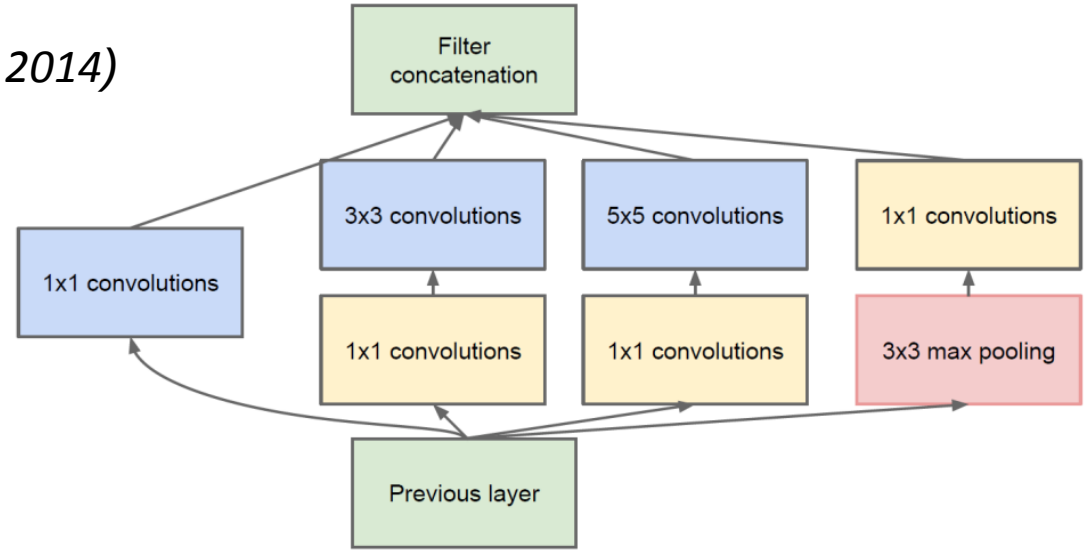

Inception модуль

- 4 канала: свертки 1x1, 3x3, 5x5 и MAX POOL
- свертки 1x1, 3x3, 5x5
  - кластеризуют нейроны с коррелирующими активациями, выше разреженность активаций
  - обработка разных пространственных масштабов
- “bottleneck” уменьшает сложность вычислений

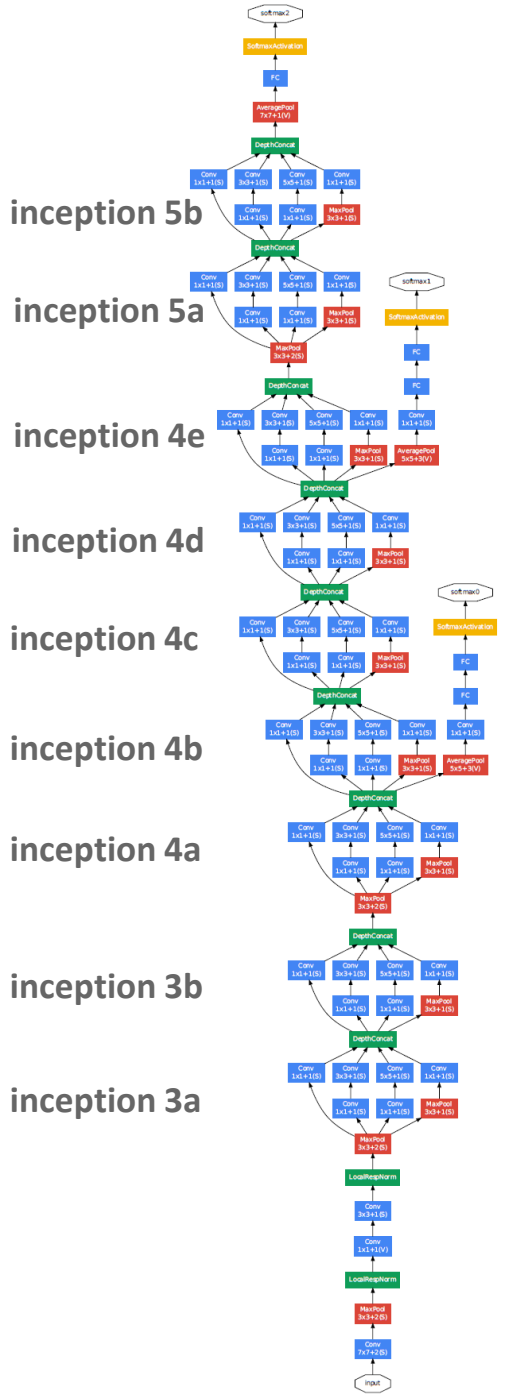

GoogleNet

(Szegedy et al., 2014)

Архитектура GoogleNet

type	patch size/ stride	output size	depth	#1×1	#3×3 reduce	#3×3	#5×5 reduce	#5×5	pool proj	params	ops
convolution	7×7/2	112×112×64	1							2.7K	34M
max pool	3×3/2	56×56×64	0								
convolution	3×3/1	56×56×192	2		64	192				112K	360M
max pool	3×3/2	28×28×192	0								
inception (3a)		28×28×256	2	64	96	128	16	32	32	159K	128M
inception (3b)		28×28×480	2	128	128	192	32	96	64	380K	304M
max pool	3×3/2	14×14×480	0								
inception (4a)		14×14×512	2	192	96	208	16	48	64	364K	73M
inception (4b)		14×14×512	2	160	112	224	24	64	64	437K	88M
inception (4c)		14×14×512	2	128	128	256	24	64	64	463K	100M
inception (4d)		14×14×528	2	112	144	288	32	64	64	580K	119M
inception (4e)		14×14×832	2	256	160	320	32	128	128	840K	170M
max pool	3×3/2	7×7×832	0								
inception (5a)		7×7×832	2	256	160	320	32	128	128	1072K	54M
inception (5b)		7×7×1024	2	384	192	384	48	128	128	1388K	71M
avg pool	7×7/1	1×1×1024	0								
dropout (40%)		1×1×1024	0								
linear		1×1×1000	1							1000K	1M
softmax		1×1×1000	0								

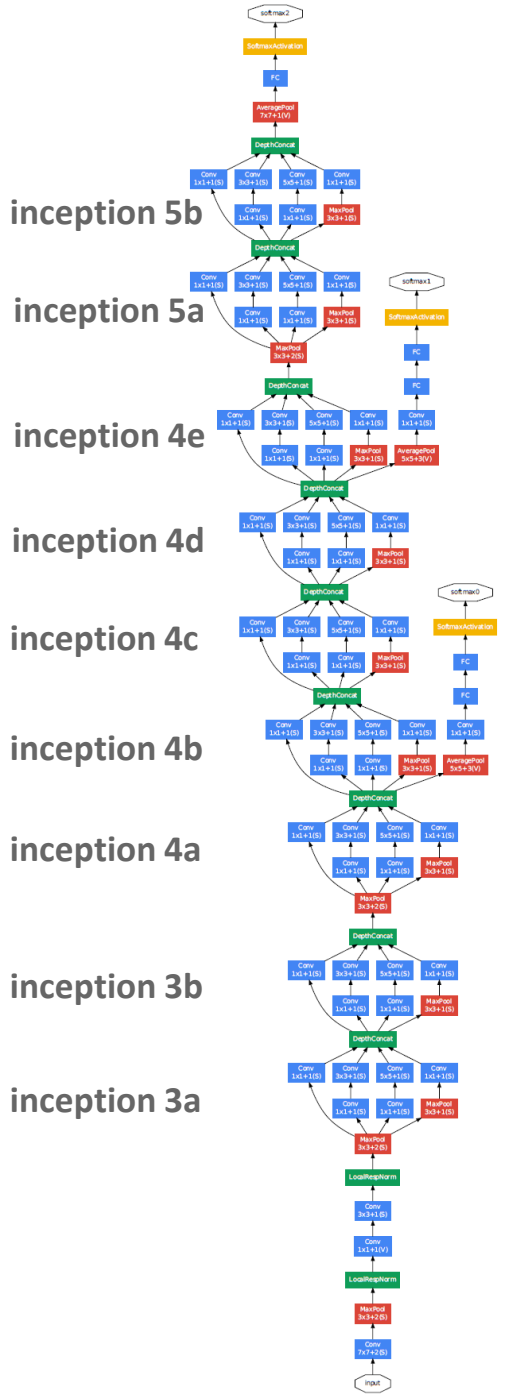

IMAGENET Large Scale Visual Recognition Challenge (ILSVRC)

Революция глубоких сетей.
ResNet 152 слоя!

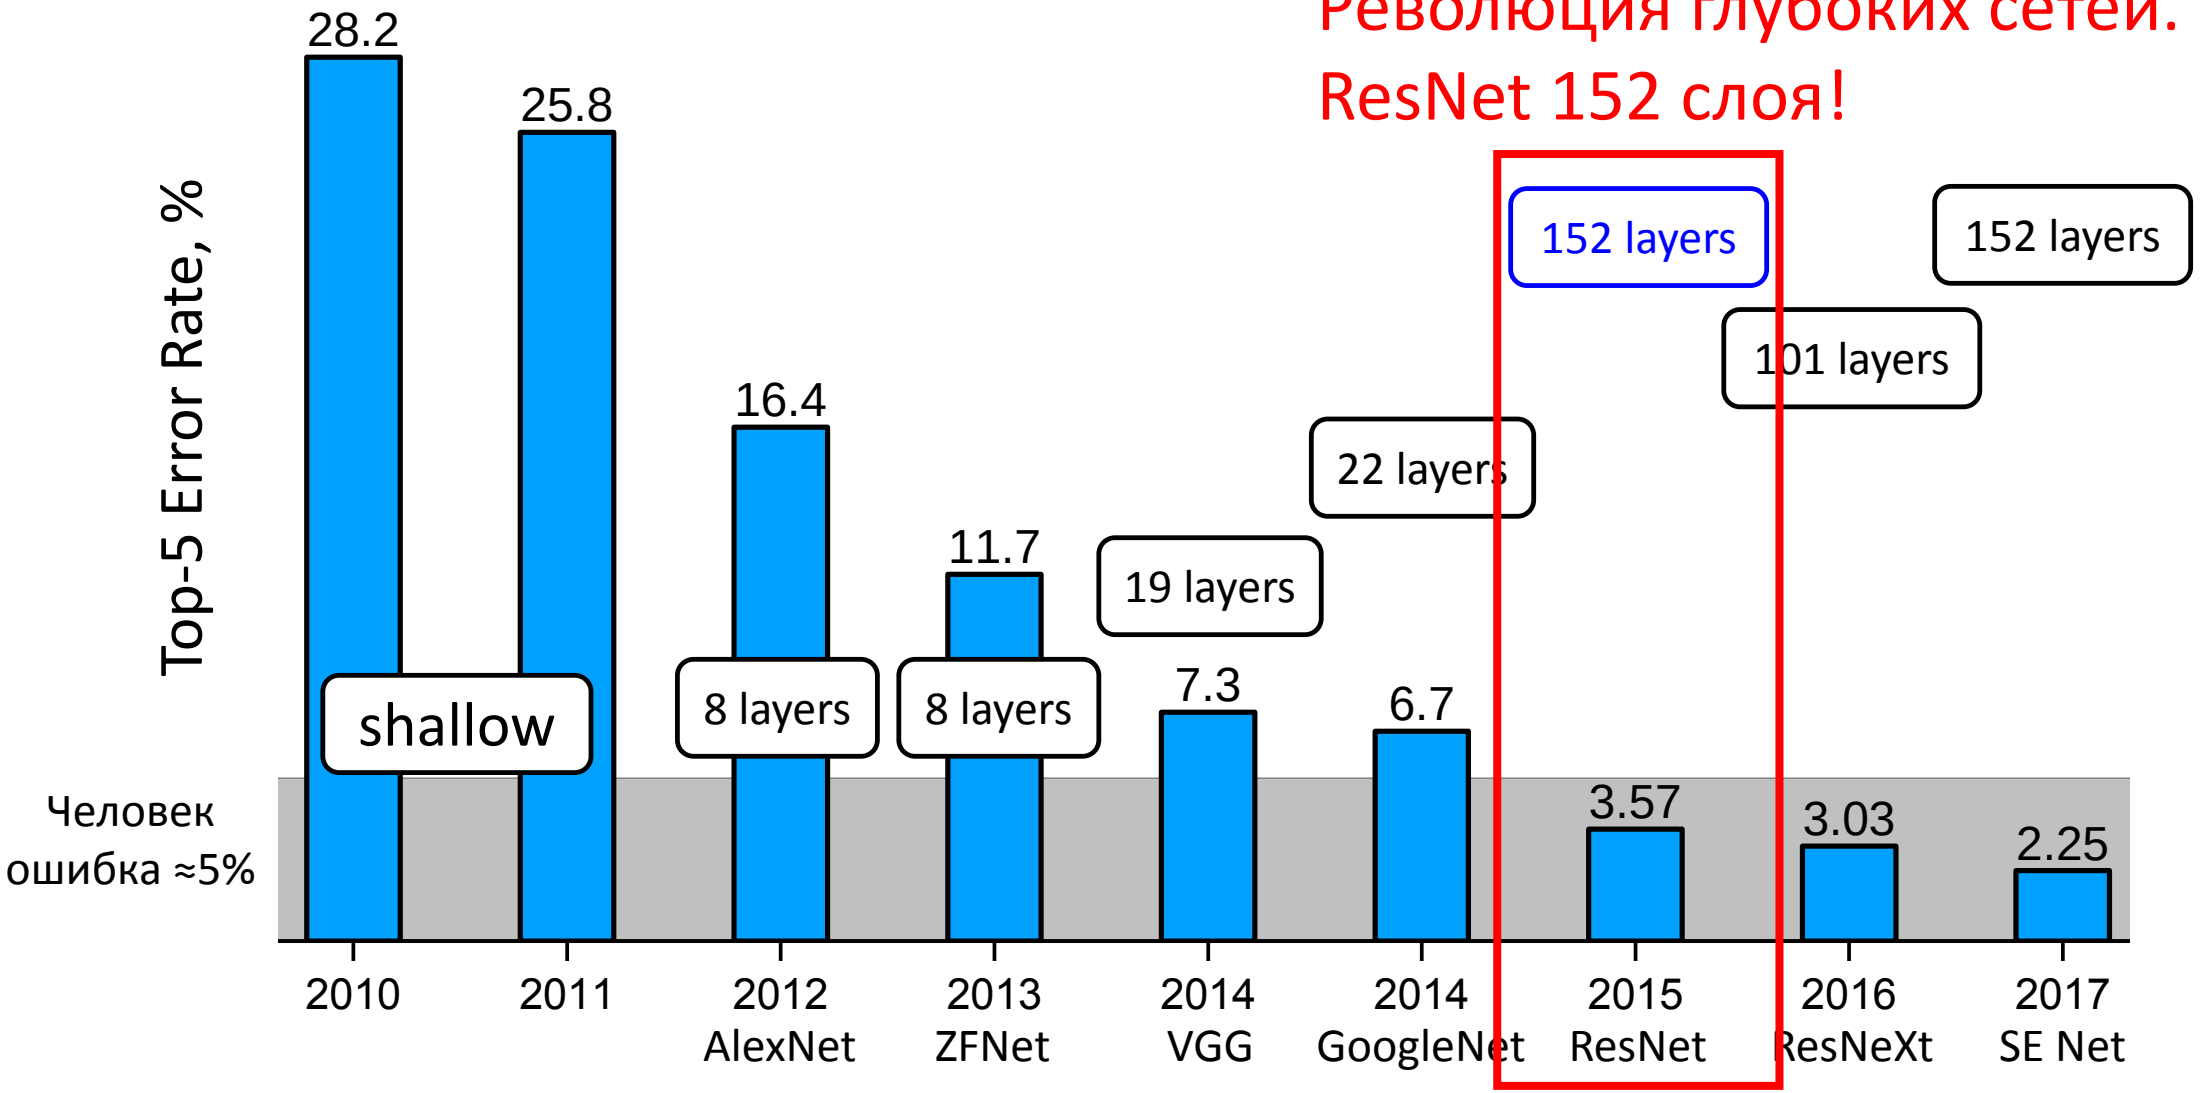

ResNet

(He et al., 2015)

Очень глубокая сеть за счет остаточных соединений (residual connections)

152 слоя в моделях для ImageNet’15

Победитель в классификации, детекции и сегментации в конкурсах ImageNet’15 и COCO’15

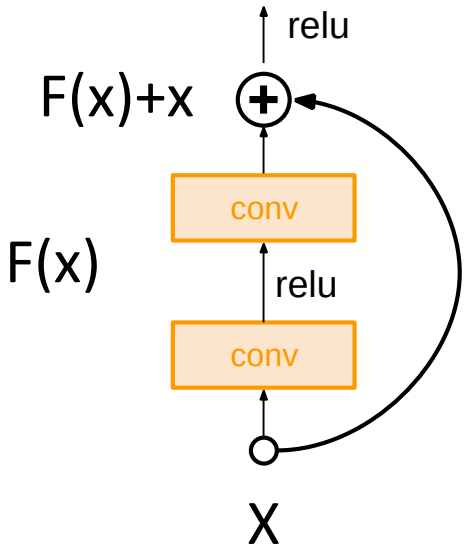

X

единичное отображение

Residual Block
(остаточный блок)

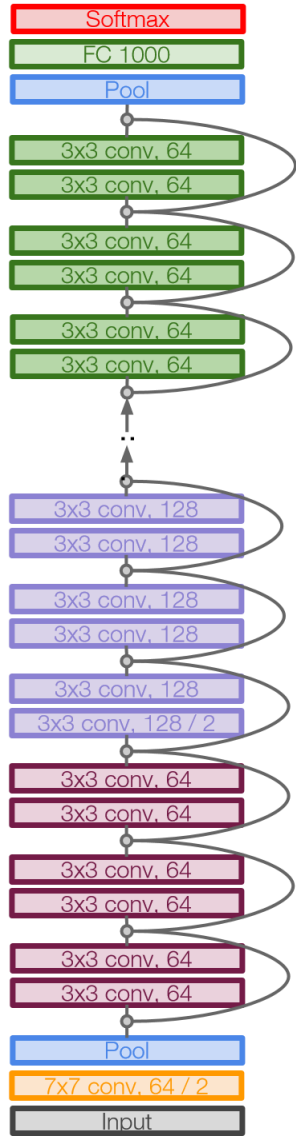

ImageNet top 5 error: 6.7% (GoogleNet) -> 3.57% - **точнее человека** (≈5%)!

ResNet

(He et al., 2015)

Графики ошибки на CIFAR-10 в зависимости от глубины обычной нейронной сети
[[CONV-ReLu]xN - [POOL]]xM

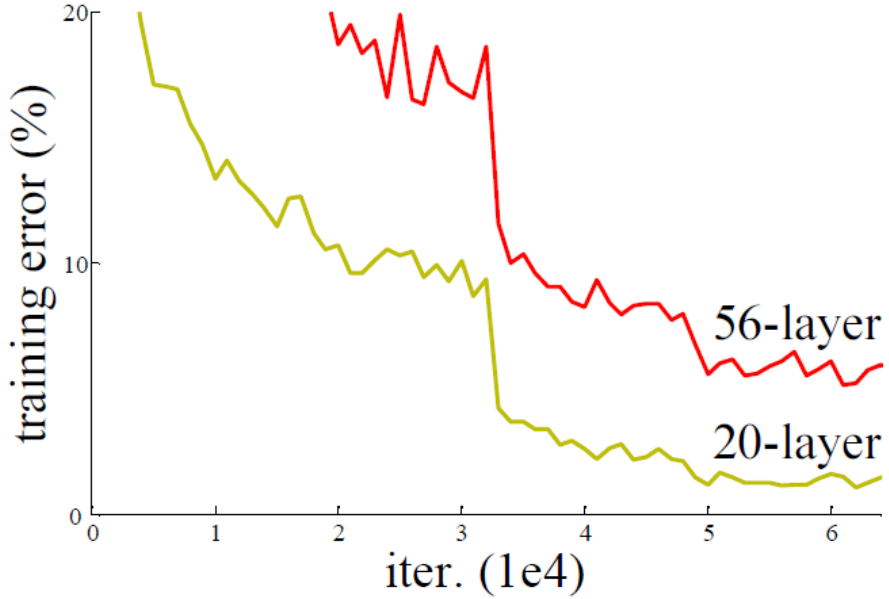

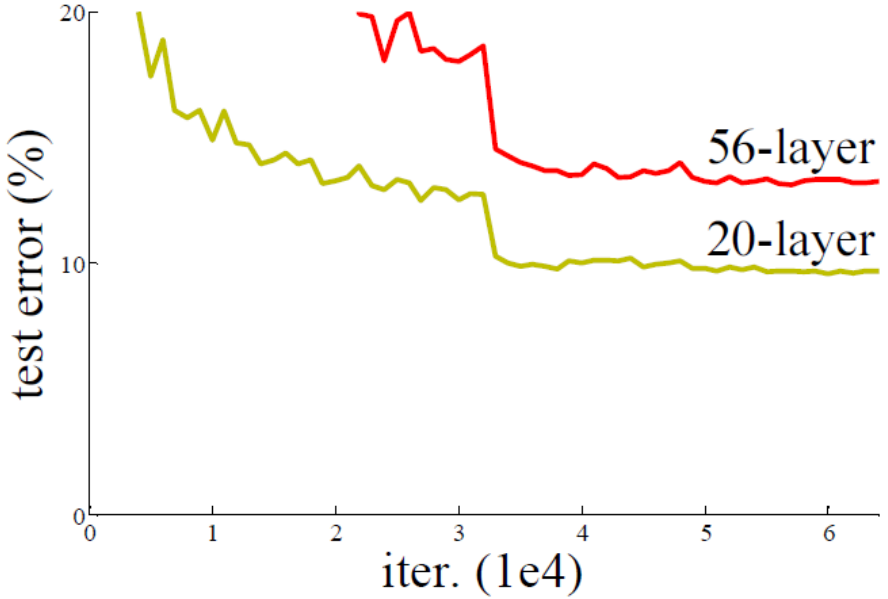

Вопрос: что странного в этих графиках ошибки на Train и Test данных?

ResNet

(He et al., 2015)

Графики ошибки на CIFAR-10 в зависимости от глубины обычной нейронной сети
[[CONV-ReLu]xN - [POOL]]xM

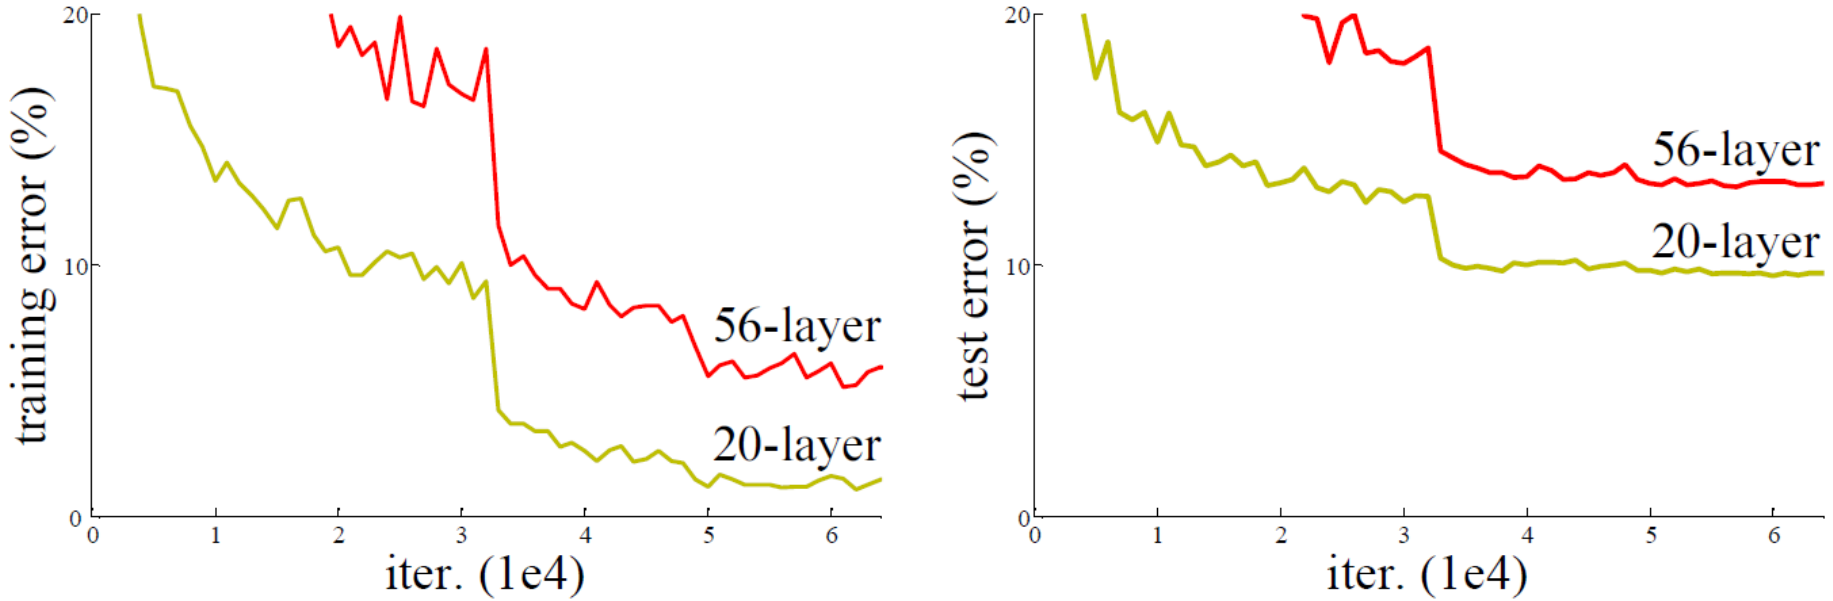

Вопрос: что странного в этих графиках ошибки на Train и Test данных?

Точность падает с ростом глубины, и это не связано с переобучением!

ResNet

(He et al., 2015)

Идея: проблема падения точности с ростом глубины сетей – проблема *оптимизации*

ResNet

(He et al., 2015)

Идея: проблема падения точности с ростом глубины сетей – проблема *оптимизации*

Мы хотим, чтобы более глубокие сети имели точность не хуже, чем неглубокие.

Как построить такую глубокую сеть?
Очевидное решение методом построения: взять неглубокую сеть и добавить слои, которые копируют вход (identity mapping)

ResNet

(He et al., 2015)

Решение: учим нейронную сеть для нахождения добавки/остатка к единичному отображению, вместо вычисления самого отображения

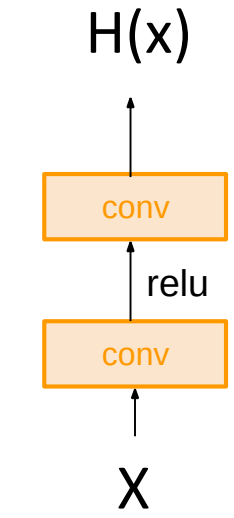

“Plain” layers

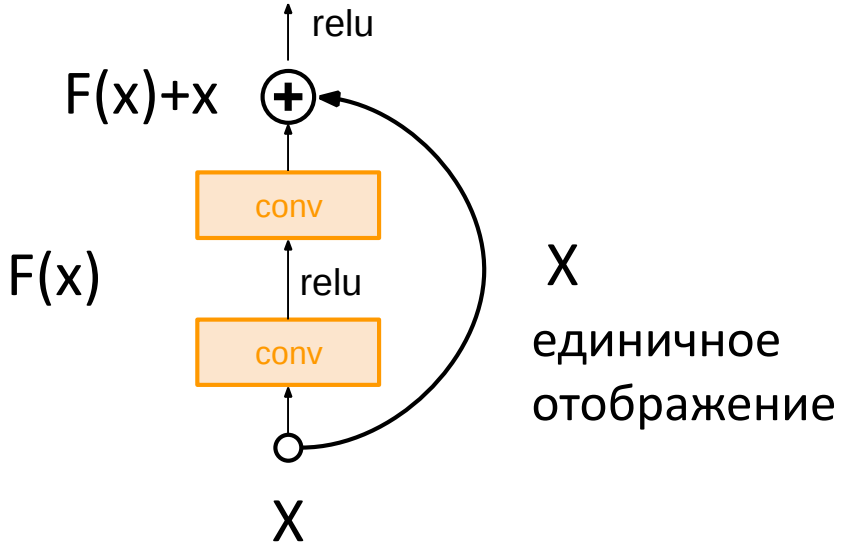

Residual Block

ResNet

(He et al., 2015)

Решение: учим нейронную сеть для нахождения добавки/остатка к единичному отображению, вместо вычисления самого отображения

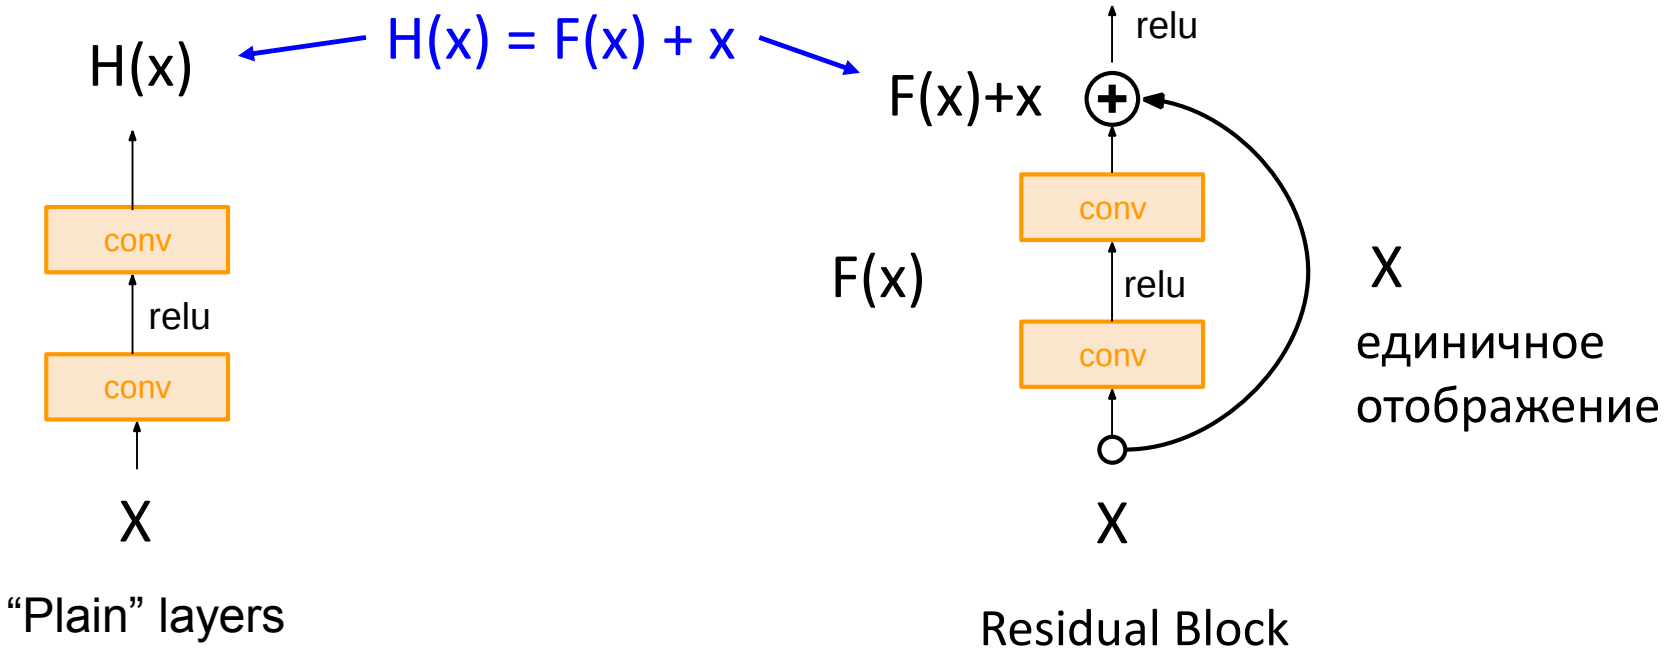

Используем слои сети для определения F(x) = H(x) - x вместо H(x)

ResNet

(He et al., 2015)

Пример архитектуры ResNet-34

- Стэк из residual blocks (2 CONV 3x3)

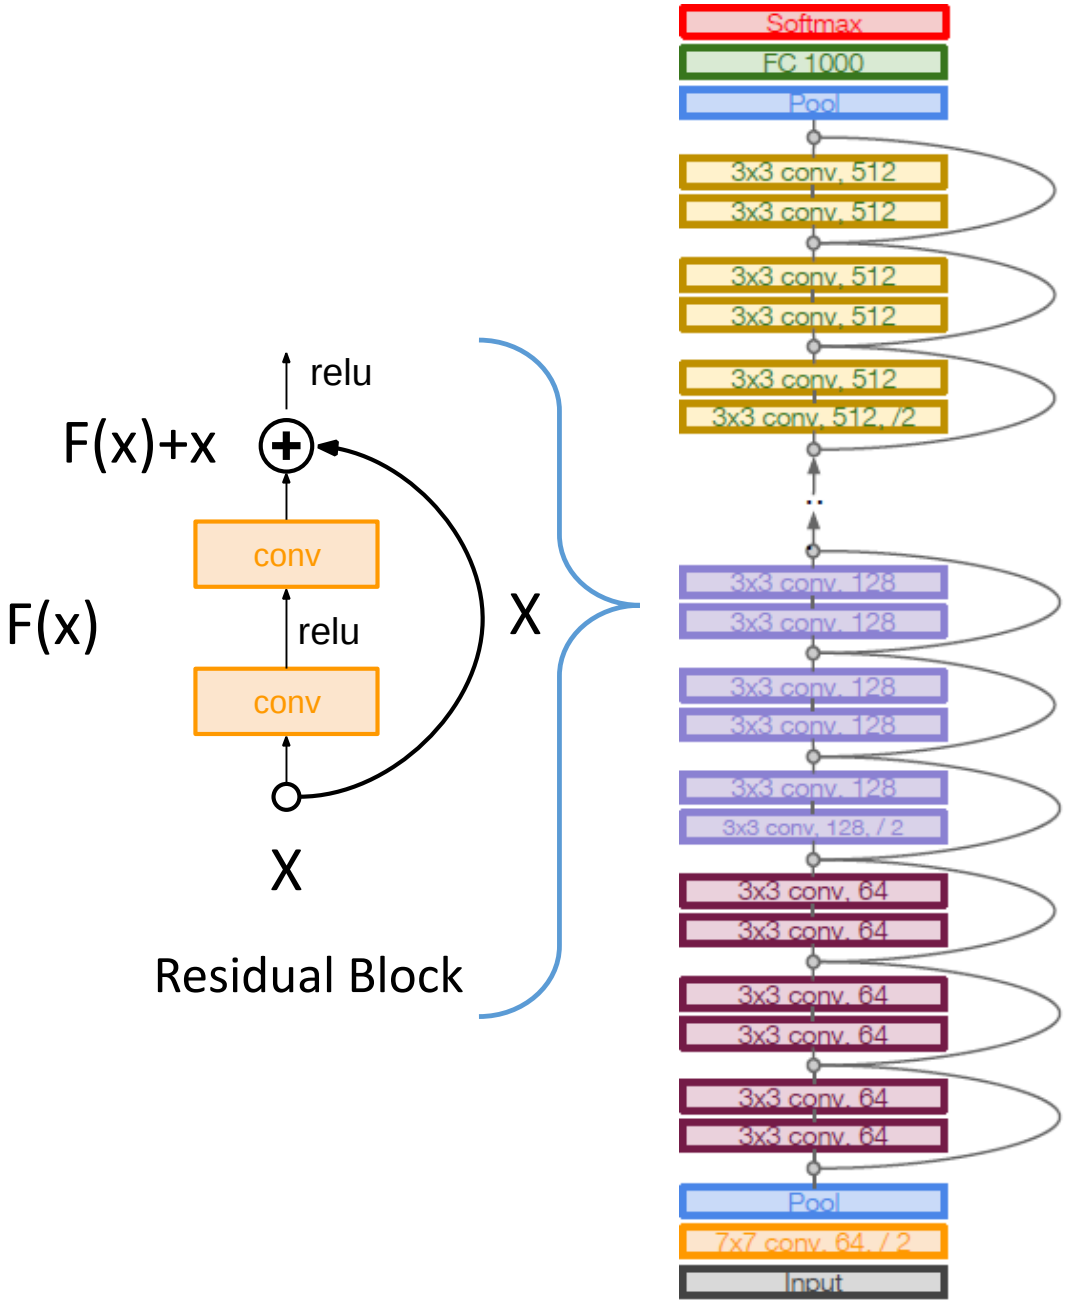

ResNet

(He et al., 2015)

Пример архитектуры ResNet-34

- Стэк из residual blocks (2 CONV 3x3)
- Число фильтров удваивается, когда пространственное разрешение уменьшается в 2 раза (stride 2, в identity CONV 1x1)

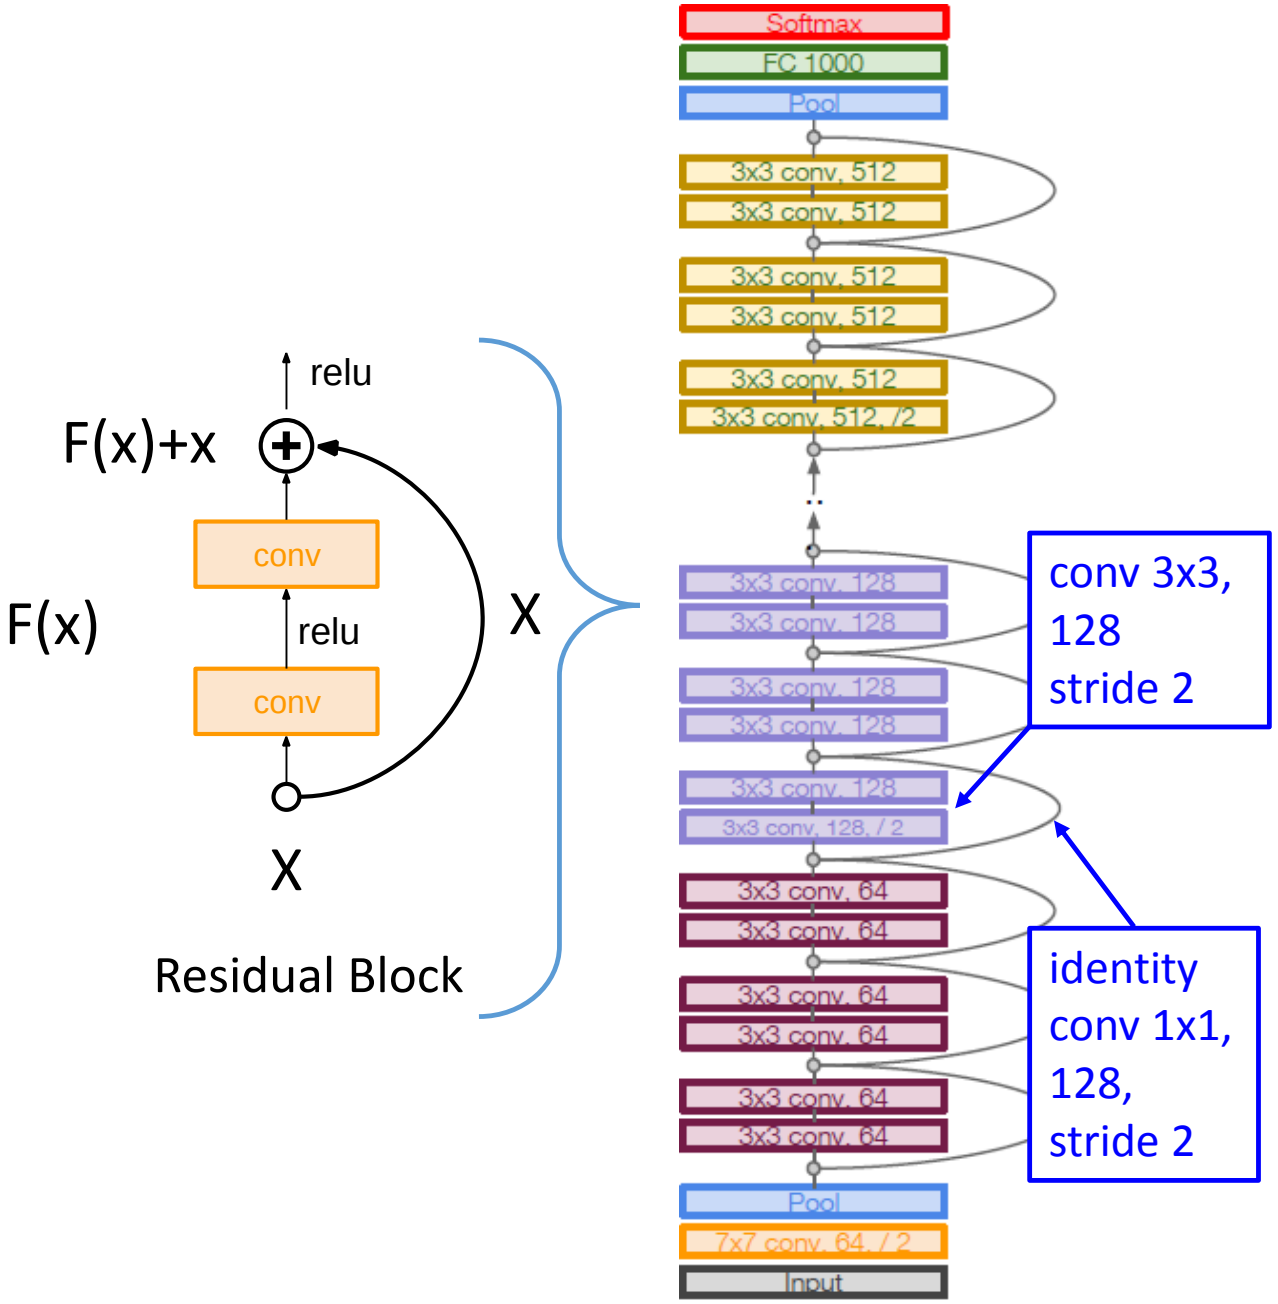

ResNet

(He et al., 2015)

Пример архитектуры ResNet-34

- Стэк из residual blocks (2 CONV 3x3)
- Число фильтров удваивается, когда пространственное разрешение уменьшается в 2 раза (stride 2, в identity CONV 1x1)
- Сразу после входа CONV 7x7 stride 2 + MAX POOL 3x3 stride 2

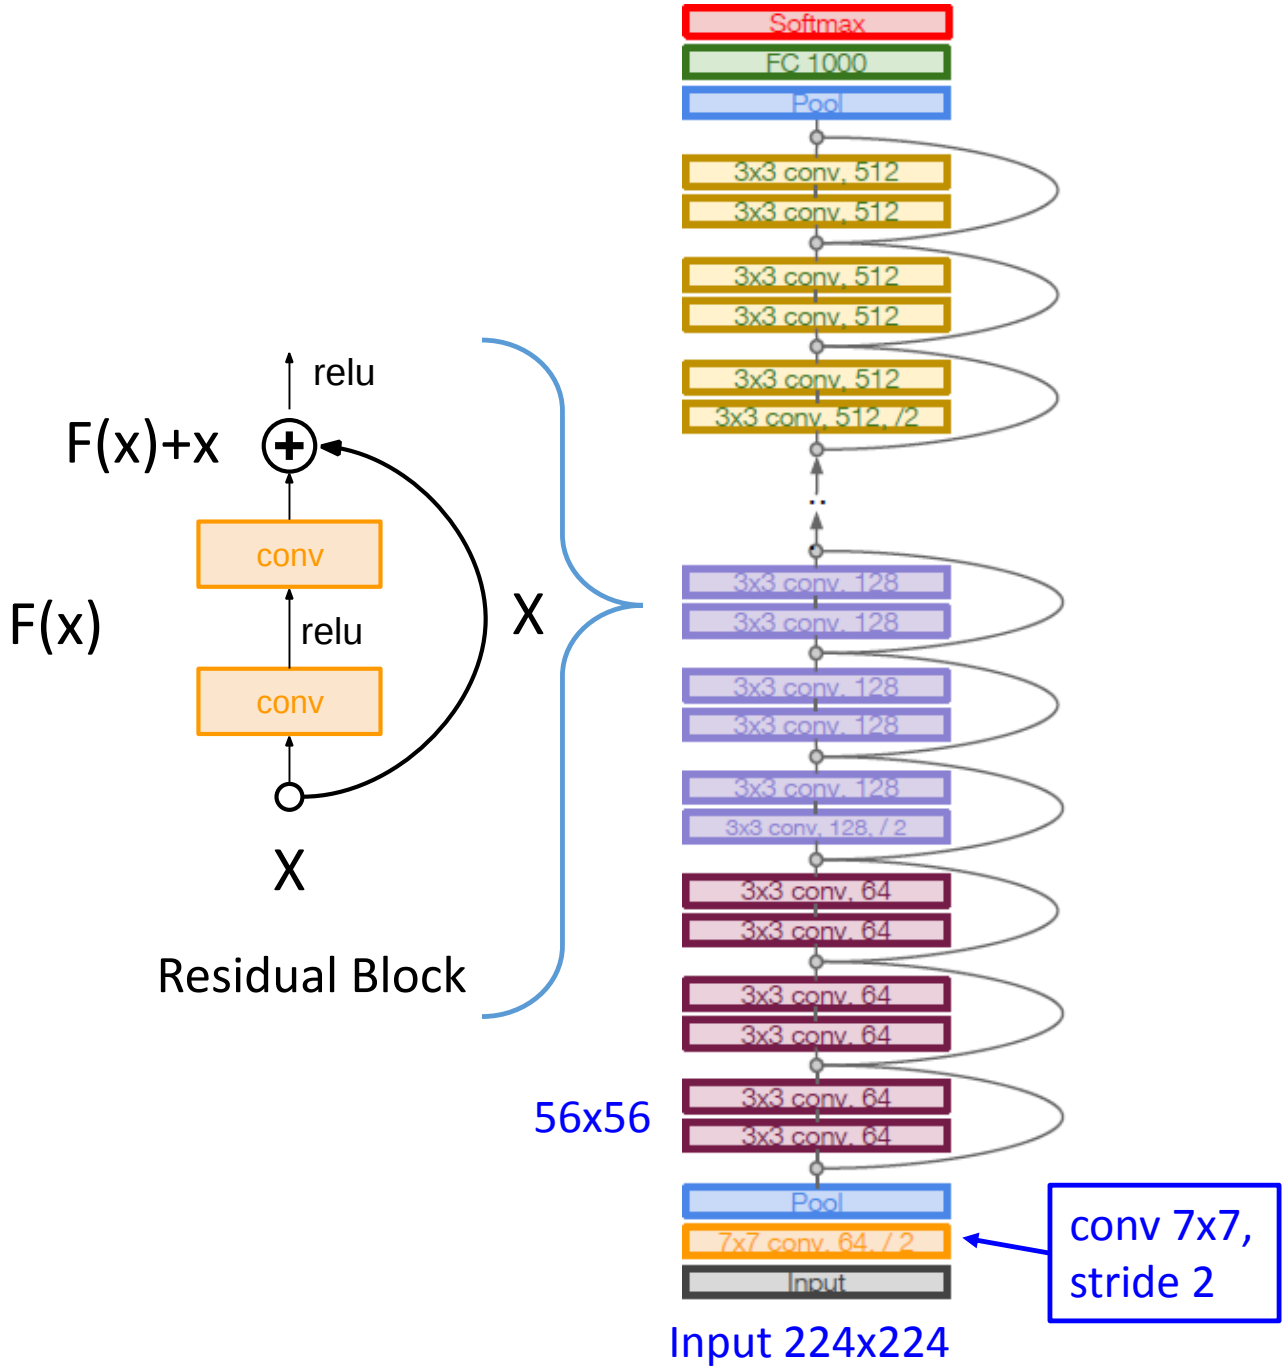

ResNet

(He et al., 2015)

Пример архитектуры ResNet-34

- Стэк из residual blocks (2 CONV 3x3)
- Число фильтров удваивается, когда пространственное разрешение уменьшается в 2 раза (stride 2, в identity CONV 1x1)
- Сразу после входа CONV 7x7 stride 2 + MAX POOL 3x3 stride 2
- Полно-связанный слой только на выходе сети (1000 классов) после AVE POOL

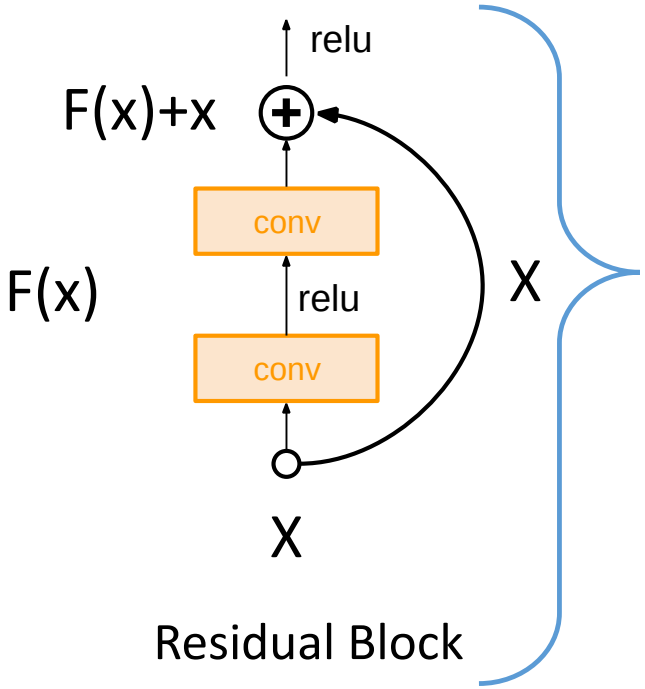

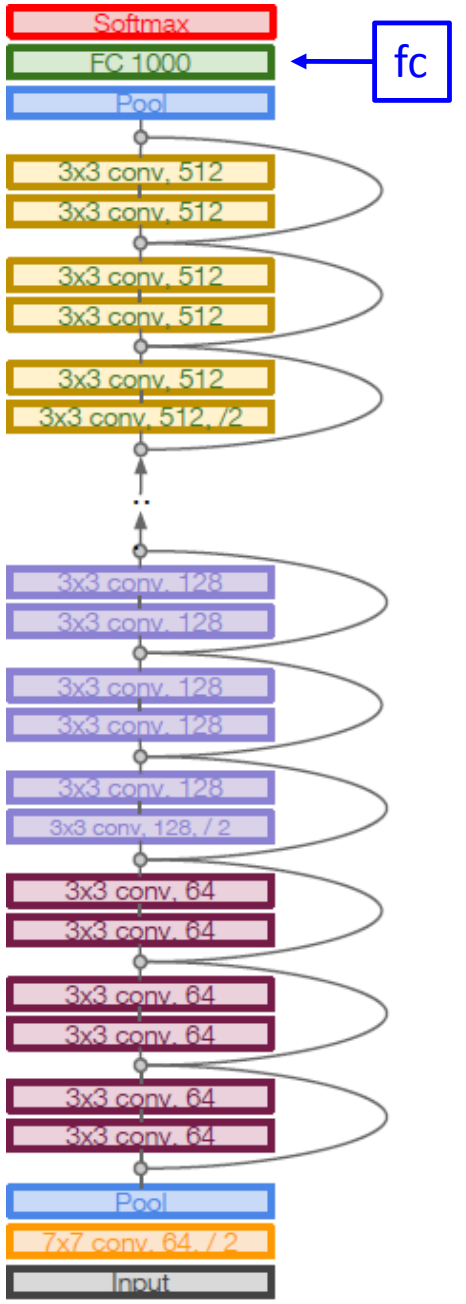

ResNet

(He et al., 2015)

Глубина сетей ResNet 34, 50, 101 или 152 слоя

Для глубоких сетей (ResNet-50+), авторы использовали “bottleneck” для уменьшения сложности вычислений (аналогично GoogleNet)

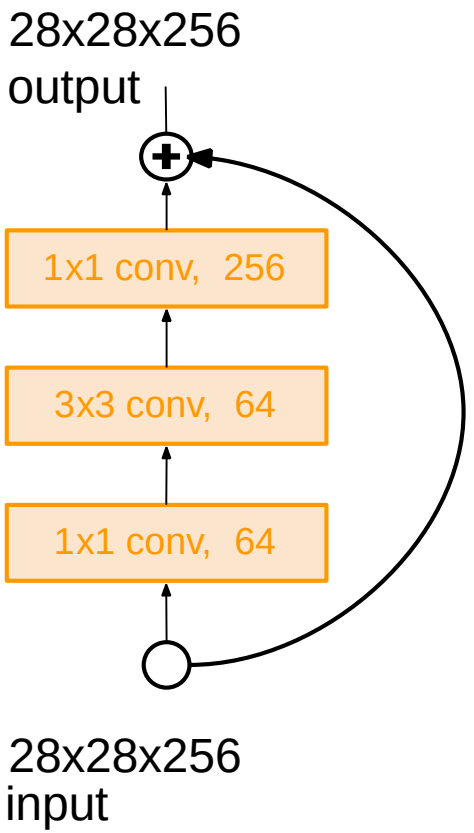

Почему ResNet проще обучать?

- Градиент ошибки легко распространяется назад

Обратный градиент при суммировании

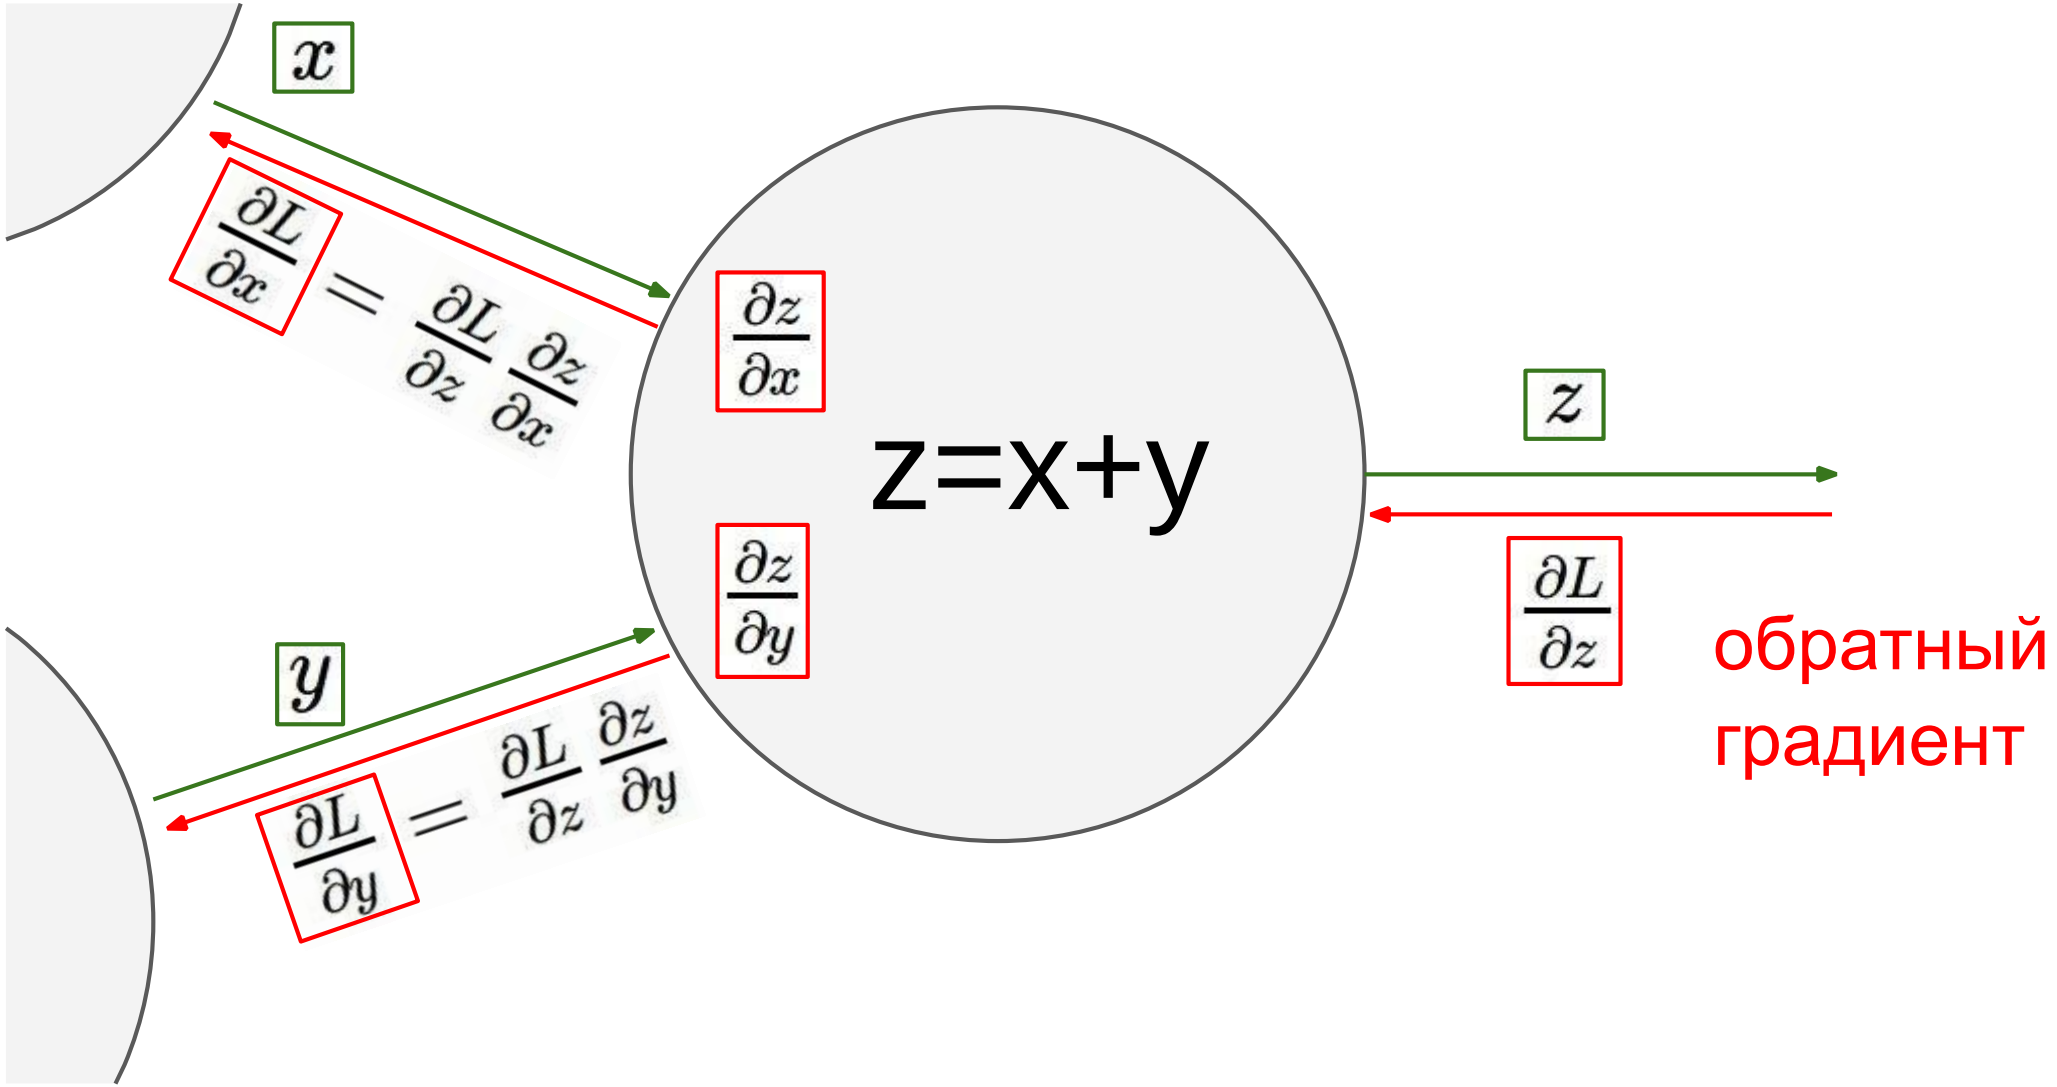

Обратный градиент при суммировании

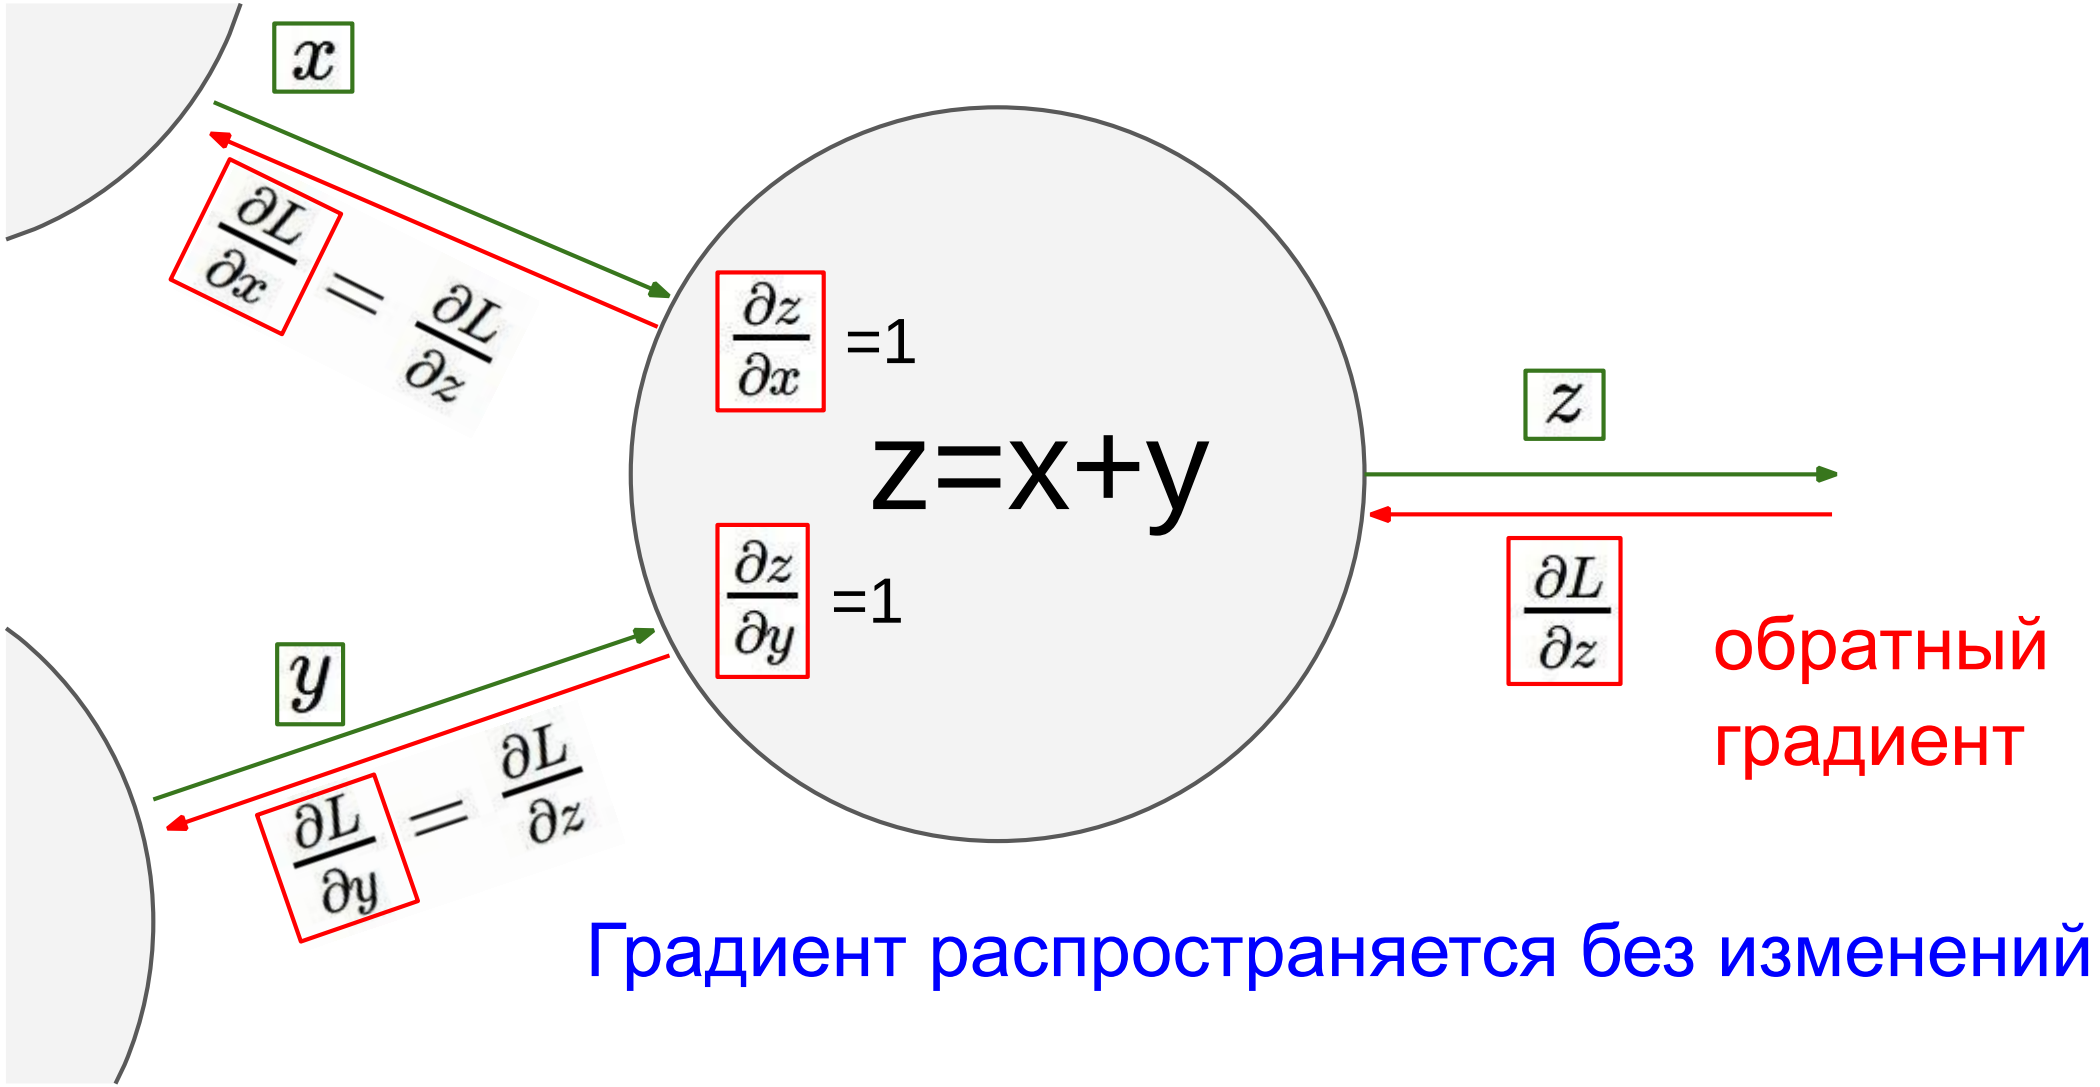

Градиент распространяется без изменений

Обратный градиент при переиспользовании переменной

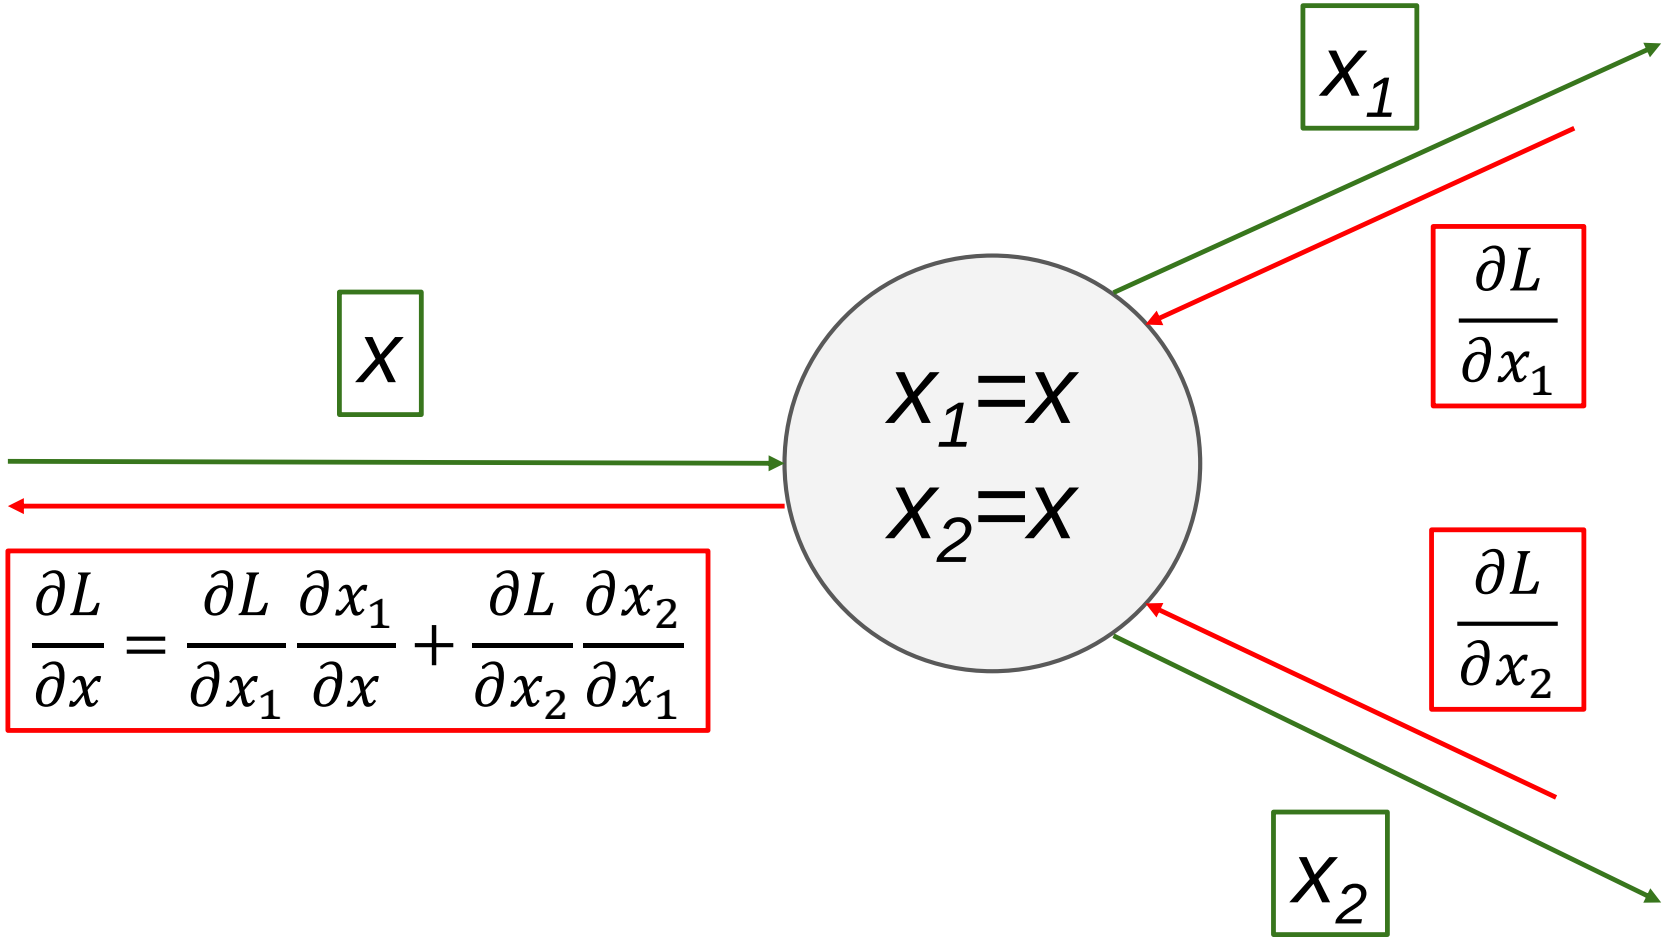

Обратный градиент при переиспользовании переменной

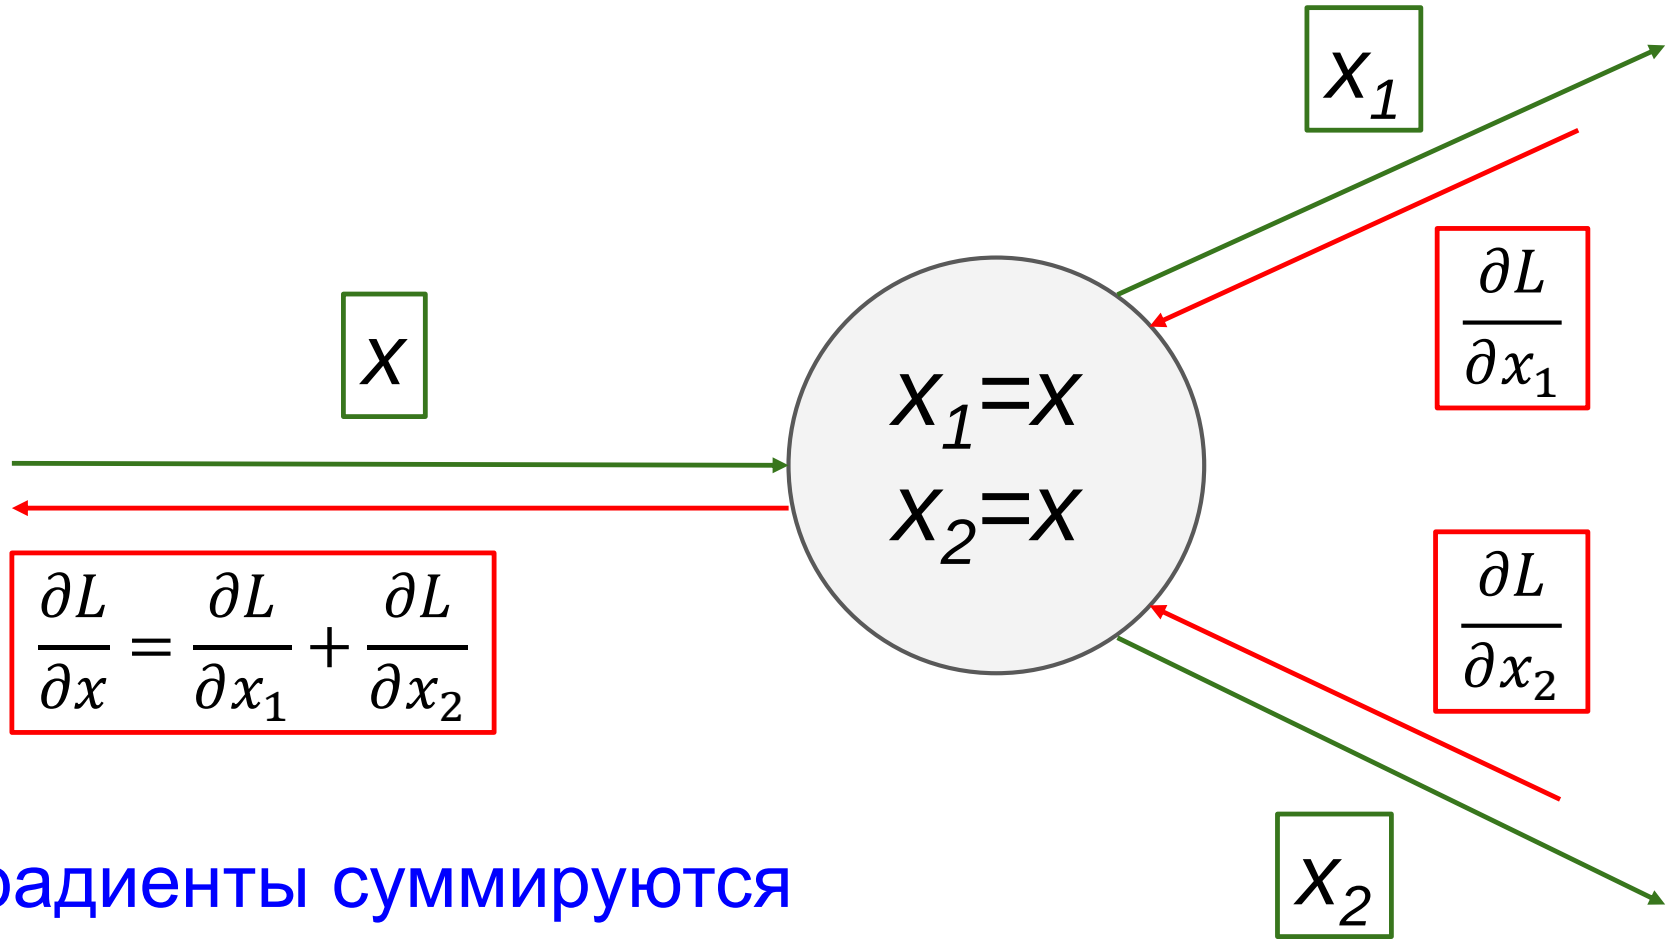

Градиенты суммируются

Почему ResNet проще обучать?

- Градиент ошибки легко распространяется назад

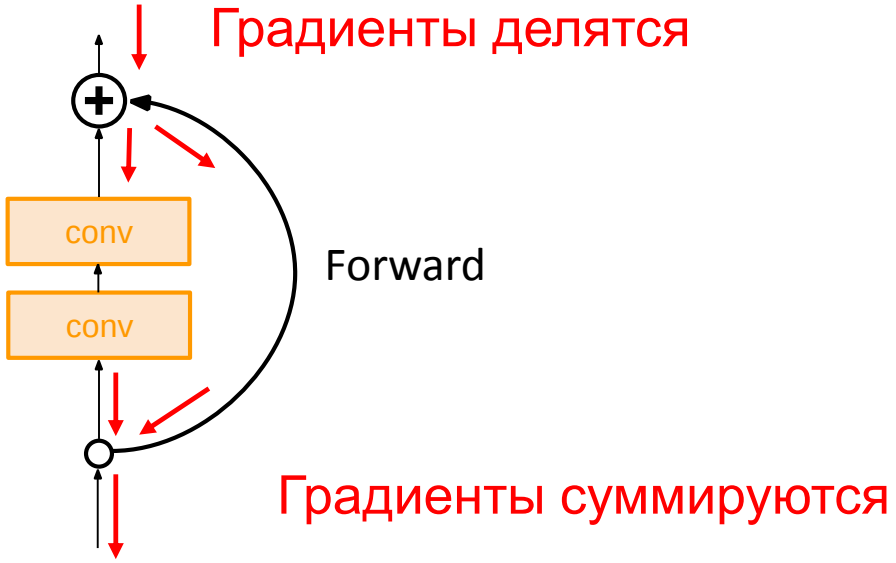

Почему ResNet проще обучать?

- Градиент ошибки легко распространяется назад
- Сложения в residual block нарушают симметрию => меньше седловых точек => проще оптимизировать с помощью backpropagation
  (Orhan et al., Skip Connections Eliminate Singularities, 2017)

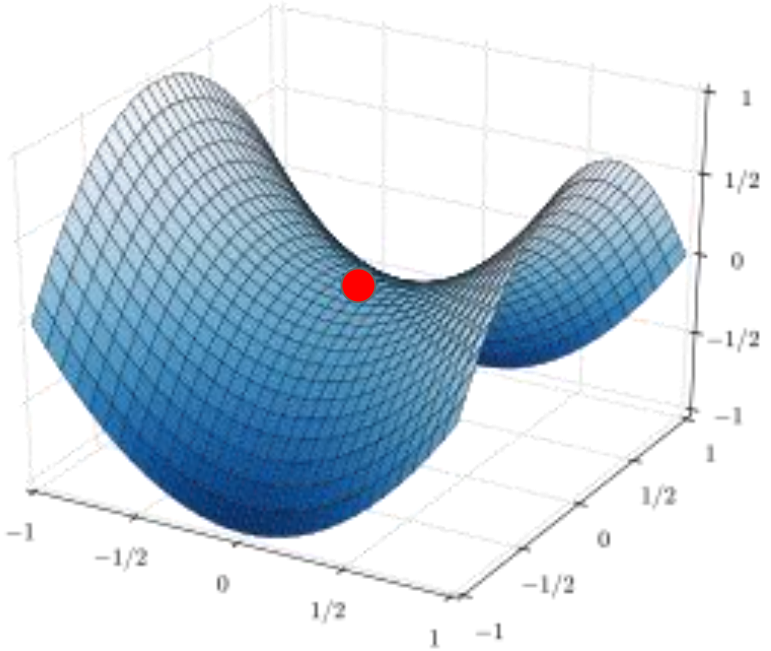

ResNet

(He et al., 2015)

Особенности:

- 1-е место во всех основных конкурсах ImageNet’15 и COCO’15
- residual connections позволили тренировать глубокие сети без уменьшения точности (152 слоя ImageNet)
- Batch Norm после каждого CONV слоя

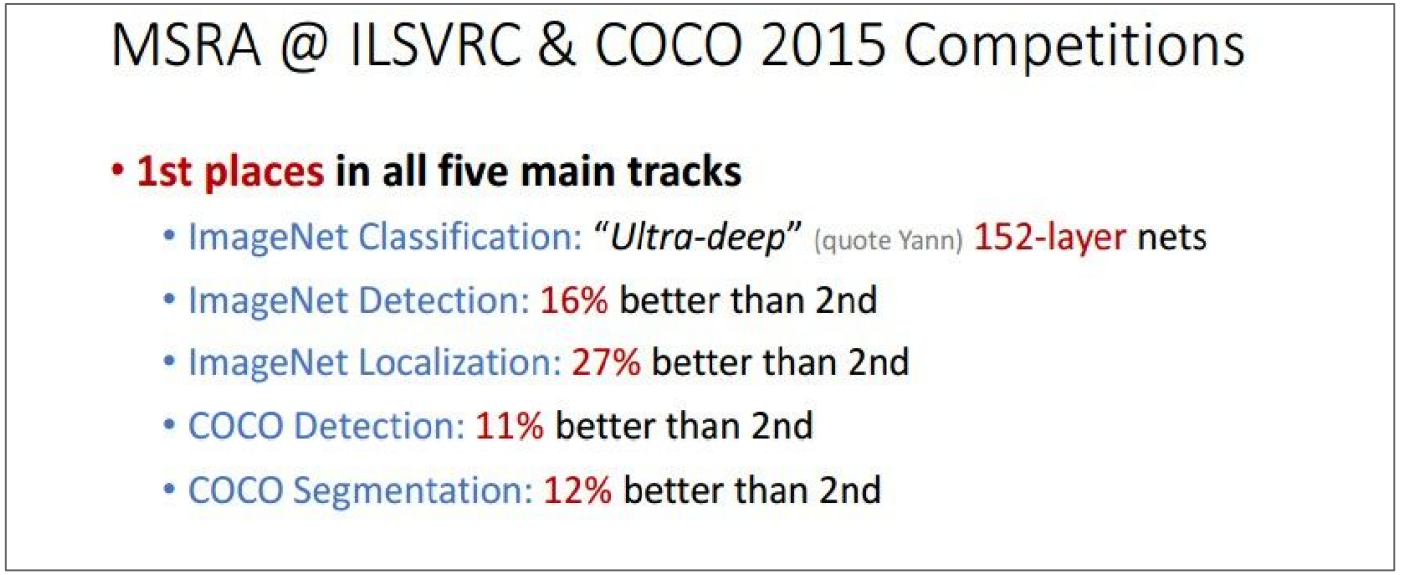

Сравнение моделей

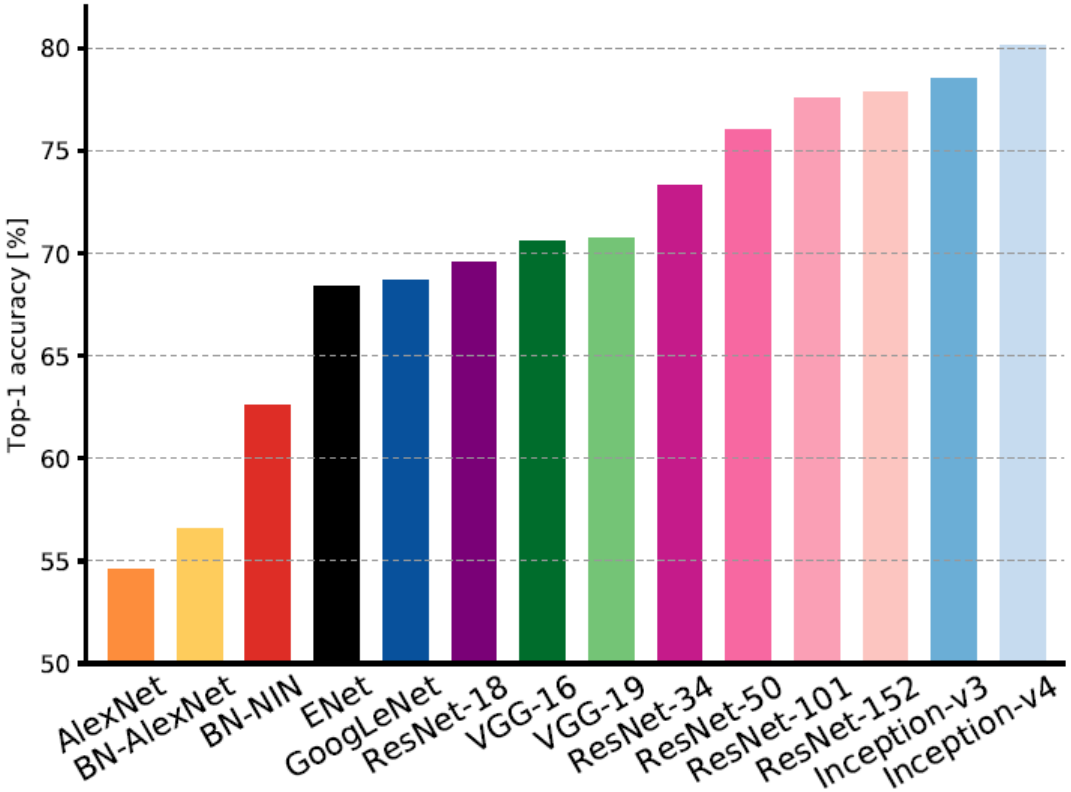

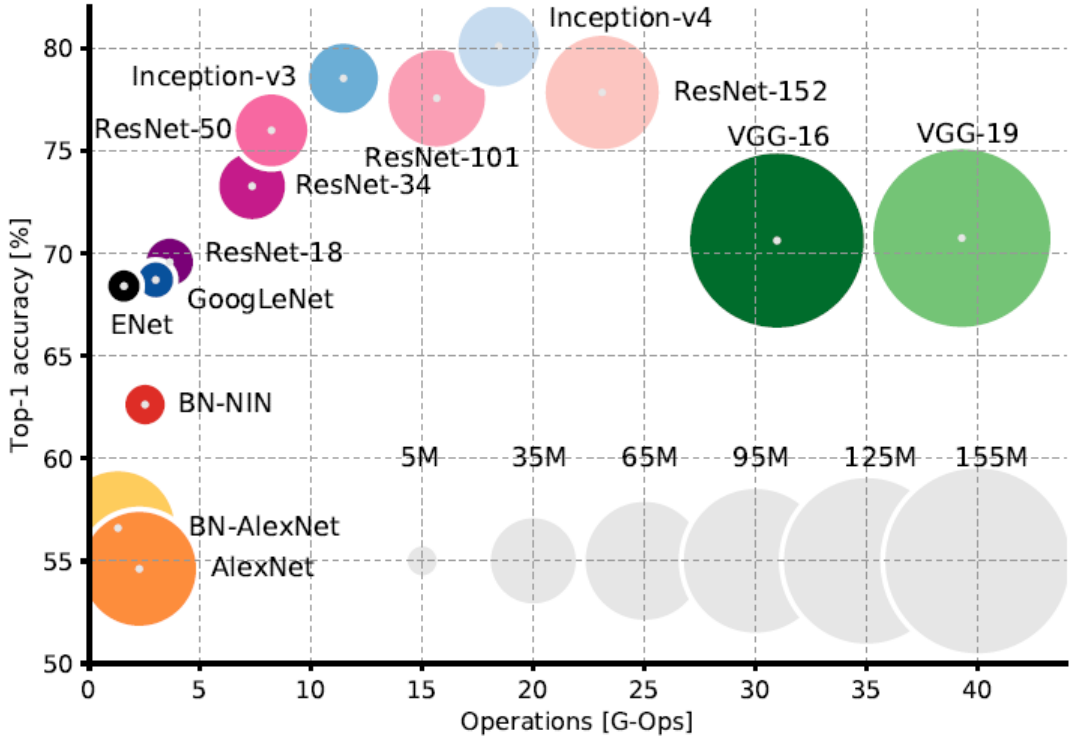

(A Canziani et al., An Analysis Of Deep Neural Network Models For Practical Applications, 2017)

Сравнение моделей

VGG: самая неэффективная
много памяти, много вычислений

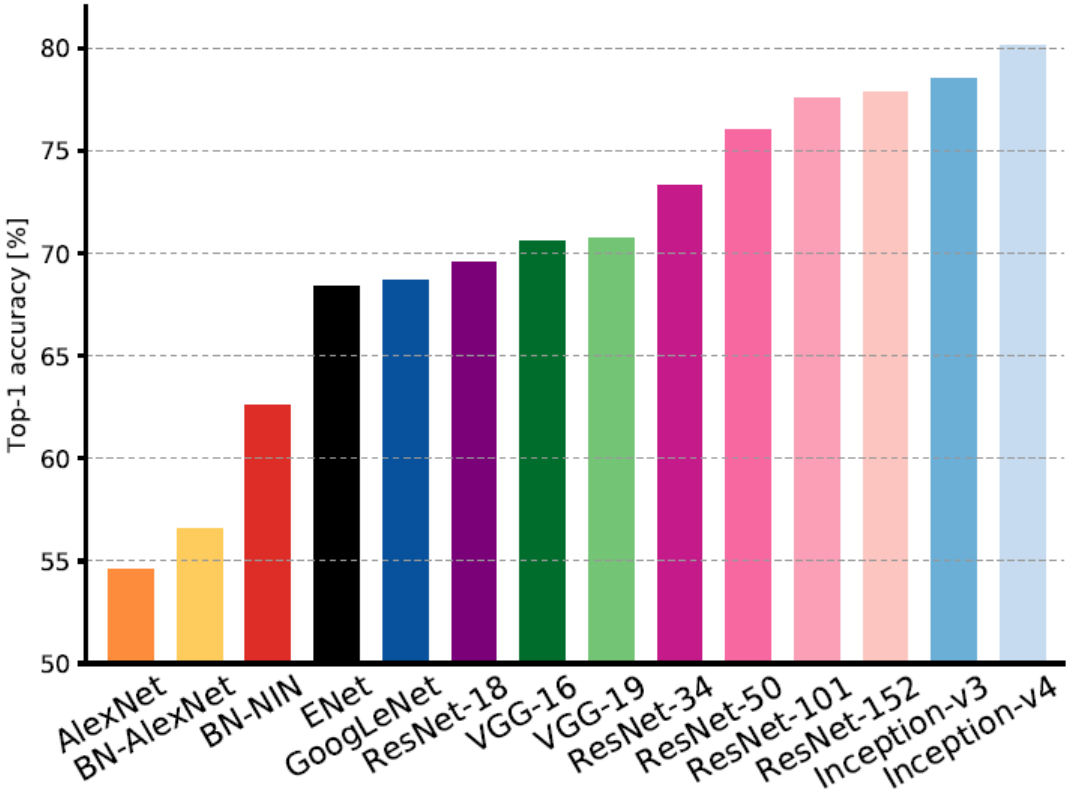

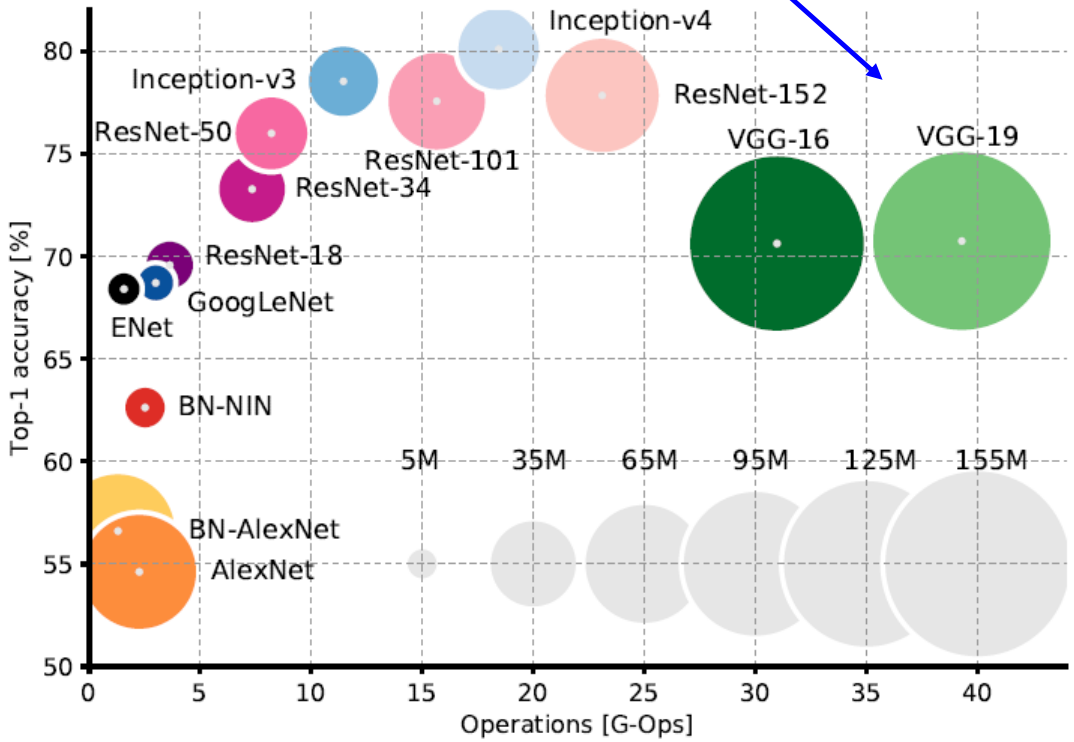

(A Canziani et al., An Analysis Of Deep Neural Network Models For Practical Applications, 2017)

Сравнение моделей

GoogleNet и ResNet-18
самые эффективные

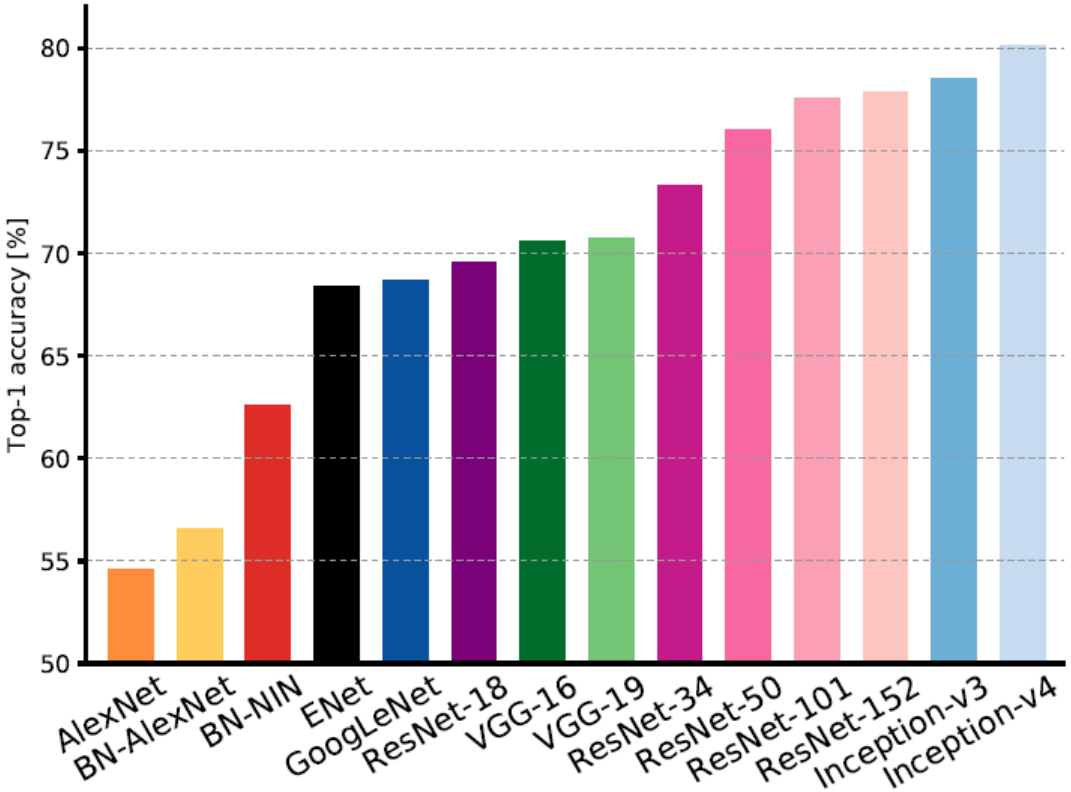

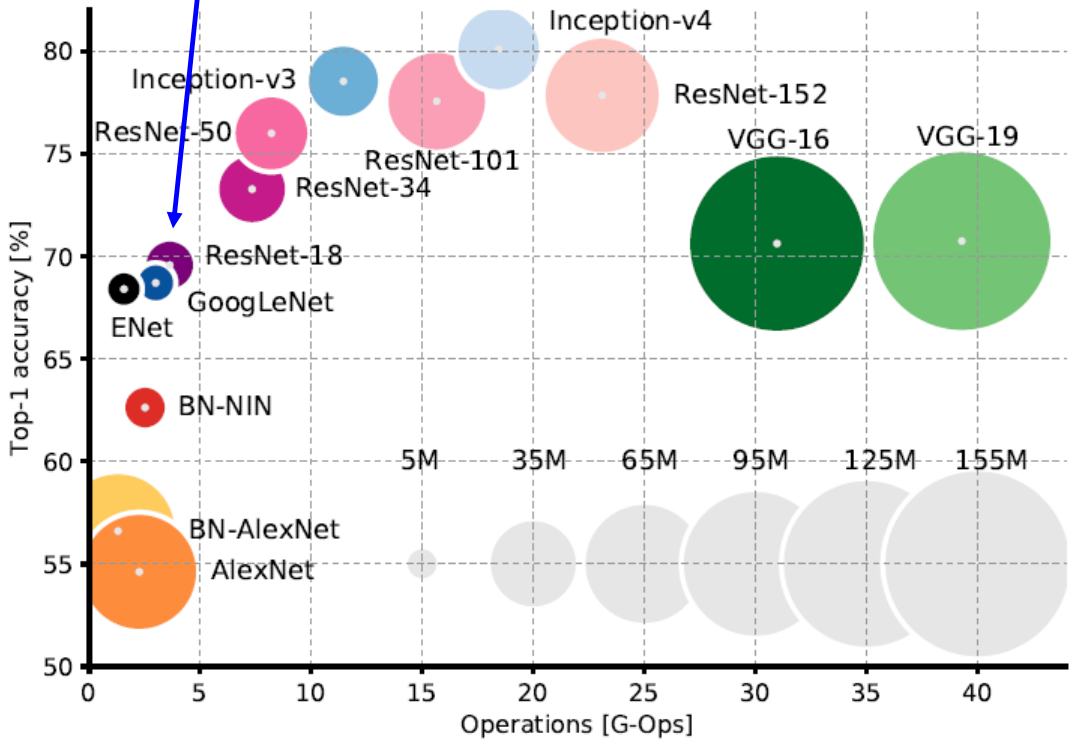

(A Canziani et al., An Analysis Of Deep Neural Network Models For Practical Applications, 2017)

Сравнение моделей

Inception v3/4 и ResNet-101/152: средняя эффективность, высокая точность, но много вычислений

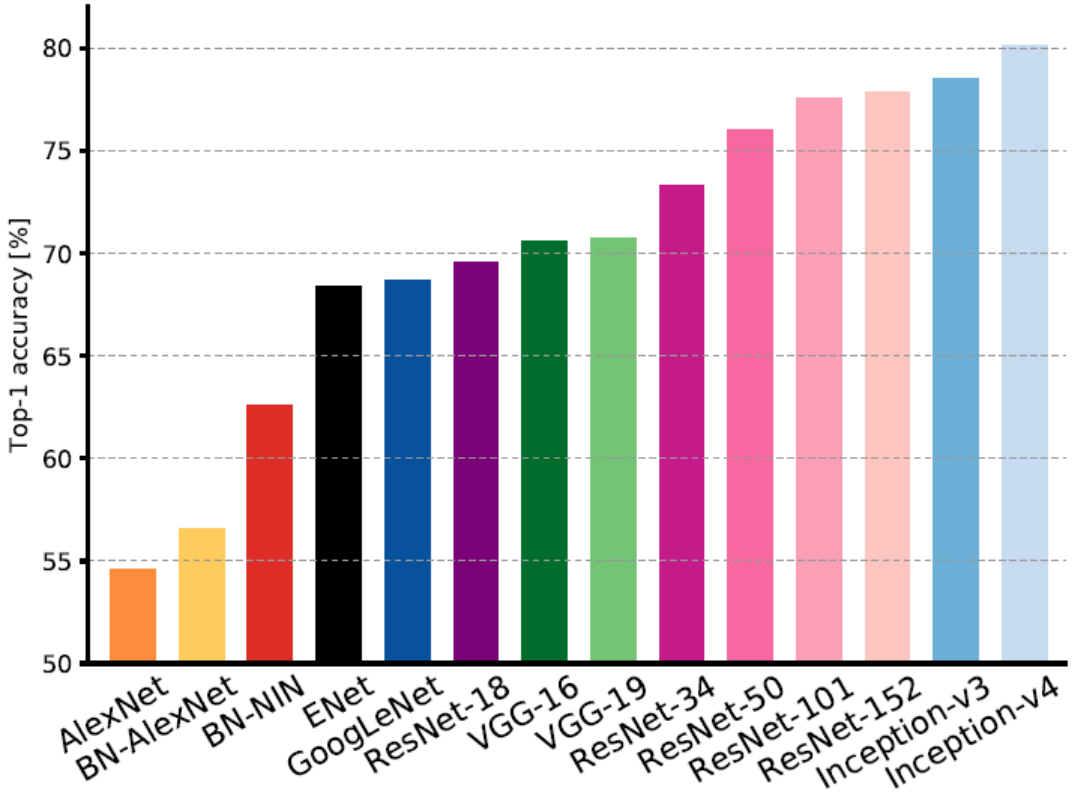

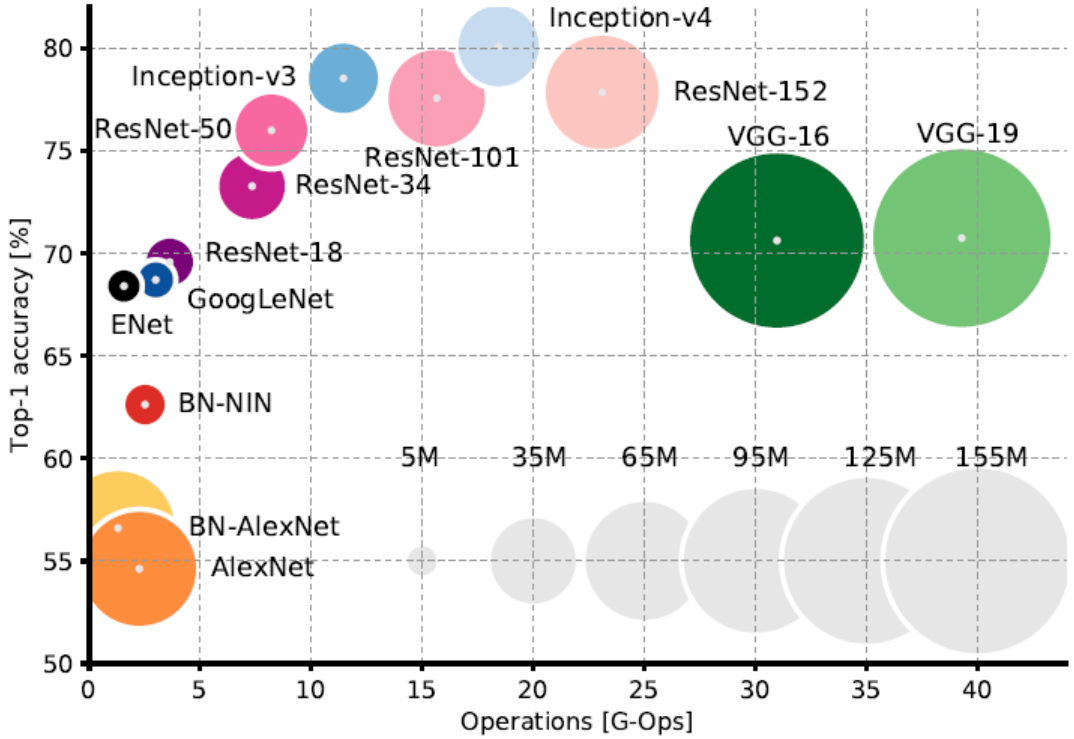

(A Canziani et al., An Analysis Of Deep Neural Network Models For Practical Applications, 2017)

Сравнение моделей

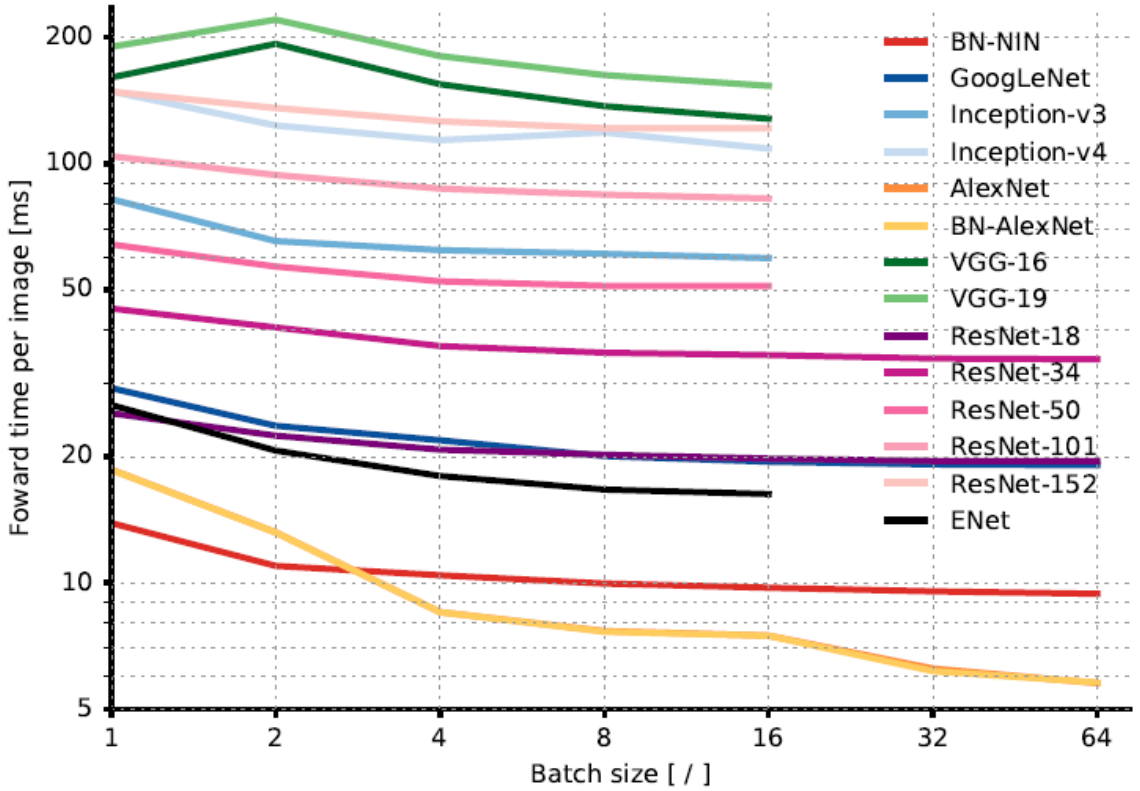

(A Canziani et al., An Analysis Of Deep Neural Network Models For Practical Applications, 2017)

Large Scale Visual Recognition Challenge (ILSVRC)

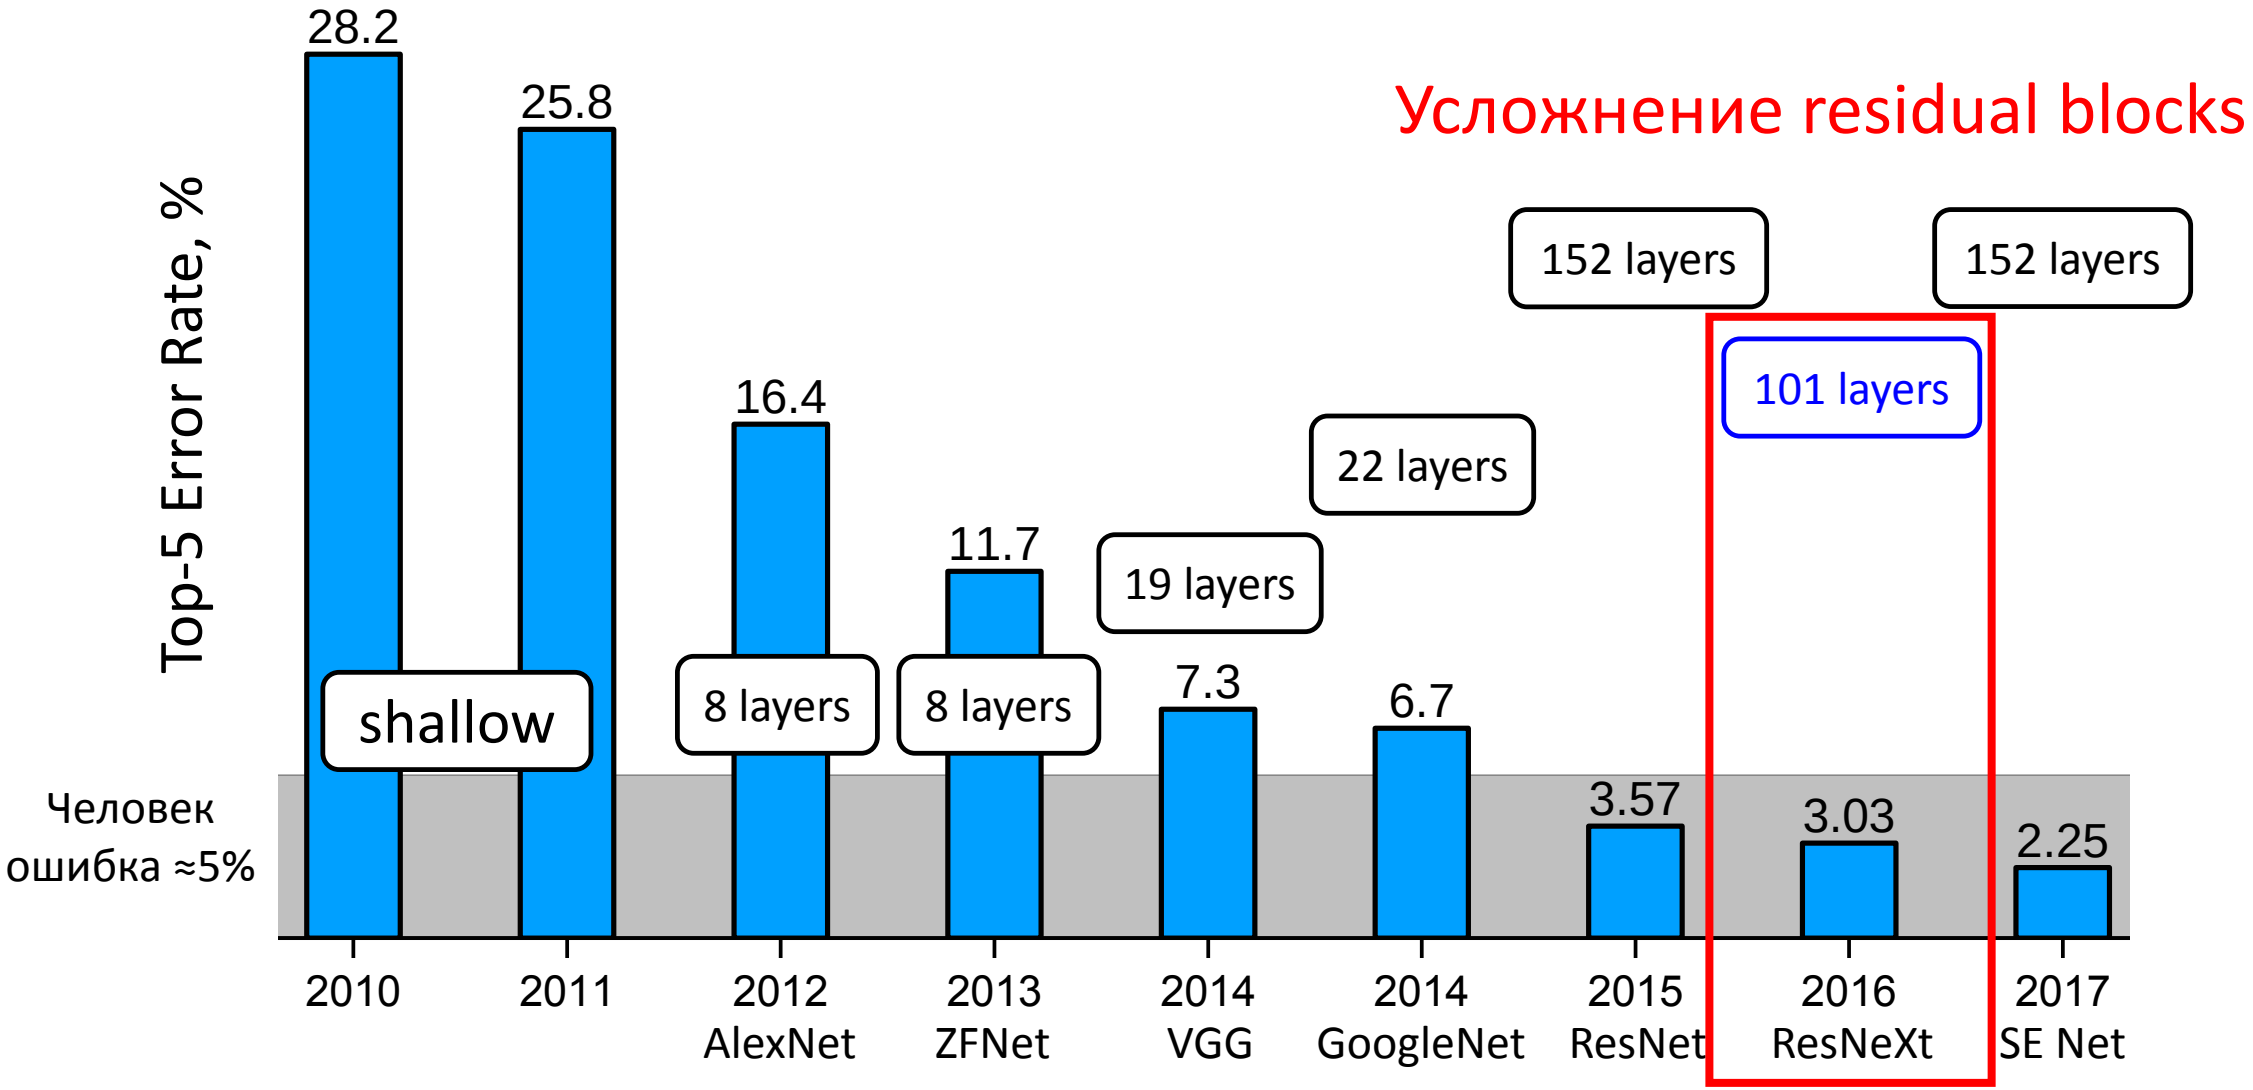

ResNeXt

(Xie et al., 2016)

ImageNet'16 2-е место в классификации
(top 5 error 3.03%, у первого места 2.99% ☺)

Новые residual блоки похожи на Inception блоки, но с одинаковыми каналами

Представили архитектуры ResNeXt-50 и ResNeXt-101

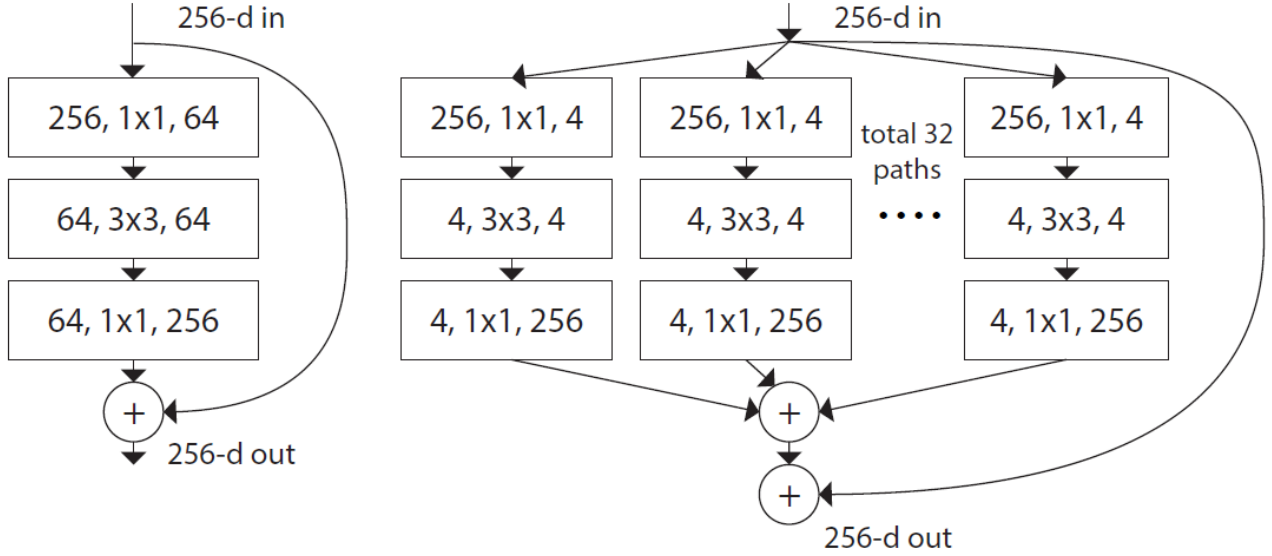

Figure 1. **Left**: A block of ResNet [14]. **Right**: A block of ResNeXt with cardinality = 32, with roughly the same complexity. A layer is shown as (# in channels, filter size, # out channels).

ImageNet top 5 error: 3.57% (ResNet) -> 3.03

ResNeXt

(Xie et al., 2016)

Переформулировки residual block

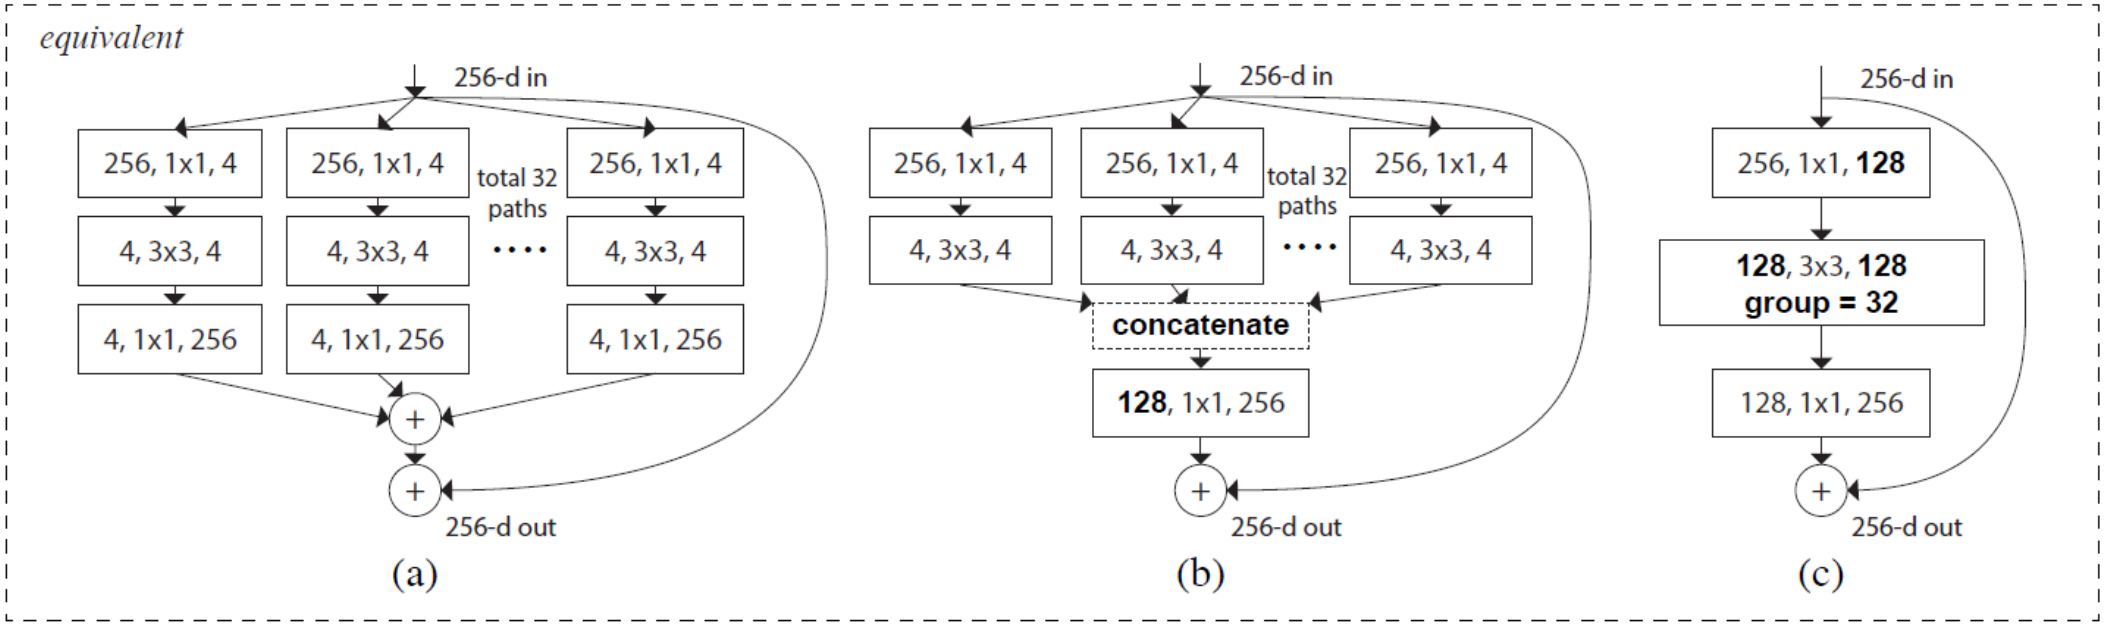

Figure 3. Equivalent building blocks of ResNeXt. **(a)**: Aggregated residual transformations, the same as Fig. 1 right. **(b)**: A block equivalent to (a), implemented as early concatenation. **(c)**: A block equivalent to (a,b), implemented as grouped convolutions [24]. Notations in **bold** text highlight the reformulation changes. A layer is denoted as (# input channels, filter size, # output channels).

ResNeXt

(Xie et al., 2016)

Пример архитектуры ResNeXt-50

stage	output	ResNet-50	**ResNeXt-50 (32×4d)**
conv1	112×112	7×7, 64, stride 2	7×7, 64, stride 2
conv2	56×56	3×3 max pool, stride 2	3×3 max pool, stride 2
		$\begin{bmatrix} 1\times1, 64 \\ 3\times3, 64 \\ 1\times1, 256 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128, C=32 \\ 1\times1, 256 \end{bmatrix}\times3$
conv3	28×28	$\begin{bmatrix} 1\times1, 128 \\ 3\times3, 128 \\ 1\times1, 512 \end{bmatrix}\times4$	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256, C=32 \\ 1\times1, 512 \end{bmatrix}\times4$
conv4	14×14	$\begin{bmatrix} 1\times1, 256 \\ 3\times3, 256 \\ 1\times1, 1024 \end{bmatrix}\times6$	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512, C=32 \\ 1\times1, 1024 \end{bmatrix}\times6$
conv5	7×7	$\begin{bmatrix} 1\times1, 512 \\ 3\times3, 512 \\ 1\times1, 2048 \end{bmatrix}\times3$	$\begin{bmatrix} 1\times1, 1024 \\ 3\times3, 1024, C=32 \\ 1\times1, 2048 \end{bmatrix}\times3$
	1×1	global average pool 1000-d fc, softmax	global average pool 1000-d fc, softmax
# params.		$\mathbf{25.5}\times10^6$	$\mathbf{25.0}\times10^6$
FLOPs		$\mathbf{4.1}\times10^9$	$\mathbf{4.2}\times10^9$

Table 1. (**Left**) ResNet-50. (**Right**) ResNeXt-50 with a 32×4d template (using the reformulation in Fig. 3(c)). Inside the brackets are the shape of a residual block, and outside the brackets is the number of stacked blocks on a stage. "C=32" suggests grouped convolutions [24] with 32 groups. *The numbers of parameters and FLOPs are similar between these two models.*

Large Scale Visual Recognition Challenge (ILSVRC)

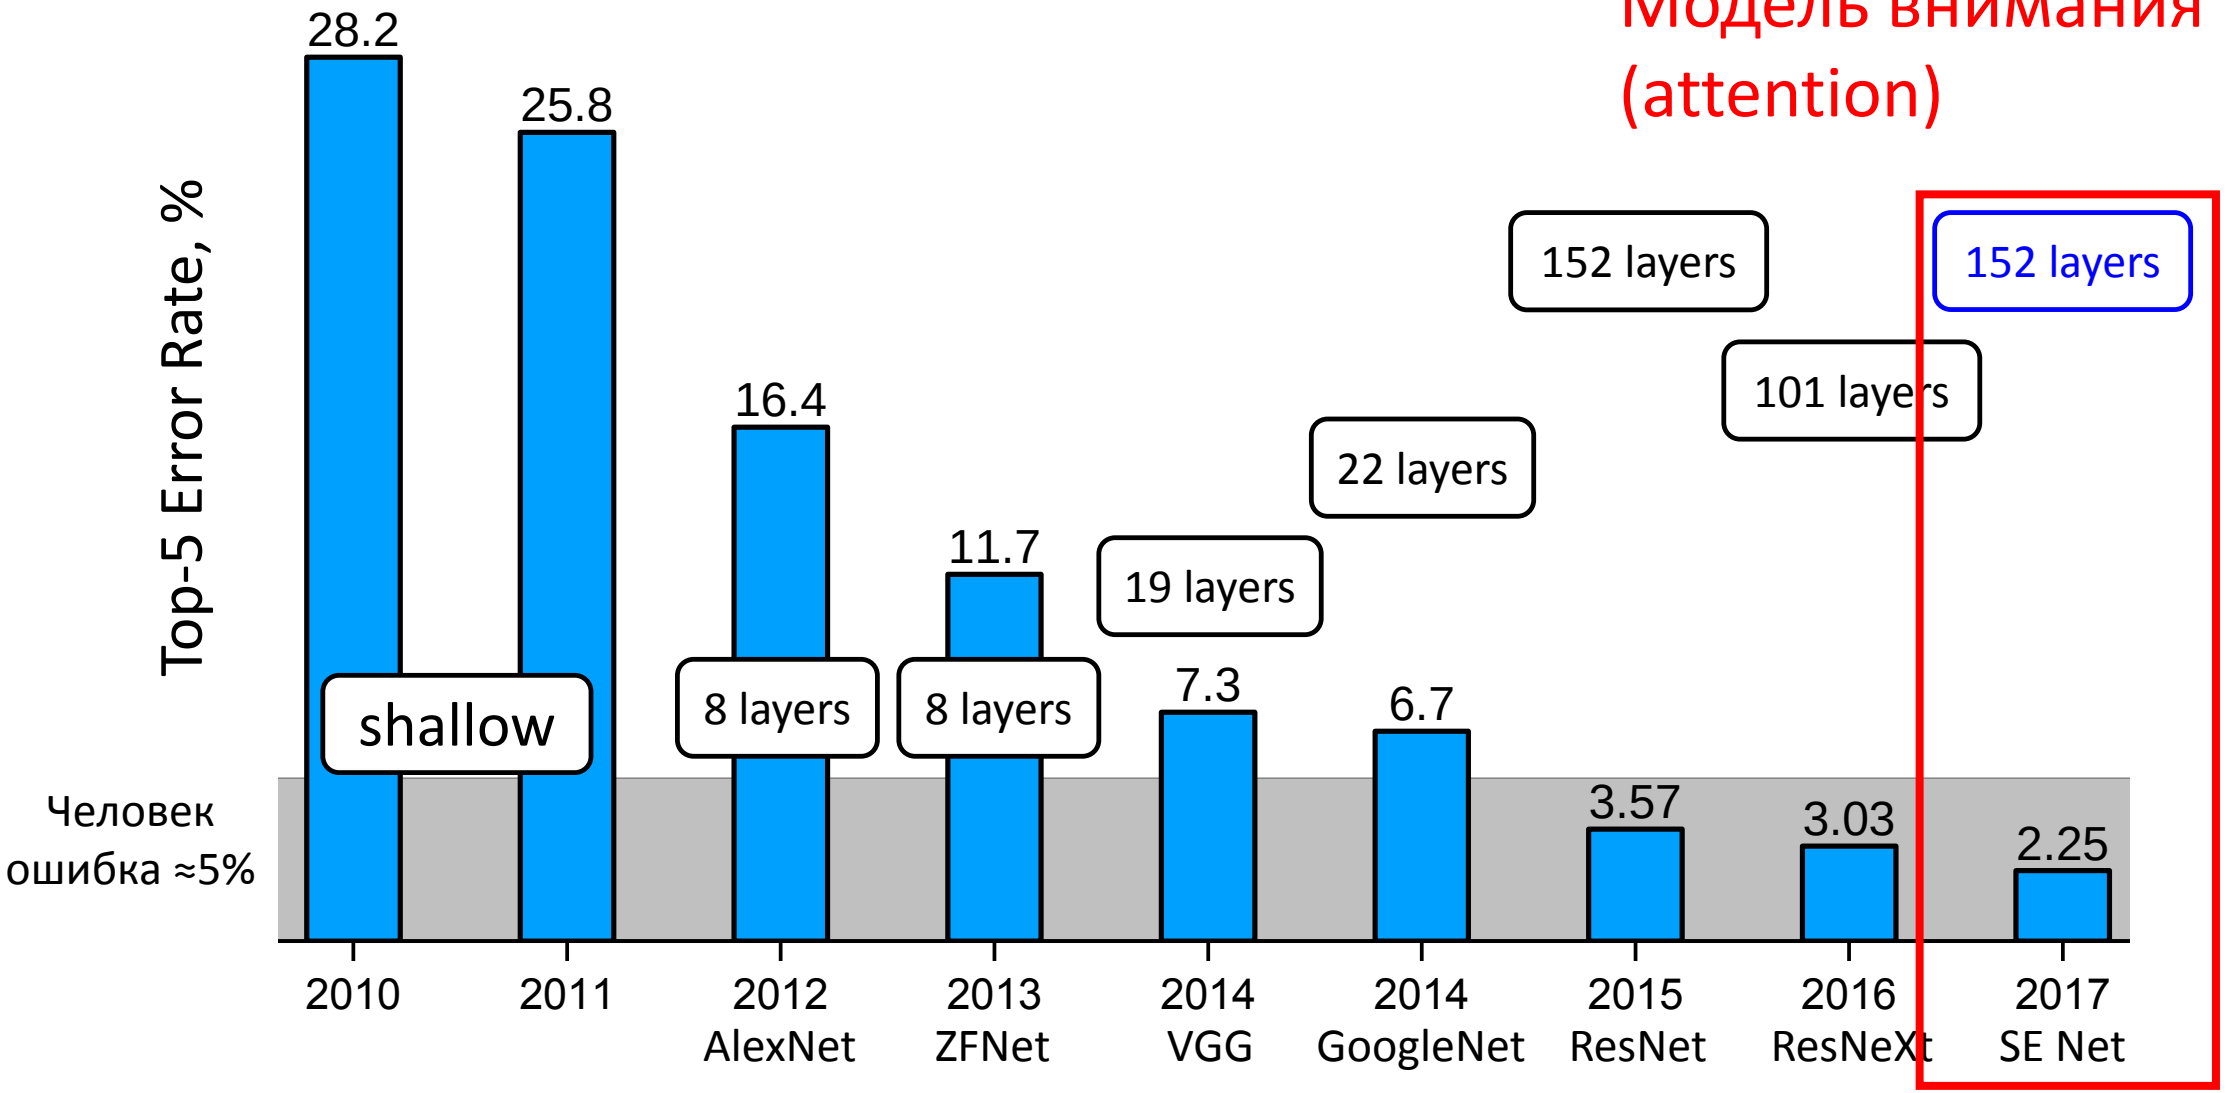

Squeeze-and-Excitation Networks

(Hu et al., 2017)

ImageNet’17 1-е место в классификации

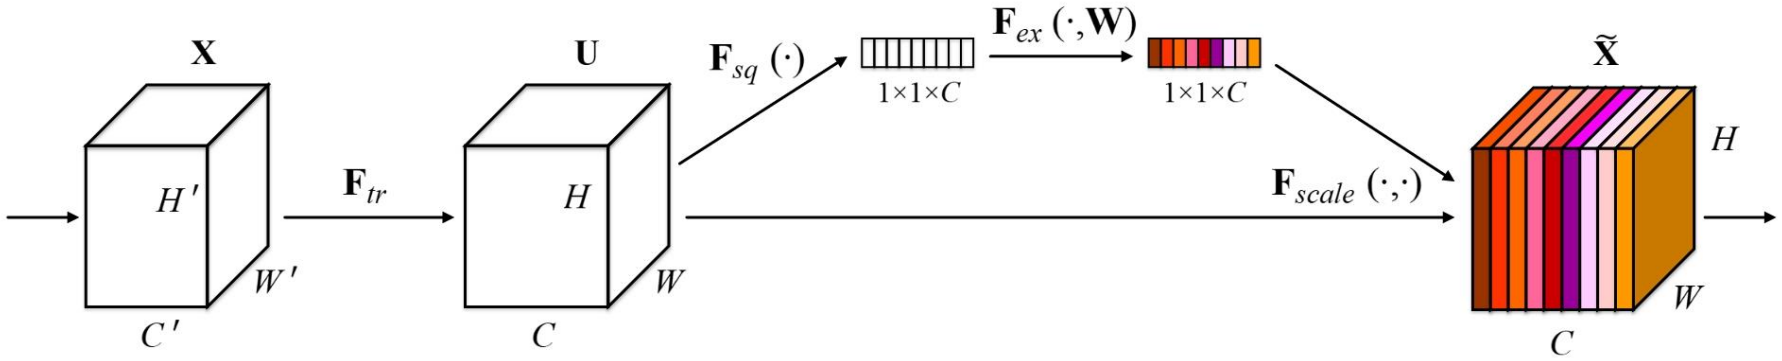

Модель внимания. Squeeze-and-Excitation блоки (SE blocks) нормируют каналы и помогают использовать глобальную информацию

Новые SE block очень быстрые и практически не замедляют сеть

ImageNet top 5 error: 3.03% (ResNeXt) -> **2.25**

Squeeze-and-Excitation Networks

(Hu et al., 2017)

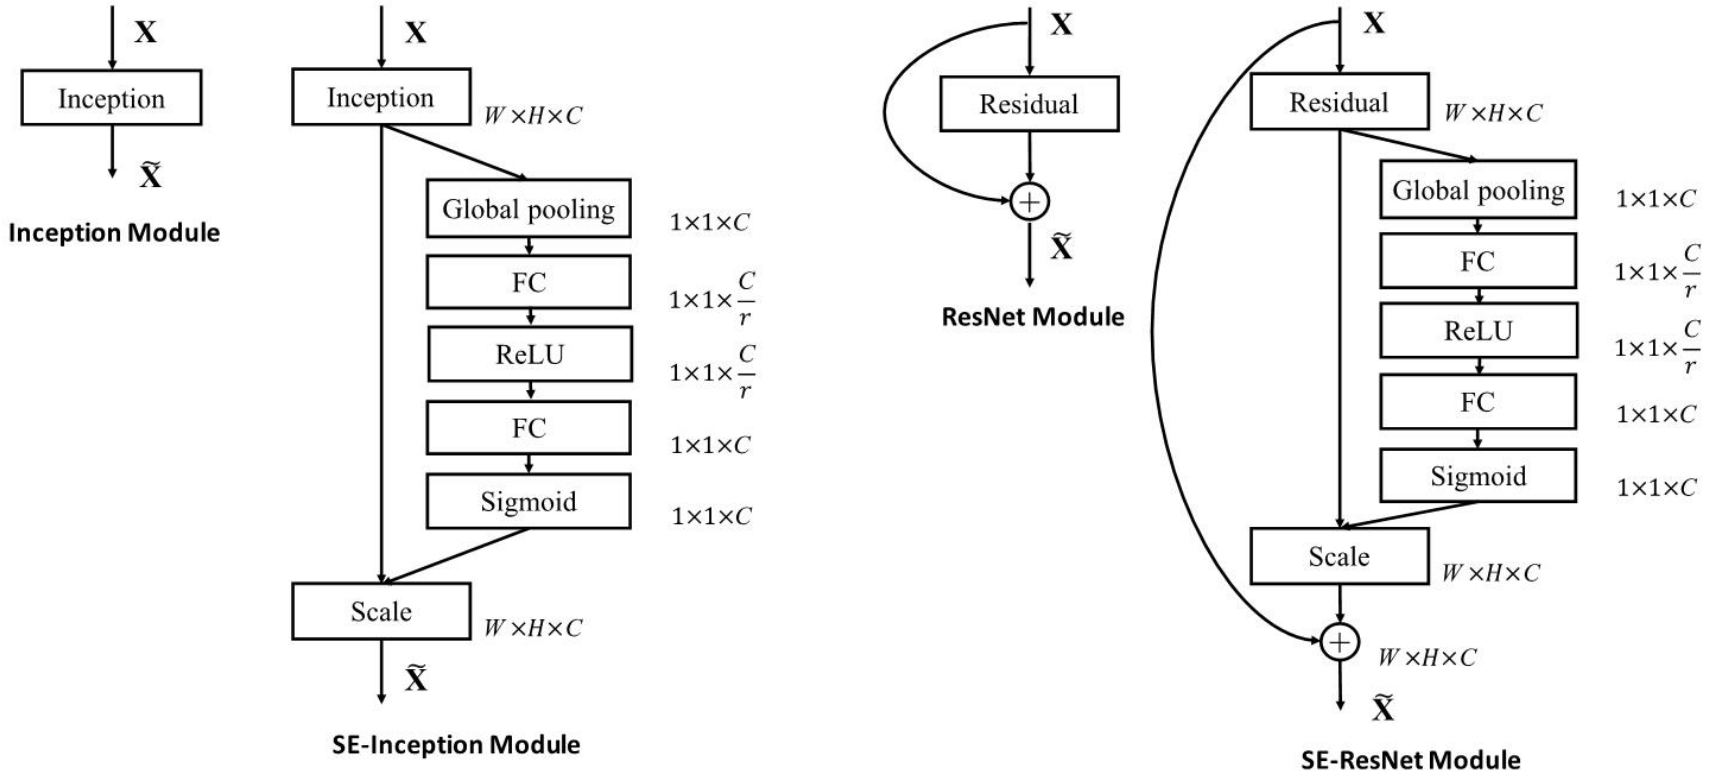

Schema of SE-Inception and SE-ResNet modules.
r=16 in all models.

Squeeze-and-Excitation Networks

(Hu et al., 2017)

Особенности победителя ImageNet:

- ResNeXt-152 + SE blocks
- 7x7 CONV => 3 3x3 CONV (like VGG)
- Число каналов в 1x1 “bottleneck” уменьшено в 2 раза, для увеличения скорости вычислений
- 1x1 CONV stride 2 => 3x3 CONV stride 2 для уменьшения пространственного разрешения
- Тренировка: Label smoothing regularization
  с небольшой вероятность реальные метки заменяются на распределение меток из train набора
  (Szegedy et al., Rethinking the inception architecture for computer vision, 2016)

Large Scale Visual Recognition Challenge (ILSVRC)

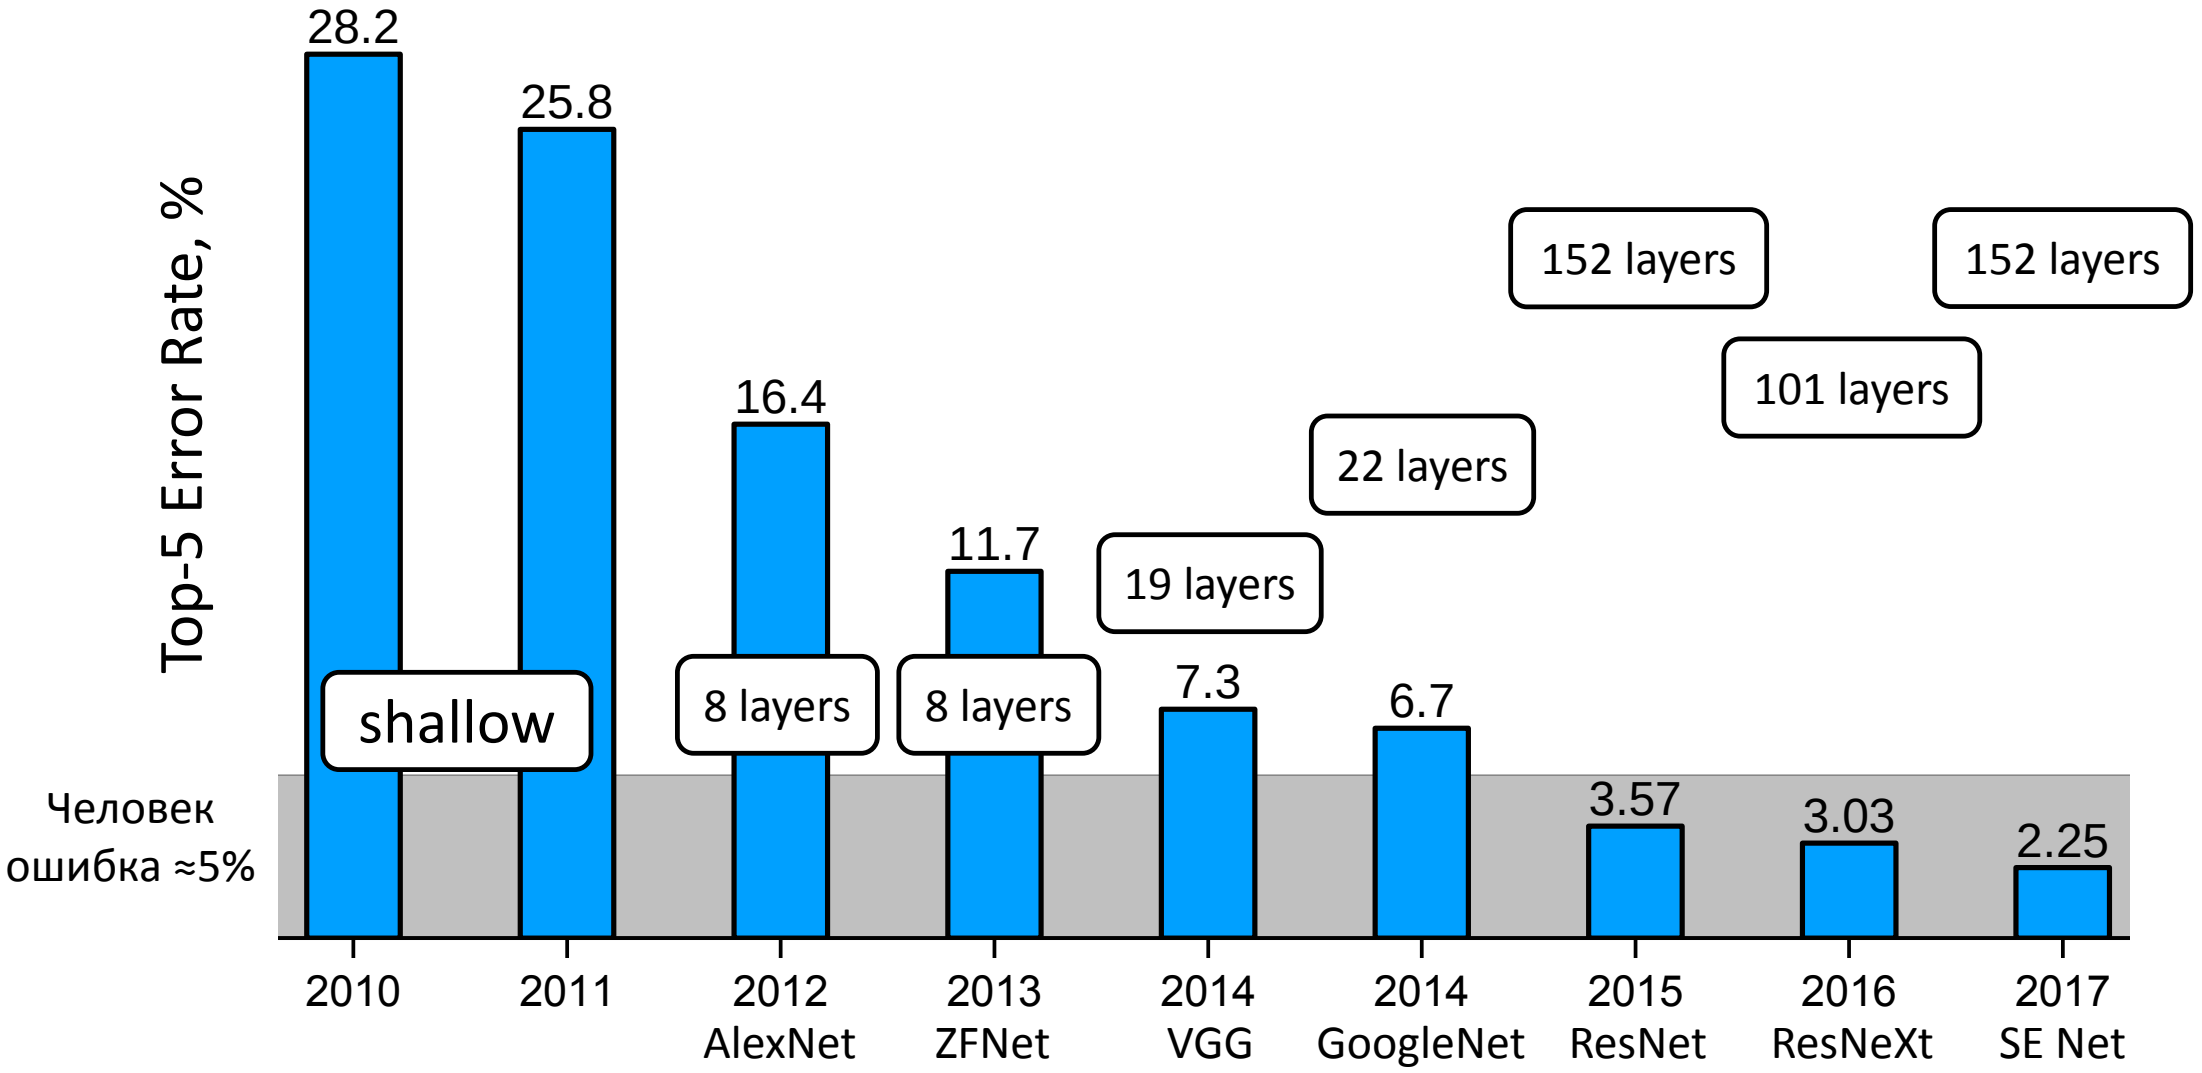

DenseNet

(Huang et al., 2017)

Улучшает распространение информации между слоями, и уменьшает число параметров

Dense blocks: каждый слой переиспользует признаки всех предыдущих

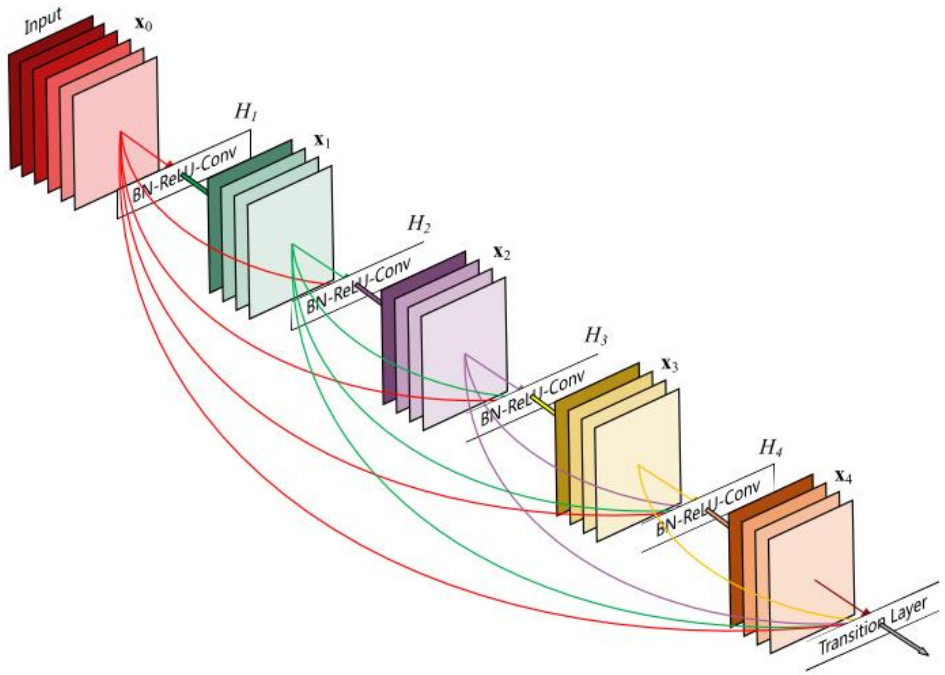

A 5-layer (l=5) dense block with a growth rate of k = 4. Each layer takes all preceding feature-maps as input.

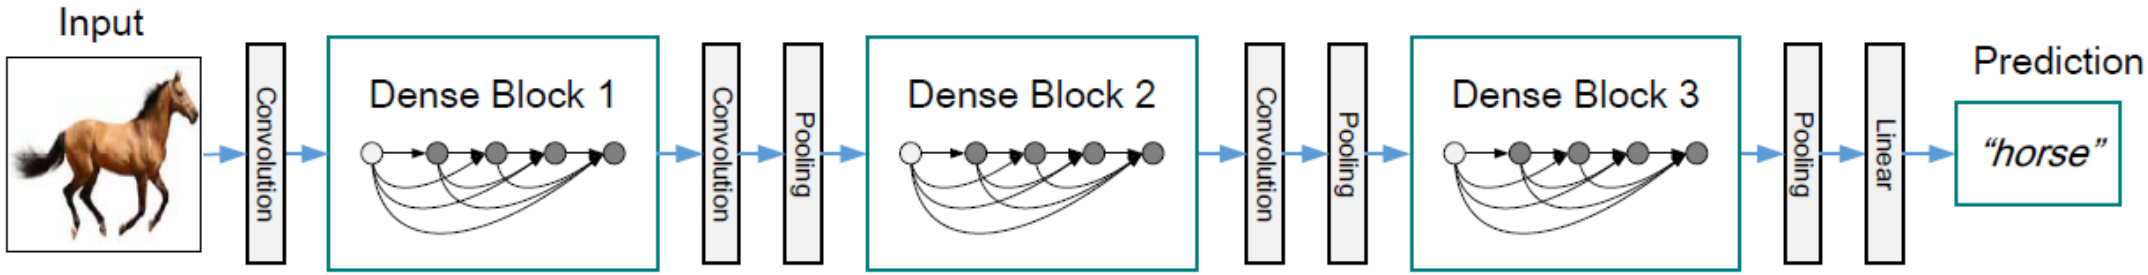

DenseNet

(Huang et al., 2017)

Набор dense блоков, разделенных transition слоями

Архитектуры для ImageNet

Layers	Output Size	DenseNet-121	DenseNet-169	DenseNet-201	DenseNet-264
Convolution	112 × 112	7 × 7 conv, stride 2			
Pooling	56 × 56	3 × 3 max pool, stride 2			
Dense Block (1)	56 × 56	[1 × 1 conv; 3 × 3 conv] × 6	[1 × 1 conv; 3 × 3 conv] × 6	[1 × 1 conv; 3 × 3 conv] × 6	[1 × 1 conv; 3 × 3 conv] × 6
Transition Layer (1)	56 × 56	1 × 1 conv			
	28 × 28	2 × 2 average pool, stride 2			
Dense Block (2)	28 × 28	[1 × 1 conv; 3 × 3 conv] × 12	[1 × 1 conv; 3 × 3 conv] × 12	[1 × 1 conv; 3 × 3 conv] × 12	[1 × 1 conv; 3 × 3 conv] × 12
Transition Layer (2)	28 × 28	1 × 1 conv			
	14 × 14	2 × 2 average pool, stride 2			
Dense Block (3)	14 × 14	[1 × 1 conv; 3 × 3 conv] × 24	[1 × 1 conv; 3 × 3 conv] × 32	[1 × 1 conv; 3 × 3 conv] × 48	[1 × 1 conv; 3 × 3 conv] × 64
Transition Layer (3)	14 × 14	1 × 1 conv			
	7 × 7	2 × 2 average pool, stride 2			
Dense Block (4)	7 × 7	[1 × 1 conv; 3 × 3 conv] × 16	[1 × 1 conv; 3 × 3 conv] × 32	[1 × 1 conv; 3 × 3 conv] × 32	[1 × 1 conv; 3 × 3 conv] × 48
Classification Layer	1 × 1	7 × 7 global average pool			
		1000D fully-connected, softmax			

Table 1: DenseNet architectures for ImageNet. The growth rate for all the networks is $k = 32$. Note that each "conv" layer shown in the table corresponds the sequence BN-ReLU-Conv.

DenseNet

(Huang et al., 2017)

Результаты на ImageNet

Model	top-1	top-5
DenseNet-121	25.02 / 23.61	7.71 / 6.66
DenseNet-169	23.80 / 22.08	6.85 / 5.92
DenseNet-201	22.58 / 21.46	6.34 / 5.54
DenseNet-264	22.15 / 20.80	6.12 / 5.29

Table 3: The top-1 and top-5 error rates on the ImageNet validation set, with single-crop / 10-crop testing.

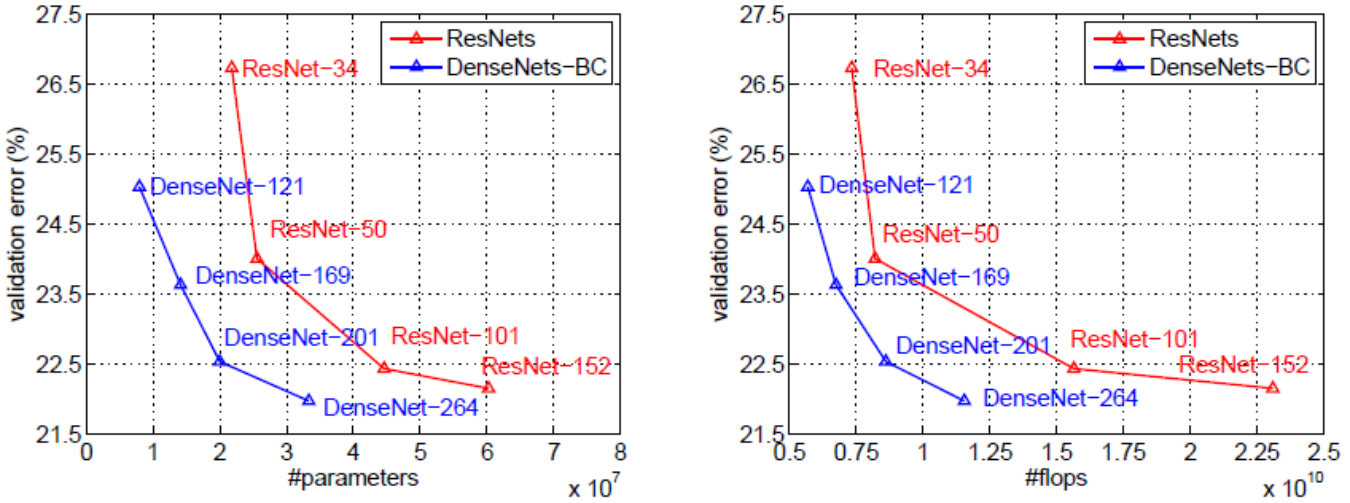

Figure 3: Comparison of the DenseNets and ResNets top-1 error rates (single-crop testing) on the ImageNet validation dataset as a function of learned parameters (*left*) and FLOPs during test-time (*right*).

DenseNet-BC = DenseNet + bottleneck + channel reduction x0.5 in transition layers

Wide Residual Networks

(Zagoruyko et al., 2016)

Ширина сети также важна как глубина

50 слойная wide ResNet точнее, чем 152 слойная обычная ResNet

Увеличение ширины сети по сравнению с глубиной позволяет достичь большей скорости за счет распараллеливания матричных операций на GPU

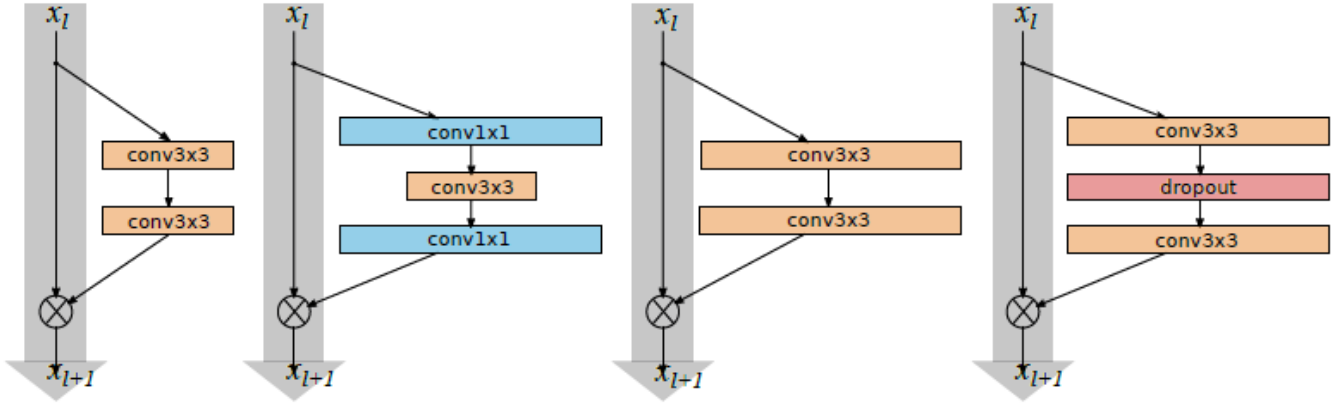

Архитектура для CIFAR-10

group name	output size	block type = $B(3,3)$
conv1	32×32	$[3\times3,\ 16]$
conv2	32×32	$\begin{bmatrix} 3\times3,\ 16\times k \\ 3\times3,\ 16\times k \end{bmatrix} \times N$
conv3	16×16	$\begin{bmatrix} 3\times3,\ 32\times k \\ 3\times3,\ 32\times k \end{bmatrix} \times N$
conv4	8×8	$\begin{bmatrix} 3\times3,\ 64\times k \\ 3\times3,\ 64\times k \end{bmatrix} \times N$
avg-pool	1×1	$[8 \times 8]$

Baseline ResNet
k=1

Wide ResNet
k=2..10
N=3..10

Identity Mappings in Deep Residual Networks

(He et al., 2016)

Существенно улучшили residual block

Сделали прямой путь для распространения информации через всю сеть
(активационные функции внесли в residual connection + переставили Batch Norm)

Стало возможным тренировать глубокие ResNet сети без потери точности (ранее на CIFAR-10 ResNet-1202 давала худшую точность, чем ResNet-110)

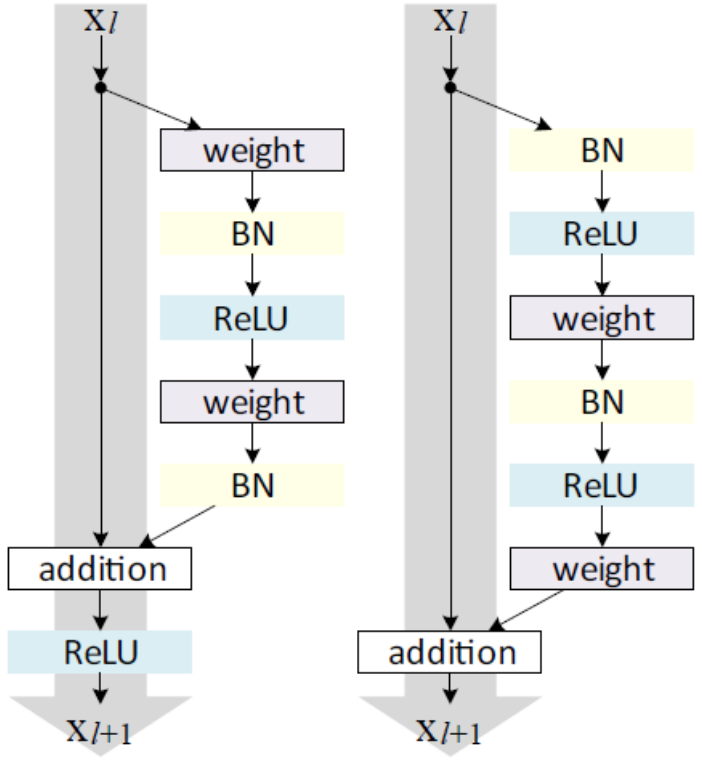

(a) original (b) proposed

Identity Mappings in Deep Residual Networks

(He et al., 2016)

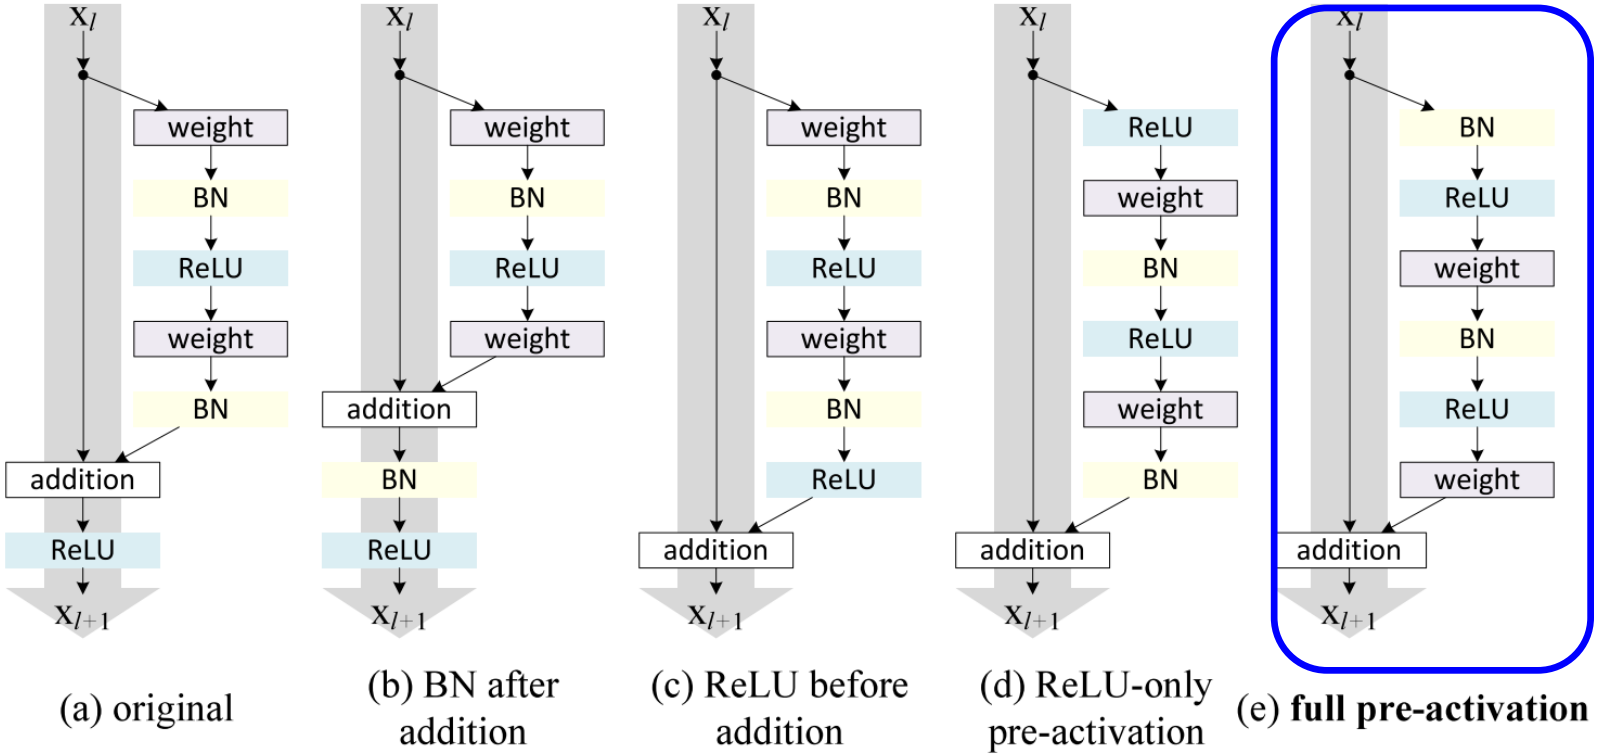

(a) original | (b) BN after addition | (c) ReLU before addition | (d) ReLU-only pre-activation | (e) **full pre-activation**

Classication error (%) on the CIFAR-10

case	ResNet-110	ResNet-164
original ResNet unit (a)	6.61	5.93
BN after addition (b)	8.17	6.50
ReLu before addition (c)	7.84	6.14
ReLu-only pre-activation (d)	6.71	5.91
full pre-activation (e)	**6.37**	**5.46**

ReLu и BatchNorm в потоке информации. Плохо!

Положительная добавка. Плохо!

Добавка с единичным распределением. Плохо!

Добавка может иметь произвольное распределение. **Хорошо!**

Identity Mappings in Deep Residual Networks

(He et al., 2016)

ImageNet результаты

Table 5. Comparisons of single-crop error on the ILSVRC 2012 validation set. All ResNets are trained using the same hyper-parameters and implementations as [1]). Our Residual Units are the full pre-activation version (Fig. 4(e)). †: code/model available at https://github.com/facebook/fb.resnet.torch/tree/master/pretrained, using scale and aspect ratio augmentation in [20].

method	augmentation	train crop	test crop	top-1	top-5
ResNet-152, original Residual Unit [1]	scale	224×224	224×224	23.0	6.7
ResNet-152, original Residual Unit [1]	scale	224×224	320×320	21.3	5.5
ResNet-200, original Residual Unit [1]	scale	224×224	320×320	21.8	6.0
ResNet-200, **pre-act** Residual Unit	scale	224×224	320×320	**20.7**	**5.3**

ResNet-200 + original Residual Unit дает худшую точность, чем ResNet-152

ResNet-200 + pre-act Residual Unit точнее, чем ResNet-152

Deep Networks with Stochastic Depth

(Huang et al., 2016)

Идея: уменьшаем время тренировки и улучшаем распространение градиентов за счет уменьшения глубины сети во время тренировки

Случайно выкидываем residual connections во время тренировки (регуляризация ≈ ансамбль моделей)

Во время теста запускаем всю сеть

ResNet-1202 со случайной глубиной

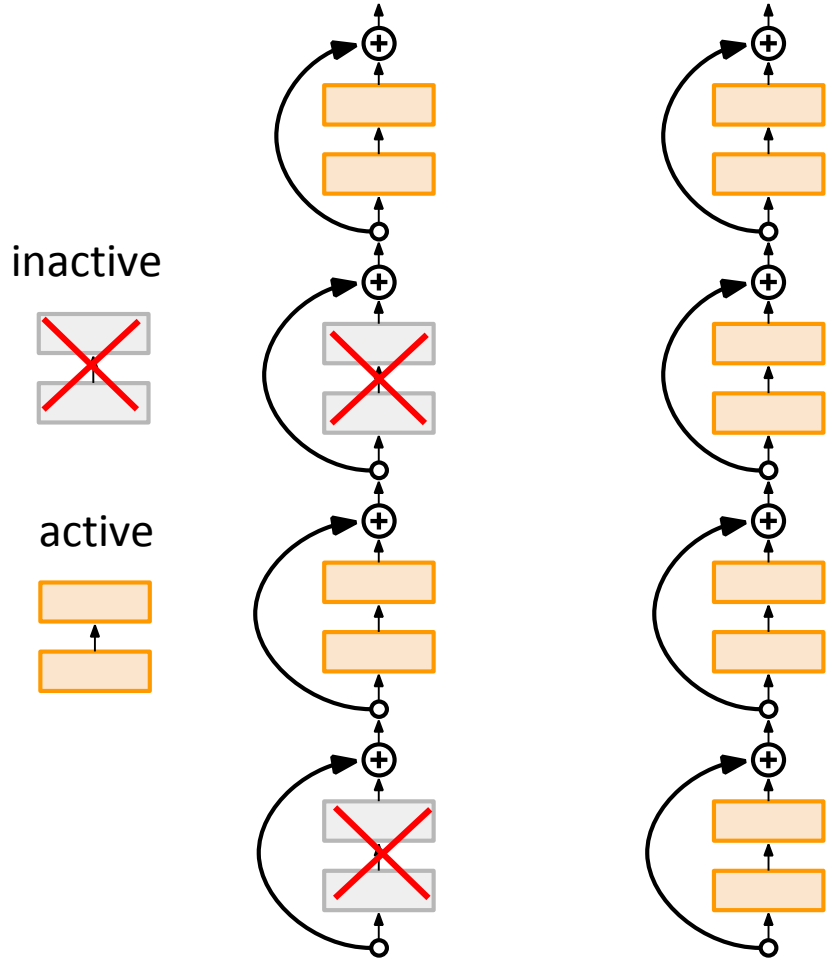

Deep Networks with Stochastic Depth

(Huang et al., 2016)

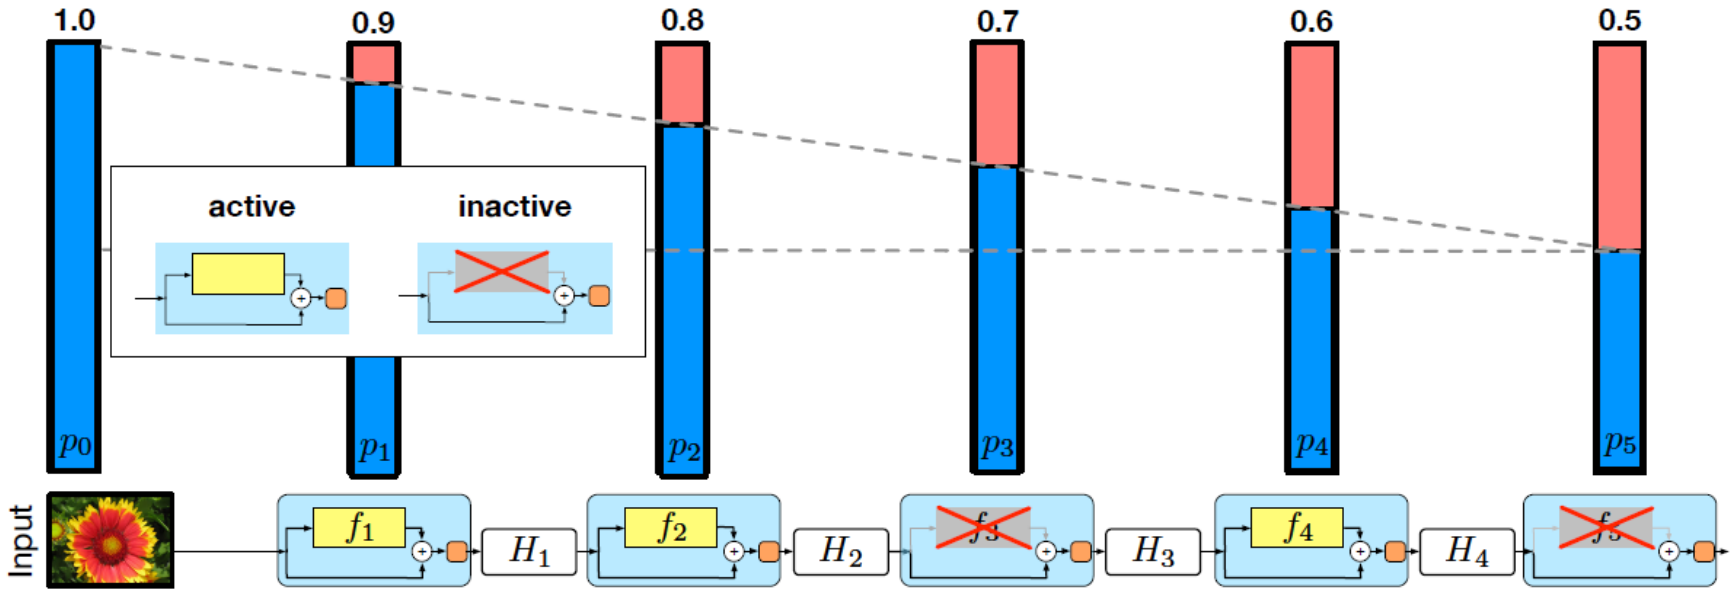

Fig. 2. The linear decay of p_ℓ illustrated on a ResNet with stochastic depth for $p_0 = 1$ and $p_L = 0.5$. Conceptually, we treat the input to the first ResBlock as H_0, which is always active.

Лучшие результаты с p_L=0.5

SqueezeNet

(Iandola et al., 2017)

Сфокусированы на уменьшении числа параметров

Fire block:

- squeeze layer 1x1 CONV
- expand layer 1x1 и 3x3 CONV

Точность как у AlexNet на ImageNet, но параметров в x50 меньше

Используя Deep Compression SqueezeNet можно сжать до размера в x510 меньше, чем AlexNet (0.5Mb)

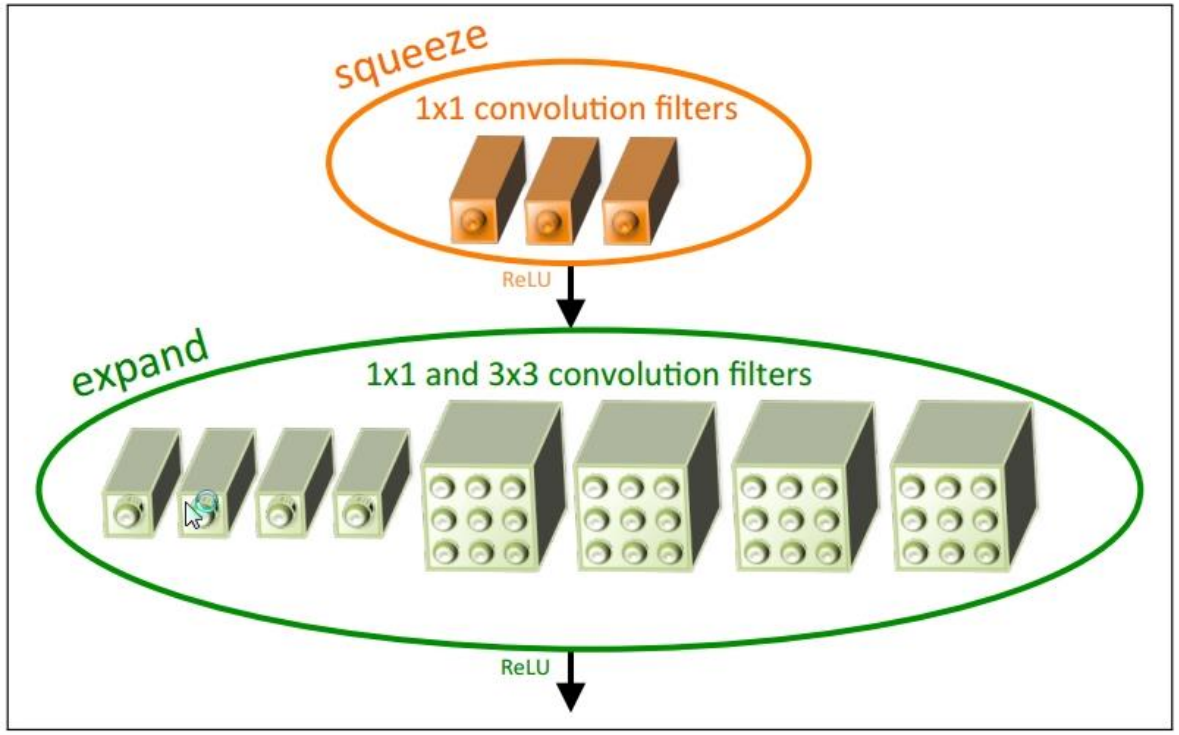

SqueezeNet

(Iandola et al., 2017)

Fire block

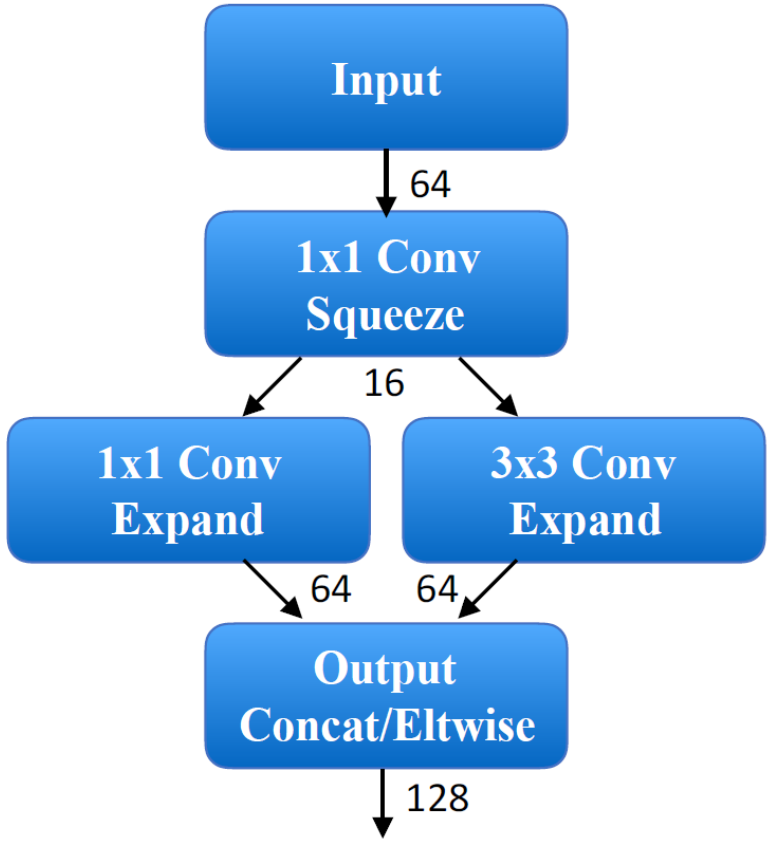

Vanilla SqueezeNet

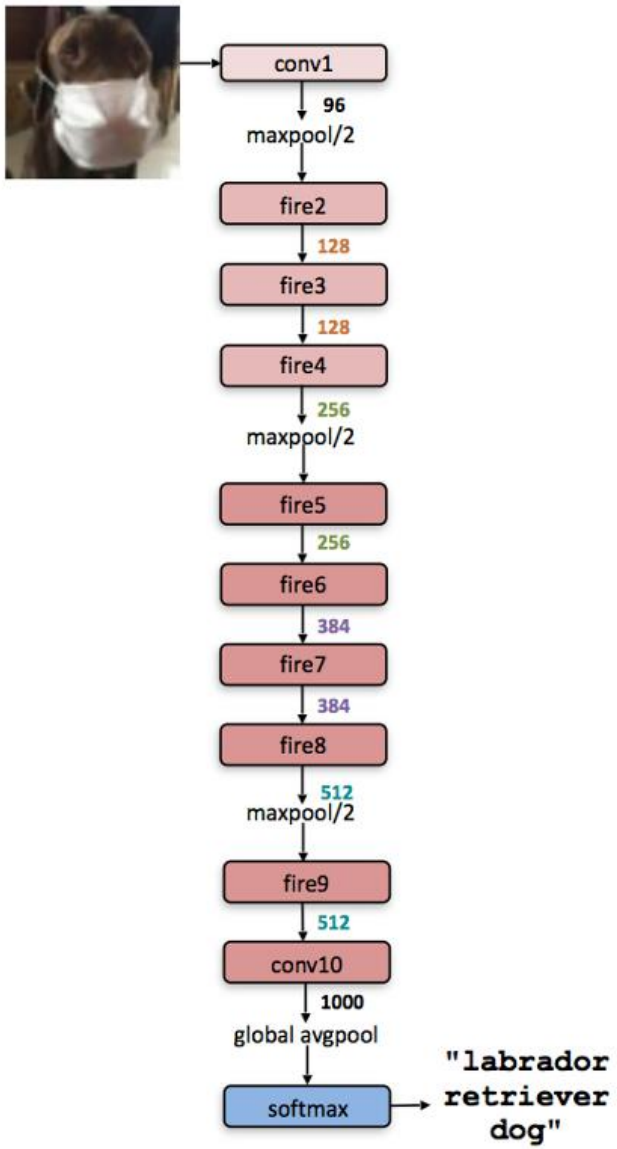

SqueezeNet

(Iandola et al., 2017)

Table 2: Comparing SqueezeNet to model compression approaches. By *model size*, we mean the number of bytes required to store all of the parameters in the trained model.

CNN architecture	Compression Approach	Data Type	Original → Compressed Model Size	Reduction in Model Size vs. AlexNet	Top-1 ImageNet Accuracy	Top-5 ImageNet Accuracy
AlexNet	None (baseline)	32 bit	240MB	1x	57.2%	80.3%
AlexNet	SVD (Denton et al., 2014)	32 bit	240MB → 48MB	5x	56.0%	79.4%
AlexNet	Network Pruning (Han et al., 2015b)	32 bit	240MB → 27MB	9x	57.2%	80.3%
AlexNet	Deep Compression (Han et al., 2015a)	5-8 bit	240MB → 6.9MB	35x	57.2%	80.3%
SqueezeNet (ours)	None	32 bit	4.8MB	**50x**	57.5%	80.3%
SqueezeNet (ours)	Deep Compression	8 bit	4.8MB → 0.66MB	**363x**	57.5%	80.3%
SqueezeNet (ours)	Deep Compression	6 bit	4.8MB → 0.47MB	**510x**	57.5%	80.3%

x510 сжатие, по сравнению с AlexNet

240MB -> 0.5MB!

SqueezeNet

(Iandola et al., 2017)

Summary of Deep Compression

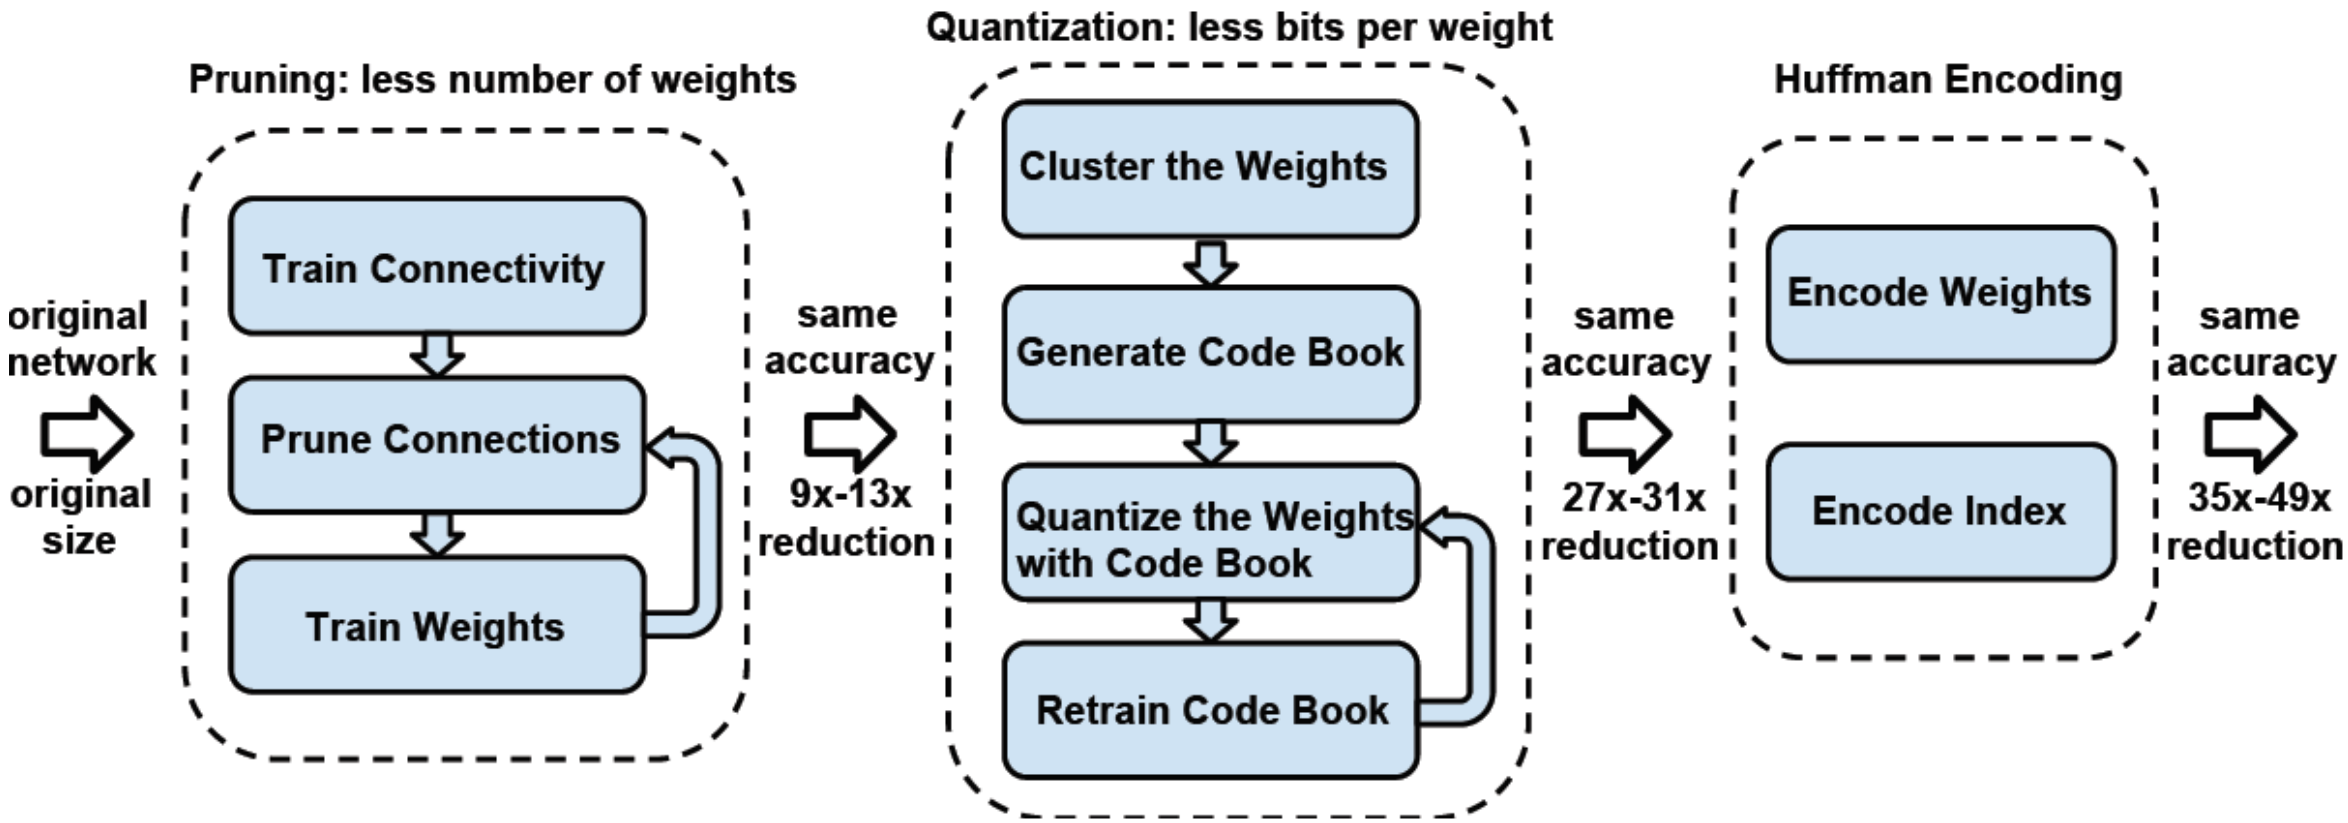

MobileNet v1

(Howard et al., 2017)

Сфокусированы на уменьшении сложности вычислений и числа параметров

Depthwise separable convolutions:

- 3x3 CONV (single filter per each input channel)
- 1x1 CONV (to create a linear combination)

Оптимизация скорости и точности за счет изменения разрешения входного изображения и числа каналов

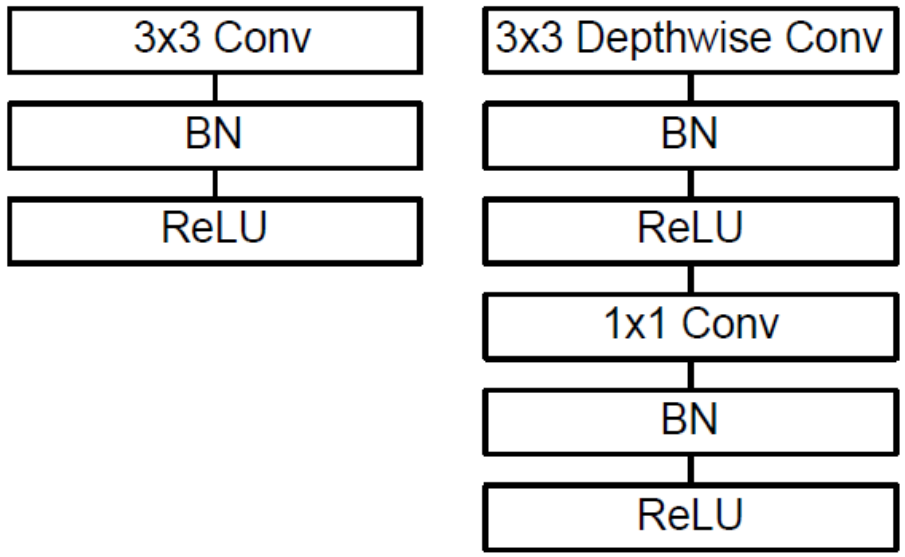

Figure 3. Left: Standard convolutional layer with batchnorm and ReLU. Right: Depthwise Separable convolutions with Depthwise and Pointwise layers followed by batchnorm and ReLU.

MobileNet v1

(Howard et al., 2017)

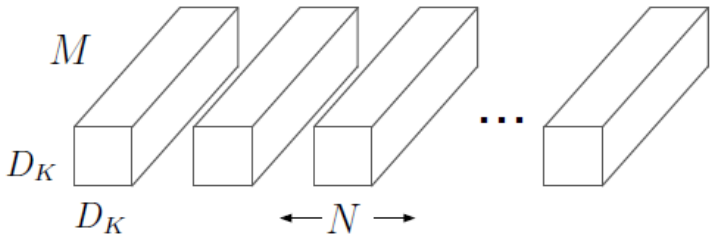

(a) Standard Convolution Filters

Depthwise separable convolutions:

- 3x3 CONV (single filter per each input channel)
- 1x1 CONV (to create a linear combination)

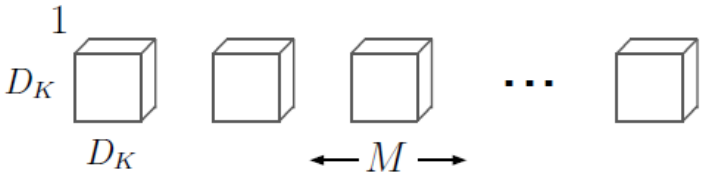

(b) Depthwise Convolutional Filters

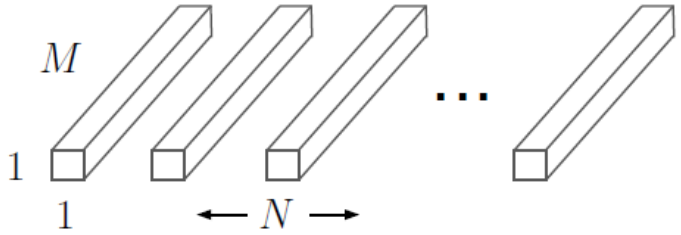

(c) 1×1 Convolutional Filters called Pointwise Convolution in the context of Depthwise Separable Convolution

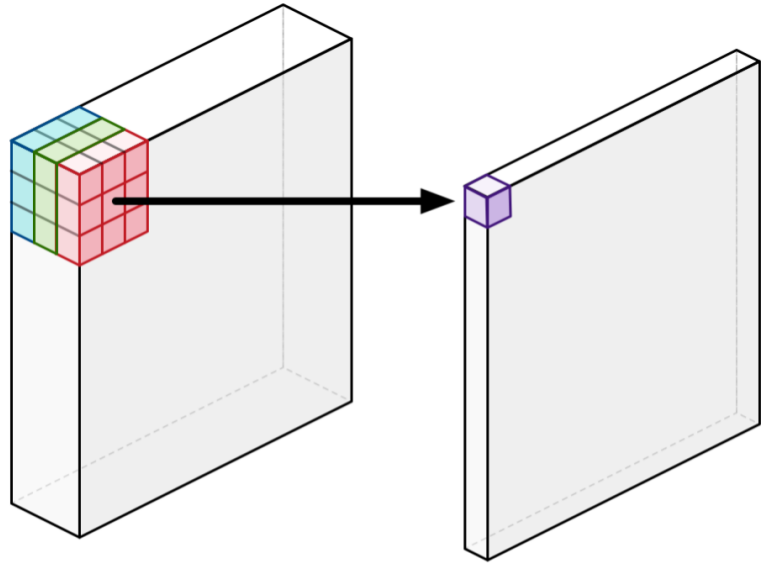

convolution

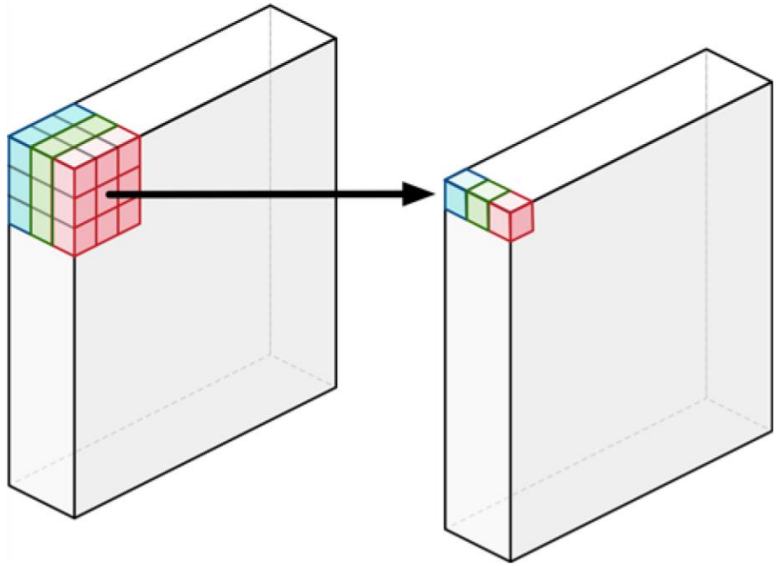

depthwise convolution

MobileNet v1

(Howard et al., 2017)

Table 1. MobileNet Body Architecture

Type / Stride	Filter Shape	Input Size
Conv / s2	$3 \times 3 \times 3 \times 32$	$224 \times 224 \times 3$
Conv dw / s1	$3 \times 3 \times 32$ dw	$112 \times 112 \times 32$
Conv / s1	$1 \times 1 \times 32 \times 64$	$112 \times 112 \times 32$
Conv dw / s2	$3 \times 3 \times 64$ dw	$112 \times 112 \times 64$
Conv / s1	$1 \times 1 \times 64 \times 128$	$56 \times 56 \times 64$
Conv dw / s1	$3 \times 3 \times 128$ dw	$56 \times 56 \times 128$
Conv / s1	$1 \times 1 \times 128 \times 128$	$56 \times 56 \times 128$
Conv dw / s2	$3 \times 3 \times 128$ dw	$56 \times 56 \times 128$
Conv / s1	$1 \times 1 \times 128 \times 256$	$28 \times 28 \times 128$
Conv dw / s1	$3 \times 3 \times 256$ dw	$28 \times 28 \times 256$
Conv / s1	$1 \times 1 \times 256 \times 256$	$28 \times 28 \times 256$
Conv dw / s2	$3 \times 3 \times 256$ dw	$28 \times 28 \times 256$
Conv / s1	$1 \times 1 \times 256 \times 512$	$14 \times 14 \times 256$
$5\times$ Conv dw / s1	$3 \times 3 \times 512$ dw	$14 \times 14 \times 512$
$5\times$ Conv / s1	$1 \times 1 \times 512 \times 512$	$14 \times 14 \times 512$
Conv dw / s2	$3 \times 3 \times 512$ dw	$14 \times 14 \times 512$
Conv / s1	$1 \times 1 \times 512 \times 1024$	$7 \times 7 \times 512$
Conv dw / s2	$3 \times 3 \times 1024$ dw	$7 \times 7 \times 1024$
Conv / s1	$1 \times 1 \times 1024 \times 1024$	$7 \times 7 \times 1024$
Avg Pool / s1	Pool 7×7	$7 \times 7 \times 1024$
FC / s1	1024×1000	$1 \times 1 \times 1024$
Softmax / s1	Classifier	$1 \times 1 \times 1000$

Table 2. Resource Per Layer Type

Type	Mult-Adds	Parameters
Conv 1×1	94.86%	74.59%
Conv DW 3×3	3.06%	1.06%
Conv 3×3	1.19%	0.02%
Fully Connected	0.18%	24.33%

Основное число операций и параметров в CONV 1x1!

MobileNet v1

(Howard et al., 2017)

Depthwise CONV уменьшают число параметров и операций умножения-сложения

Table 4. Depthwise Separable vs Full Convolution MobileNet

Model	ImageNet Accuracy	Million Mult-Adds	Million Parameters
Conv MobileNet	71.7%	4866	29.3
MobileNet	70.6%	569	4.2

Оптимизация числа каналов

Table 6. MobileNet Width Multiplier

Width Multiplier	ImageNet Accuracy	Million Mult-Adds	Million Parameters
1.0 MobileNet-224	70.6%	569	4.2
0.75 MobileNet-224	68.4%	325	2.6
0.5 MobileNet-224	63.7%	149	1.3
0.25 MobileNet-224	50.6%	41	0.5

Table 7. MobileNet Resolution

Resolution	ImageNet Accuracy	Million Mult-Adds	Million Parameters
1.0 MobileNet-224	70.6%	569	4.2
1.0 MobileNet-192	69.1%	418	4.2
1.0 MobileNet-160	67.2%	290	4.2
1.0 MobileNet-128	64.4%	186	4.2

Оптимизация разрешения входного изображения

MobileNet v1

(Howard et al., 2017)

Особенности тренировки простых MobileNets:

- слабая регуляризация и аугментация данных
- иногда авторы отключали l2 decay для Depthwise CONV

MobileNet v2

(Sandler et al., 2018)

Дальнейшее уменьшение числа операций и параметров

Inverted residual unit:

- 1x1 CONV ReLU with **expansion**
- 3x3 CONV Depthwise ReLU
- 1x1 CONV **linear (no activation func)**

Оптимизация скорости и точности за счет сохранения информации в inverted residual unit

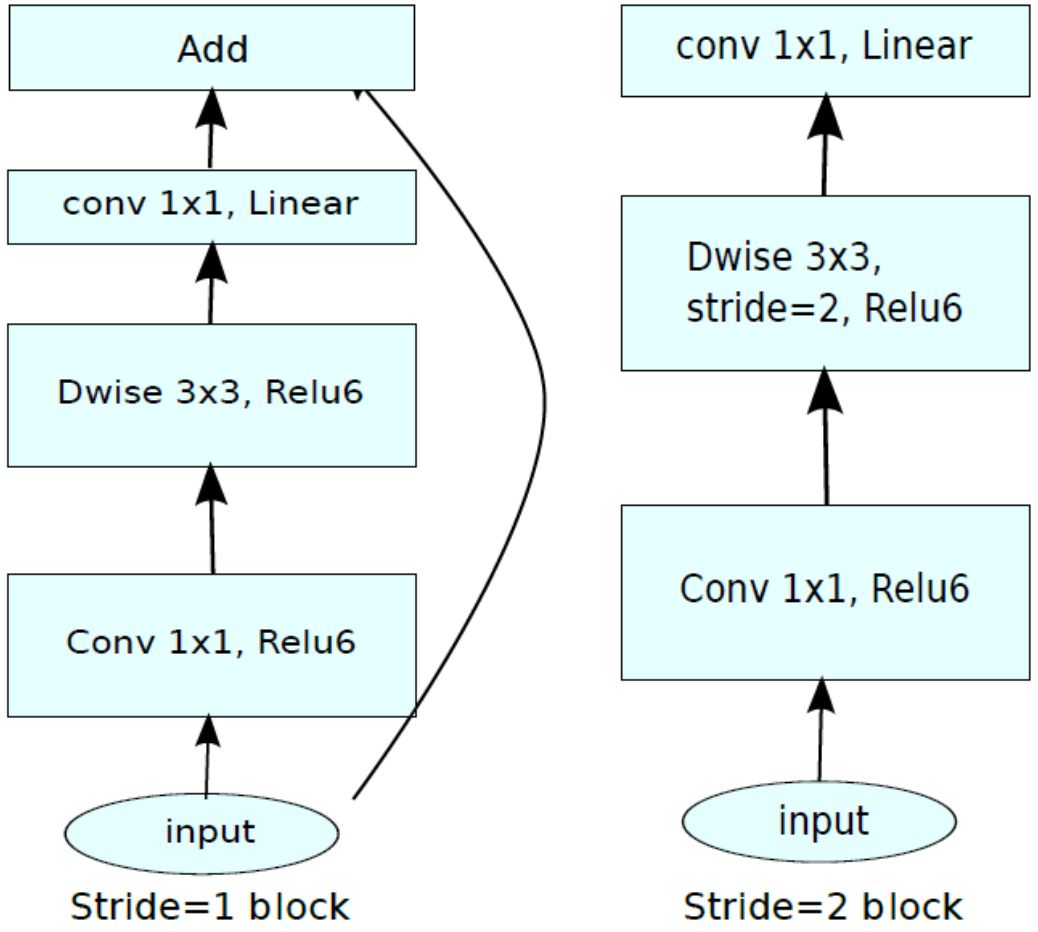

MobileNet v2

(Sandler et al., 2018)

ImageNet результаты

Network	Top 1	Params	MAdds	CPU
MobileNetV1	70.6	4.2M	575M	113ms
ShuffleNet (1.5)	71.5	**3.4M**	292M	-
ShuffleNet (x2)	73.7	5.4M	524M	-
NasNet-A	74.0	5.3M	564M	183ms
MobileNetV2	**72.0**	**3.4M**	**300M**	**75ms**
MobileNetV2 (1.4)	**74.7**	6.9M	585M	**143ms**

v2 > v1

Архитектура

Input	Operator	t	c	n	s
$224^2 \times 3$	conv2d	-	32	1	2
$112^2 \times 32$	bottleneck	1	16	1	1
$112^2 \times 16$	bottleneck	6	24	2	2
$56^2 \times 24$	bottleneck	6	32	3	2
$28^2 \times 32$	bottleneck	6	64	4	2
$14^2 \times 64$	bottleneck	6	96	3	1
$14^2 \times 96$	bottleneck	6	160	3	2
$7^2 \times 160$	bottleneck	6	320	1	1
$7^2 \times 320$	conv2d 1x1	-	1280	1	1
$7^2 \times 1280$	avgpool 7x7	-	-	1	-
$1 \times 1 \times 1280$	conv2d 1x1	-	k	-	

t - expansion factor
c - number of output channels
n - number of repetitions
s - stride

Neural Architecture Search:

Neural Architecture Search with Reinforcement Learning (NAS) *[Zoph et al. 2016]*

- "Controller" network that learns to design a good network architecture (output a string corresponding to network design)
- Iterate:
  1) Sample an architecture from search space
  2) Train the architecture to get a "reward" R corresponding to accuracy
  3) Compute gradient of sample probability, and scale by R to perform controller parameter update (i.e. increase likelihood of good architecture being sampled, decrease likelihood of bad architecture)

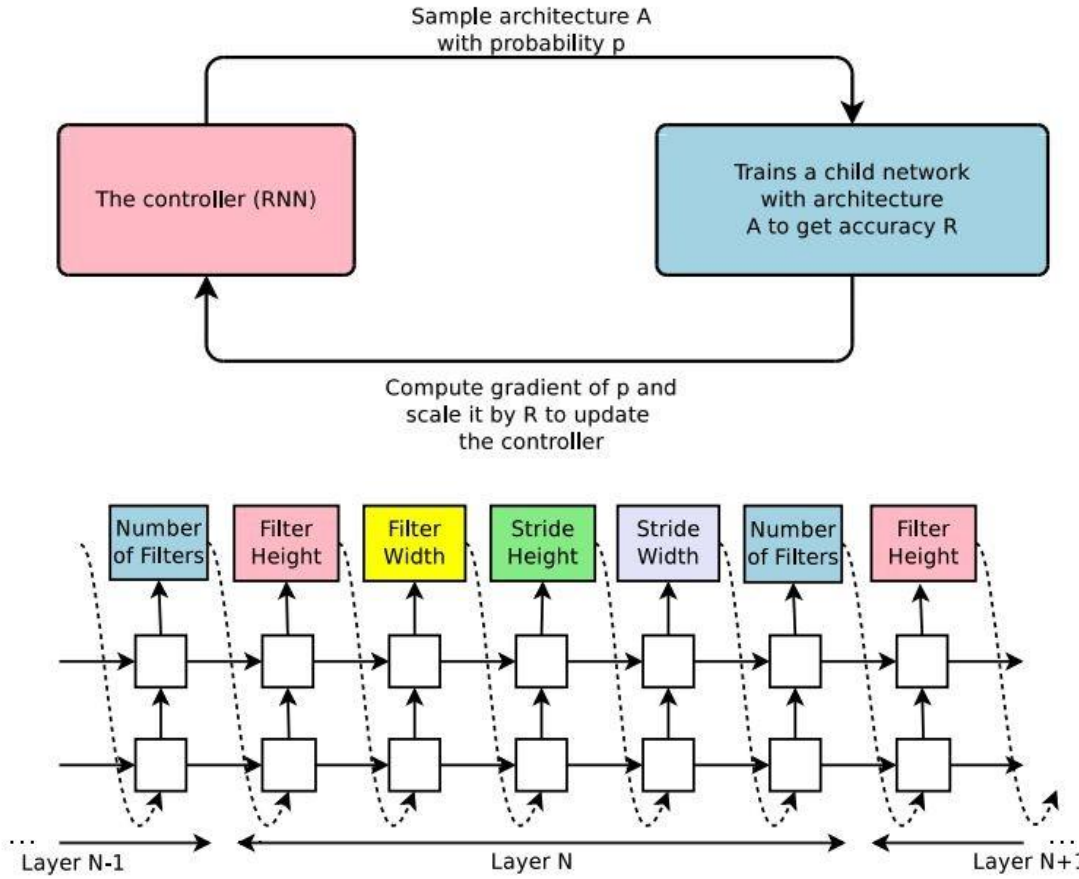

Neural Architecture Search:

Learning Transferable Architectures for Scalable Image Recognition *[Zoph et al. 2017]*

- Applying neural architecture search (NAS) to a large dataset like ImageNet is expensive
- Design a search space of building blocks ("cells") that can be flexibly stacked
- NASNet: Use NAS to find best cell structure on smaller CIFAR-10 dataset, then transfer architecture to ImageNet

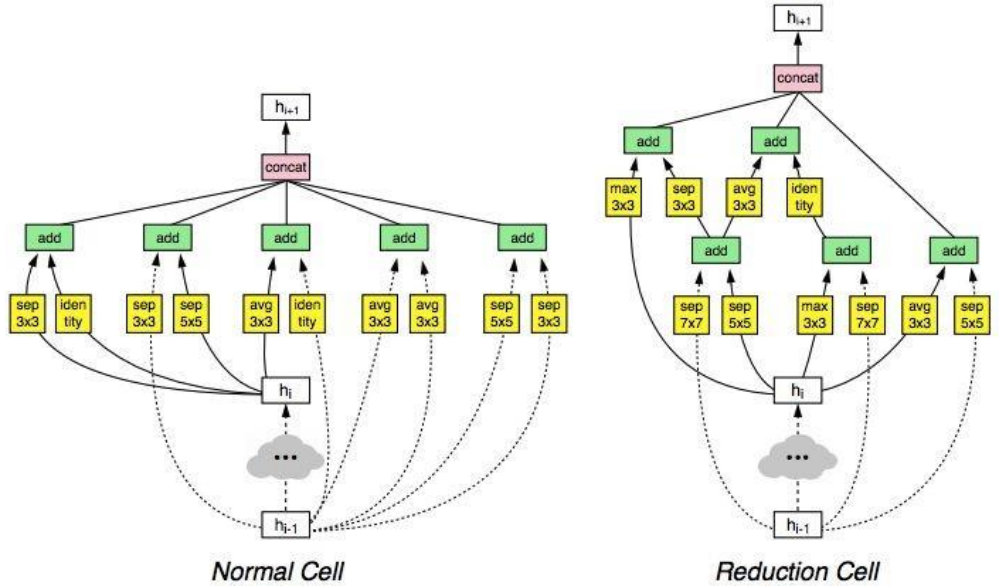

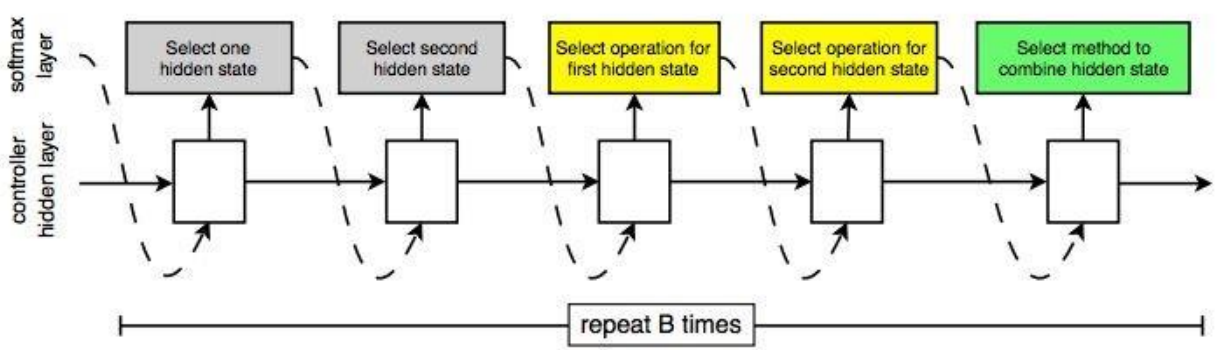

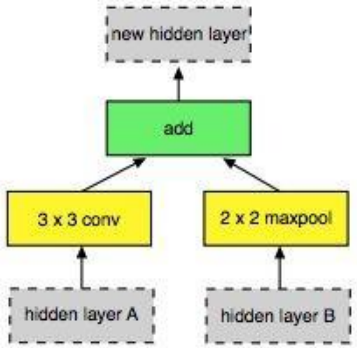

Резюме: модели нейронных сетей

Мы разобрали основные модели

- AlexNet
- VGG
- GoogleNet
- ResNet

Также посмотрели

- ResNeXt
- SE Nets
- Wide ResNet
- ResNet with Stochastic Depth
- MobileNets
- SqueezeNet
- DenseNet

Резюме: модели нейронных сетей

- Широко используются VGG, GoogLeNet, ResNet
- Последние улучшения архитектур:
  - увеличение глубины сетей
  - применение residual blocks = identity mappings + residual connections
  - усложнение residual blocks (attention)
  - **NAS**
- Рекомендую модели: GoogleNet, ResNet, DenseNet

- На следующем занятии
  Caffe, NVIDIA DIGITS и TensorFlow